Memorias R Day

Segundo encuentro nacional de usuarios de R

24 de noviembre de 2023
Medellín, Antioquia, Colombia



Editora: **Olga Cecilia Usuga Manco**

UNIVERSIDAD DE ANTIOQUIA
UNIVERSIDAD NACIONAL DE COLOMBIA
ITM Institución Universitaria Reacreditada en Alta Calidad
UNAD Universidad Nacional Abierta y a Distancia ACREDITADA EN ALTA CALIDAD

Comité Organizador

Olga Cecilia Usuga Manco
Profesora Titular
Departamento de Ingeniería Industrial
Universidad de Antioquia
olga.usuga@udea.edu.co

Carmen Elena Patiño Rodríguez
Profesora Titular
Departamento de Ingeniería Industrial
Universidad de Antioquia
elena.patino@udea.edu.co

Freddy Hernández Barajas
Profesor Asociado
Escuela de Estadística
Universidad Nacional de Colombia, sede Medellín
fhernanb@unal.edu.co

Romario Ademir Conto López
Profesor
Facultad de Ciencias Económicas y Administrativas
Instituto Tecnológico Metropolitano
romarioconto@itm.edu.co

Martha Catalina Ospina Hernández
Profesora
Universidad Nacional Abierta y a Distancia de Colombia
martha.ospina@unad.edu.co

Comité Científico

Olga Cecilia Usuga Manco
Profesora Titular
Departamento de Ingeniería Industrial
Universidad de Antioquia
olga.usuga@udea.edu.co

Carmen Elena Patiño Rodríguez
Profesora Titular
Departamento de Ingeniería Industrial
Universidad de Antioquia
elena.patino@udea.edu.co

Freddy Hernández Barajas
Profesor Asociado
Escuela de Estadística
Universidad Nacional de Colombia, sede Medellín
fhernanb@unal.edu.co

Romario Ademir Conto López
Profesor
Facultad de Ciencias Económicas y Administrativas
Instituto Tecnológico Metropolitano
romarioconto@itm.edu.co

Diana Marcela Pérez Valencia
Investigadora
BCAM - Basque Center for Applied Mathematics, Bilbao, Spain
dimapeva@gmail.com

María Valentina Clavijo Mesa
PhD Student - 38th cycle
Laboratory of Signal and Risk Analysis (LASAR)
Politecnico di Milano
valentina.clavijo@udea.edu.co

R Day es un evento que ha tenido un impacto positivo en la comunidad científica y empresarial debido a la versatilidad del lenguaje de programación R. Este evento se ha realizado en diferentes ciudades del mundo, en esta ocasión se realizará por segunda vez en Medellín. Con el R Day queremos integrar la comunidad de usuarios de R en Colombia y llamar la atención de quienes aún no lo conocen.

Contacto

R Day
Universidad Nacional de Colombia, sede Medellín
Facultad de Ciencias
Escuela de Estadística
Carrera No. 65 – 59A 110
Medellín, Colombia
Tel: (57-4) 4309808
Email: rdaycolombia@gmail.com
Webpage: https://rday-colombia.github.io/2023/

ISSN: 2981-7188 (En línea)

CONTENIDO

Los contenidos de las publicaciones son responsabilidad de sus autores, toda vez que estas no han sido editadas por el Comité Organizador.

Comunicaciones

1. Efecto de las experiencias traumáticas tempranas en los mecanismos de desconexión moral en adultos jóvenes de la ciudad de Medellín. Edison Alexander Ocampo Osorio, Raúl Alejandro Morán Vásquez, David Andrés Montoya Arenas y Ana Milena Gaviria Gómez.

2. Procesamiento y análisis de datos de resistencia antimicrobiana de WHONET con R. Jorge Mario Estrada Álvarez, Hernán Felipe García Arias y Maryluz Hincapié Acuña.

3. Predicción inteligente de diabetes mellitus tipo 2 usando R y mapas cognitivos difusos. Kenia Hoyos, Rander Ruíz, y William Hoyos.

4. Uso de R para el análisis y creación de informes de secuenciación de exomas en pacientes con asfixia perinatal. Diego Mauricio Gómez Londoño, Hernán Felipe García Árias, Natalia Trujillo Árias, Jorge Mario Estrada Álvarez, Natalia Cardona Ramírez, Juan Alejandro Trujillo Posada y Gloria-Liliana Porras Hurtado.

5. Boletines epidemiológicos con R. Carlos Andrés Barco Rojas y Jorge Mario Estrada Álvarez.

6. Diseño y validación de un instrumento de medida para el razonamiento estadístico de estudiantes de las Ciencias de la Salud. Jaime A Gaviria Bedoya, Difariney González Gómez y Jhony A Villa Ochoa.

7. Análisis de conglomerados jerárquicos para optimizar la distribución diferenciada de estudiantes de décimo grado del colegio Marymount de Barranquilla en la preparación de las Pruebas Saber 11. Elmer S. Rodríguez Stevez y Sandra M. López Romano.

8. Solución de problemas de prueba de hipótesis para promedio y proporción usando R. Wilson Rodríguez Calderón y Myriam R. Pallares Muñoz.

9. Distribución discreta Poisson XLindley. Mariana Blandón Mejía y Freddy-Hernández Barajas.

10. Metaanálisis de metaheurísticas empleando R. Daniela Alcázar, Aura María Molina, Alejandro Arenas-Vasco y Juan G. Villegas.

11. Estudio de simulación y análisis de la distribución discreta invertida de Kumaraswamy. Daniel Felipe Villa Rengifo y Freddy Hernández-Barajas.

12. Métodos de selección de variables en R para incrementar el poder discriminatorio del Análisis envolvente de datos (DEA). Andrés Mauricio Gómez, Andrés Mauricio Villegas y Juan G. Villegas.

13. Implementación de la distribución Burr Hatke para evaluar el proceso de estimación de parámetros en datos sobre dispersos. Valentina Hurtado Sepúlveda y Freddy Hernández-Barajas.

14. Herramientas Matemáticas para el Análisis de Actividad Física. Oscar Eduardo Martínez Castiblanco.

15. Analítica descriptiva de la evaluación de desempeño financiero de las PYMES individuales en Colombia. Luis Felipe Marulanda, Gloria Lucía Ramírez y Olga Cecilia Usuga-Manco.

16. Estimaciones espaciales de evapotranspiración multianual usando R para aplicaciones hidrológicas. Breiner Dan Bastidas Osejo y Laura Ximena Echeverri Gutiérrez.

17. Análisis estadístico multivariado aplicado a datos hidrogeológicos usando R: Acuífero Transfronterizo del Amazonas (ATAS) en Leticia – Amazonas. Laura Ximena Echeverri Gutiérrez y Breiner Dan Bastidas Osejo.

18. R Ladies Medellín - Aplicativo Web. Sara Garces Cespedes, Valentina Clavijo Mesa, Stephany Lobo Laguado, Carmen Elena Patino-Rodríguez, Ana Sánchez Henao y Olga Cecilia Usuga-Manco.

19. Ciencia de datos: salarios bajo la lupa. Daniela Alcázar, Esteffany Peña y Juliana Rueda.

20. Dashboard para la visualización de las variables que afectan la confiabilidad y la eficiencia en la operación de patinetas eléctricas. José Luis Osorio Ariza, Carmen Elena Patino-Rodríguez, Fernando Guevara-Carazas, Freddy Hernández-Barajas, Olga Cecilia Usuga-Manco.

21. Análisis descriptivo de las variables que afectan el tiempo de vida remanente en la operación de elementos críticos de bicicletas eléctricas. Laura Herrera Giraldo,

Memorias R Day
Segundo encuentro nacional de usuarios de R
Medellín, Antioquia, Colombia – 24 de noviembre de 2023

Alexander Amaya León, Carmen Elena Patino-Rodríguez, Olga Cecilia Usuga-Manco, Fernando Guevara-Carazas y Freddy Hernández-Barajas.

Efecto de las experiencias traumáticas tempranas en los mecanismos de desconexión moral en adultos jóvenes de la ciudad de Medellín. *

Edison Alexander Ocampo Osorio *Universidad de Antioquia - Universidad de San Buenaventura*
Raúl Alejandro Morán Vásquez *Universidad de Antioquia*
David Andrés Montoya Arenas *Universidad de San Buenaventura - Medellín*
Ana Milena Gaviria Gómez *Universidad de San Buenaventura - Medellín*

Resumen: La violencia es un fenómeno complejo con evidencia de asociación a Experiencias Traumáticas Tempranas (ETT) y a Mecanismos de Desconexión Moral (MDM), siendo para la OMS un problema de salud pública, con impactos devastadores para la humanidad. Objetivo: analizar el efecto de las ETT en los MDM, con mediación de la autoeficacia y moderación las conductas prosociales en adultos jóvenes de Medellín. Metodología: enfoque cuantitativo, observacional y analítico con diseño transversal. Para el modelado y análisis de los datos se empleó la técnica de Modelos de Ecuaciones Estructurales de Mínimos Cuadrados Parciales (siglas en inglés PLS-SEM) para maximizar la varianza explicada en los constructos dependientes. Se usó R con interfaz de R Studio y el paquete "seminr". Se obtuvieron estadísticos de los modelos de medida reflectivos, y en el modelo interno se estimaron los coeficientes de vías, los efectos y valores de ajuste del modelo que evidenciaron las relaciones entre las variables.

Keywords: Desarrollo moral, maltrato infantil, violencia, modelo estadístico, cognición social,mecanismos de desconexión moral.

Introducción

La agresión y la violencia son fenómenos complejos que han demostrado estar vinculados de manera significativa tanto a las Experiencias Traumáticas Tempranas (ETT)(Posada, Londoño and Gaviria, 2019) como a los Mecanismos de Desconexión Moral (MDM) (Bandura et al., 1996). Si bien la violencia es un concepto multifacético e interdisciplinario, se aborda en este estudio desde la perspectiva de la Organización Mundial de la Salud (OMS, 2002) como un problema de salud pública, debido a sus profundos impactos y consecuencias para la humanidad, que incluyen una alta tasa de mortalidad.

Este estudio se concentra en el contexto del Valle de Aburrá, específicamente en la capital del departamento de Antioquia y su área metropolitana, caracterizadas por su densidad poblacional, su historia de conflicto marcada por bandas criminales (Centro Nacional de Memoria Histórica, 2017) y por ser destinos de población desplazada (Sánchez Gómez et al., 2015), que ha experimentado diversas formas de trauma en edades tempranas (ICBF, 2021). Dadas estas particularidades regionales con presencia de comportamientos delictivos en la adolescencia (Policía-Nacional, 2021) y en la juventud (INPEC, 2021), con impacto en la sociedad, lo cual hace relevante investigar

* **Autor de contacto**: ealexander.ocampo@udea.edu.co.

las condiciones que subyacen al fenómeno de la violencia en este entorno.

La investigación se enmarca en las ciencias cognitivas, con un enfoque particular en la psicología social cognitiva de Bandura (1995, 1991). El objetivo principal es analizar cómo la exposición a ETT influye en los MDM, y cómo esta relación se ve influenciada por el nivel de autoeficacia y las conductas prosociales en adultos jóvenes en el Valle de Aburrá.

Metodología:

Este estudio se basa en un enfoque cuantitativo observacional y analítico, con un diseño transversal. La recopilación de datos se realizó en un solo momento a través de la aplicación de instrumentos de medición. Su objetivo es identificar el efecto de las ETT y los MDM en los jóvenes, así como comprender el papel de variables intervinientes, como las tendencias prosociales y la autoeficacia en la regulación emocional. Estos hallazgos contribuirán al conocimiento en el contexto colombiano y proporcionarán fundamentos sólidos para futuros proyectos de promoción y prevención.

Modelo de Análisis:

El modelo propuesto considera a las ETT (Posada, 2020) como variable predictora e independiente, y a los MDM (Gómez-Tabares et al., 2023) como variable dependiente. Además, se incorporan dos constructos de la teoría social cognitiva como variables mediadoras y moderadoras: la autoeficacia para la regulación emocional (Caprara et al., 2008) y las tendencias prosociales (Caprara et al., 2005), respectivamente. Las variables intervinientes incluyen los síndromes disejecutivos (Pedrero-Perez et al., 2015) y la percepción de inseguridad social (Velazquez et al., 1997), que, aunque independientes, pueden tener un efecto explicativo en el modelo.

Para analizar este modelo complejo, se emplea la técnica de Modelos de Ecuaciones Estructurales (siglas en inglés SEM). Dada la naturaleza de la muestra y las distribuciones muestrales, se utiliza el método Partial Least Squares Structural Equation Modeling (PLS-SEM), adecuado para conjuntos de datos de tamaño moderado (Hair Jr et al., 2017).

Procedimiento de Análisis:

El proceso de análisis se inicia especificando tanto el modelo interno como el modelo de medida. Esto se fundamenta en revisiones de literatura y análisis de estudios previos que han establecido relaciones entre las variables. El modelo también considera otras variables que podrían tener efectos explicativos en el fenómeno estudiado. La organización de los datos se realiza teniendo en cuenta la limitación de no superar el 15 % de datos faltantes por observación y garantizando un mínimo de 10 observaciones por relación en la estructura interna (Hair Jr et al., 2017).

Los datos se procesaron utilizando el entorno y lenguaje de programación R (R Core Team, 2019), con la interfaz de R Studio y el paquete “seminr”, considerando que es una sintaxis amigable para el diseño en el programa de los modelos que se van a analizar, permite insertar extensiones, configuraciones para el uso del bootstrapping con códigos de práctico uso, tablas comparativas y las visualizaciones de los resultados evidencian el modelo con sus valores respectivos (Hair Jr et al., 2021). Se tiene también en cuenta que R permite obtener las tablas en formato LaTex

que pueden compilarse como estrategia eficiente para el proceso escritural de los resultados.

El algoritmo PLS-SEM se utilizó para estimar coeficientes de vías y maximizar la varianza explicada en los constructos dependientes. Para los análisis de los modelos de medida reflectivos se analizó el Alpha de Cronbach´s para la consistencia interna o confiabilidad, el indicador de la varianza extraída (siglas en inglés AVE) para la validez convergente y la proporción heterorasgo - monorasgo (siglas en inglés HTMT) para la validez discriminante (Hair Jr et al., 2017).

Para el modelo estructural se analiza el coeficiente de determinación R2, el tamaño del efecto f2, la relevancia predictiva Q2 y el tamaño del efecto q2 . En este paso se requiere evaluar la colinealidad entre las variables del modelo interno a través del factor de inflación de la varianza (siglas en inglés VIF), por otra parte se analizan el valor de las regresiones lineales o coeficientes de vías (Hair Jr et al., 2017), tanto con valores de la muestra y remuestreos usando el método de bootstrap (Hair Jr et al., 2021).

Resultados

Los resultados revelaron un efecto significativo de las ETT en los MDM, destacando el impacto del abuso emocional. Se observó un mejor ajuste del modelo cuando se consideró la autoeficacia para la regulación emocional (ARE) como mediador y las tendencias prosociales (TP) como moderadoras. Además, se identificaron variables intervinientes importantes, como los síndromes disejecutivos (SD) y la percepción de inseguridad social (PSS), que aportan a la comprensión del fenómeno.

La Tabla 1 mostrada a continuación se elaboró usando instrucciones usuales de LaTex.

Tabla 1: Coeficiente de determinacion R^2 y coeficientes de vías

	MDM	ARE
R^2	0.271	0.030
AdjR^2	0.235	0.020
ETT	0.211	-0.172
ARE	-0.189	
TP	-0.143	
SD	0.233	
PSS	0.260	

Una limitación relevante de este estudio fue la dificultad para acceder a la muestra debido a la sensibilidad emocional de las preguntas, lo que afectó la participación y la finalización de los cuestionarios, con implicación para incluir las observaciones en el análisis de los datos.

Teniendo en cuenta la complejidad del fenómeno y la múltiplicidad de variables que intervienen, los análisis ameritan tanto el uso de herramientas de medición como de métodos y procesamientos de datos robustos para tener mayores alcances. Este estudio proporciona una comprensión más profunda de las relaciones entre las ETT, los MDM y factores de resiliencia en jóvenes del Valle de Aburrá, con implicaciones importantes para la promoción y prevención en este contexto particular, en especial en contextos escolares y familiares donde se desenvuelve la vida de los menores.

Código de R

En el procedimiento inicialmente se toman las variables observadas para la evaluación del modelo de medida, es decir, cada una de las variables latentes se constituye con información datos observados en los indicadores de los instrumentos empleados para la medición. En este caso todos los modelos son reflectivos.

```
library(seminr)
```

```
## Warning: package 'seminr' was built under R version 4.3.2
```

```
datas<- read.csv("Data.csv")
simple_mm<-constructs(
  composite("ETT",multi_items("V",9:16),weights = mode_A),
  composite("MDM",multi_items("V",19:26),weights = mode_A),
  composite("ARE",multi_items("V",35:36)),
  composite("TP",multi_items("V",28:33)),
  composite("SP",multi_items("V",38:40)),
  composite("PSS",multi_items("V",42:44)))
```

Teniendo la constitución y la evaluación del modelo de medida, se construye el modelo interno, dado a partir de las relaciones que se establecen entre las variables latentes a partir de coeficientes de vías:

```
simple_sm<-relationships(
  paths(from="ETT", to="MDM"),
  paths(from="ETT", to="ARE"),
  paths(from=c("ARE","TP"), to="MDM"),
  paths(from="SP", to="MDM"),
  paths(from="PSS", to="MDM"))
```

Con esto se tienen análisis del modelo en conjunto para su análisis, para lo cual se estima el modelo de ecuaciones estructurales con mínimos cuadrados parciales de la siguiente manera:

```
simple_model=estimate_pls(data=datas,
                          measurement_model=simple_mm,
                          structural_model=simple_sm,
                          missing=mean_replacement,
                          missing_value="-99")
```

```
## Generating the seminr model
```

```
## All 107 observations are valid.
```

Referencias

Bandura, Albert. 1991. "Social cognitive theory of moral thought and action.".

Bandura, Albert. 1995. *Self-efficacy in Changing Societies*. Cambridge University Press.

Bandura, Albert, Claudio Barbaranelli, Gian Vittorio Caprara and Concetta Pastorelli. 1996. "Mechanisms of Moral Disengagement in the Exercise of Moral Agency.".

Caprara, Gian Vittorio, Laura Di Giunta, Nancy Eisenberg, Maria Gerbino, Concetta Pastorelli and Carlo Tramontano. 2008. "Assessing Regulatory Emotional Self-Efficacy in Three Countries." *Psychological Assessment* 20:227–237.

Caprara, Gian Vittorio, Patrizia Steca, Arnaldo Zelli and Cristina Capanna. 2005. "A new scale for measuring adults' prosocialness." *European Journal of Psychological Assessment* 21:77–89.

Centro Nacional de Memoria Histórica. 2017. *Medellín: memorias de una guerra urbana*. Bogotá: .
URL: *http://www.centrodememoriahistorica.gov.co/informes/informes-2017/medellin-memorias-de-una-guerra-urbana*

Gómez-Tabares, Anyerson S, César Nuñez, Andrés M Grisales-Aguirre, Gastón Zapata-Lesmes and Olber E Arango-Tobón. 2023. "Confirmatory Factor Analysis and Factorial Invariance of the Mechanisms of the Moral Disengagement Scale." *Anuario de Psicologia Juridica* .

Hair Jr, Joseph F, G. Tomas Hult, Christian M. Ringle and Marko Sarsteadt. 2017. *A primer on Partial Least Squares Structural Equation Modeling (PLS-SEM)*. Second edition ed. Sage.

Hair Jr, Joseph F, G Tomas M Hult, Christian M Ringle, Marko Sarstedt, Nicholas P Danks and Soumya Ray. 2021. *Partial least squares structural equation modeling (PLS-SEM) using R: A workbook*. Springer Nature.

ICBF. 2021. "Observatorio del Bienestar de la Niñez.".

INPEC. 2021. "Tableros estadísticos INPEC.".
URL: *https://www.inpec.gov.co/estadisticas-/tableros-estadisticos*

OMS, [Organización Mundial de la Salud]. 2002. *Informe mundial sobre la violencia y la salud*. World Health Organization.

Pedrero-Perez, Eduardo J, Jose M Ruiz-Sanchez de Leon, Sara Morales-Alonso, Jara Pedrero-Aguilar and Laura M Fernandez-Mendez. 2015. "Prefrontal clinical symptoms in daily living: screening assessment by means of the short Prefrontal Symptoms Inventory (PSI-20)." *Revista de Neurologia* 60(9):385–393.

Policía-Nacional. 2021. "Estadística Delictiva.".
URL: *https://www.policia.gov.co/grupo-informacion-criminalidad/estadistica-delictiva*

Posada, Sara. 2020. *Inventario de experiencias traumáticas en la infancia (ETI-SRCol), versión colombiana: manual de aplicación y calificación*. Primera ed ed. Sello Editorial T Tecnológico de Antioquia Institución Universitaria.

Posada, Sara, Nora Helena Londoño and Ana M. Gaviria. 2019. "Propiedades psicométricas de la adaptación para Colombia del inventario de experiencias traumáticas en la infancia (ETI-SRCol)." *Medicina UPB* 38:33–45.

R Core Team. 2019. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing.
URL: *https://www.R-project.org/*

Sánchez Gómez, Gonzalo, Myriam Hernández Sabogal, Myriam Hernández Sabogal Catalina Riveros Gómez Mónica Johanna Rueda Yamile Salinas Abdala Juan Manuel Zarama Santacruz, Andrés Mauricio Mendoza Freddy Ricardo Saavedra Medina, Paola Rojas, Presidenta Tatyana Orozco de la Cruz, Mariana Garcés Córdoba Ministra de Cultura and Yesid Reyes Alvarado. 2015. *Una nación desplazada: Informe nacional del desplazamiento forzado en Colombia*. Bogotá: .

Velazquez, Jorge A Villatoro, Melanie M Domenech Rodríguez, María Elena Medina-Mora and Clara Fleiz. 1997. "Percepción de la inseguridad social y su relación con el uso de drogas." *Revista Mexicana de Psicología* 14(2):105–112.

Procesamiento y analisis de datos de resistencia antimicrobiana de WHONET con R *

Jorge Mario Estrada Alvarez MSc. *Salud Comfamiliar - Comfamiliar Risaralda*
Hernan Felipe Garcia Arias MSc. PhD *Universidad de Antioquia - Facultad de Ingenieria*
Maryluz Hincapie Acuña MSc. *Fundacion Universitaria UNIMINUTO*

Resumen: La resistencia antimicrobiana (RAM) es un problema de salud pública, agravado por el uso inadecuado de antimicrobianos. En Colombia, la RAM es un evento de interés en salud pública, vigilado por el Instituto Nacional de Salud. Aunque se recolectan datos mediante el aplicativo WHONET, su procesamiento es limitado, dificultando la obtención de perfiles de resistencia. En 2022, se publicó la librería AMR de R para facilitar el tratamiento de datos extraídos de WHONET. Se implementó un flujo de trabajo en R utilizando las librerías tidyverse, lubridate y AMR para procesar datos de susceptibilidad antimicrobiana en Pereira. Se consolidó un conjunto de datos y se desarrolló código para estandarizar variables esenciales. La librería AMR abordó desafíos como la estandarización de nombres de microorganismos y la asignación de clasificaciones de puntos de corte para resistencia. Permitió una estandarización efectiva y facilitó la clasificación de resistencia/sensibilidad según guías como CLSI y EUCAST. Conclusión. la librería AMR de R proporciona una solución efectiva y amigable para el procesamiento de datos de resistencia antimicrobiana, superando las limitaciones de WHONET.

Keywords: Resistencia antimicrobiana, R software, Vigilancia en salud pública

Introducción

La resistencia antimicrobiana (RAM), es el mecanismo mediante el cual microorganismos puede disminuir la acción de los agentes antimicrobianos Fernández. et al. (2003). El desarrollo de la resistencia bacteriana tiene diferentes causantes, algunos de ellos plenamente identificados como: el uso inadecuado de antimicrobianos entre la población humana, el uso masivo de antibiótico en animales como "*promotores del crecimiento*" y "*agentes preventivos de la enfermedad*"; todo ello ha llevado a la selección de bacterias resistentes en los animales que llegan al ser humano a través de la cadena alimenticia World Health Organization (2021).

La Resistencia antimicrobiana constituye un problema de salud publica, el cual se ha estimado su aumento como efecto colateral por la pandemia de SARS-Cov-2, especialmente por aumento en el uso de antibióticos como estrategia para contrarrestar a nivel individual la COVID-19. Es por tal motivo que el enfoque "Una sola Salud" (One Health) difundida por la OMS (Organización Mundial de la Salud (OMS), intenta abordar el problema desde una perspectiva holistica y conjunta entre la salud humana y animal en la cual se debe co-existir equilibradamente, es esencial para informar políticas e intervenciones.

En Colombia la resistencia antimicrobiana es catalogada como un evento de interés en salud pública, por tanto el Instituto Nacional de Salud emite lineamientos sobre la vigilancia de la misma Instituto Nacional de Salud (2022), la cual esta definida como una vigilancia por laboratorio que se

*Jorge Mario Estrada Alvarez: jestradaa@comfamiliar.com

operacionaliza mediante la recolección sistemática de resultados de pruebas de sensibilidad a microorganismos aislados en individuos consultantes a distintos servicios o áreas de las instituciones de salud del país.

El mecanismo de recolección de datos se realiza mediante el aplicativo de la OMS denominado WHONET, que tiene parametrizados algunos campos en la recolección de datos. Sin embargo el procesamiento de la información con fines de reportes y analítica dentro del software WHONET es limitado; la extracción de datos con otros fines analíticos, aunque es fácil, los datos no se obtienen con la suficiente estandarización, sobre todo en variables contundentes como lo es, el tipo de microorganismo y la clasificación de la resistencia según guias actuales, lo que dificulta aun mas la obtención de perfiles de resistencia, la eliminación de duplicados o aislamientos de un mismo paciente sobre distintas muestras y mismo microorganismo.

En 2022 fue publicado por Berends y cols. la librería `AMR` de R Berends et al. (2022) que facilita el tratamiento de datos extraídos de WHONET, con funciones que facilitan el pre procesamiento de datos, depuración y estandarización de variables para análisis y el anclaje a reportes automatizados de datos disponibles de manera mas rápida y consecuente con la toma de decisiones.

Este trabajo tuvo como objetivo implementar un flujo de trabajo para el tratamiento de datos de resistencia de WHONET, bajo el uso de la librería `AMR` en el pre-procesamiento, procesamiento y análisis de datos de la vigilancia de resistencia antimicrobiana.

Materiales y metodos

Se realizo una implementación en R usando la librerias `tidyverse`, `lubridate` y en `AMR` para el procesamiento de datos sobre resultados de pruebas de susceptibilidad antimicrobiana en cultivos procesados en laboratorios clínicos de la Ciudad de Pereira.

La información fue aportada por la Secretaria de Salud y Seguridad Social de Pereira como parte del sistema de vigilancia en salud publica en el evento resistencia bacteriana, para ello se recolectan mensualmente los datos del aplicativo WHONET de cada institución de salud esto permite una definición de la epidemiología local en microorganismos circulantes y/o causantes de infecciones o colonizaciones en pacientes hospitalizados y ambulatorios, ademas de ser insumo primordial para la vigilancia de patrones de resistencia existentes o emergentes.

Se consolido un dataset de 87978 muestras para la implemantación y de desarrollo código principalmente para la estandarización de variables primordiales en el análisis, como lo fue: nombre de microorganismo aislado, normalización de nombre de antimicrobianos según la ATC (Clasificación de Antibióticos) y la clasificación de puntos de corte para resistencia o sensibilidad en la combinación de microorganismo aislado versus antibiótico evaluado.

Resultados

El principal desafió del procesamiento de información sobre resistencia antimicrobioana extraída de WHONET se encontraba en nombres de microorganismos, análisis de datos de MIC (concentración inhibitoria minima) y la clasificación de Resistencia/Sensible de cada microorganismos combinado con el antibiótico deseado.

La implementación del uso de la librería `AMR` permitió:

1. **Estandarizacion de nombre de microorganimos** Los datos de la aplicación WHONET no tiene estandarizado el registro de microorganimos aislados en cada muestra, por tal motivo se puede encontrar variaciones en los nombres asignados a un mismo microorganimos

o abreviaturas no estandarizadas que no permiten una clara identificación, como: `stran`, `strang`, `e.coli`, `esccol`, `eco`. Lo que mediante dos funciones `as.mo()` permite la estandarización y la función `mo_name()` que asigna nombre científico completo. Tambien se pueden tener otras funciones que facilitan aun mas el manejo de este datos en el análisis, como lo es la clasificación por especie, familia, dominio entre otras.

```
library(AMR)
library(tidyverse)
as.mo("eco")
```

```
  Class 'mo'
  [1] B_ESCHR_COLI
```

```
mo_name(as.mo("eco"))
```

```
  [1] "Escherichia coli"
```

```
as.mo("esccol")
```

```
  Class 'mo'
  [1] B_ESCHR_COLI
```

```
mo_name(as.mo("esccol"))
```

```
  [1] "Escherichia coli"
```

2. **Manejo y asiganción de clasificación de punto de corte**

El dato relacionado al punto de corte de concentración inhibitoria minima de un antibiótico sobre un microorganismo incluye una valor logico (<= <) lo que al exportarse dicho campo no es asumido ser numérico y no permitía su manejo estadístico. Con la función `as.sir()` dicho simbolo lógico es conservado y no interfiere con su manejo estadístico:

```
mic <- as.mic(c("<=0.25","<=0.5","<=6"))
summary(mic)
```

```
     Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
    0.250   0.375   0.500   2.250   3.250   6.000
```

3. **Clasificación de Resistencia/Sensible para microorganismo y antibiótico**

Se obtienen clasificación de puntos de corte para microorganismo y antibiótico deseado, segun distintas guías como la CLSI 2020-2022 (americana) y EUCAST (europea). Lo anterior permite rápidamente obtener resultados consolidados y visualización gráfica mas rapida.

```
sir <- as.sir(mic,mo = as.mo("esccol"), ab = "MER" , guideline = "CLSI2021")
```

```
   Run sir_interpretation_history() afterwards to retrieve a logbook with
    all the details of the breakpoint interpretations. Note that some
    microorganisms might not have breakpoints for each antimicrobial drug in
    CLSI 2021.

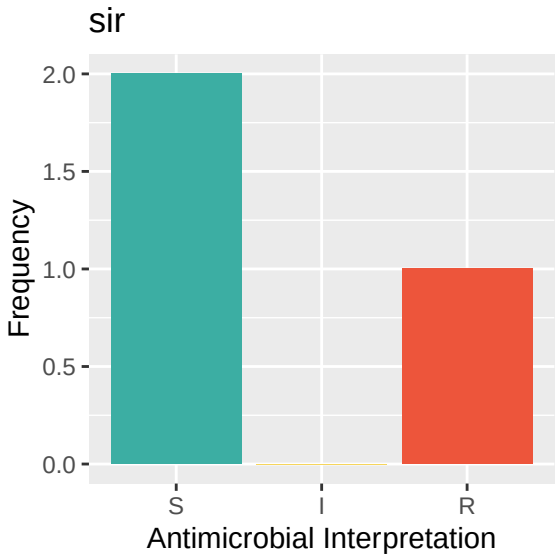
  Interpreting MIC values: 'MER' (MEM, meropenem), CLSI 2021... OK
```

```
sir
```

```
  Class 'sir'
  [1] S S R
```

y su visualizacion se hace inmediata sin mayor especificacion de parametos:

```
autoplot(sir)
```



Conclusión

Este trabajo se ve enfocado en el uso de la librería `AMR` de R, el cual permite de una manera amigable y fácil el procesamiento de dicha información manteniendo la estructura tidy del dataframe utilizado, situación que no era factible bajo la aplicación de escritorio WHONET, ademas que no permitia la posible complementación con datos clínicos de los individuos, provenientes de otras fuentes externas (Registro clínico electrónico).

Los equipos de comités de infección hospitalaria, vigilancia en salud publica de entidades territoriales tienen a disponibilidad una herramienta versátil y ajustada a las necesidades de organización de los datos para acelerar el proceso de analítica y potenciar las visualización y uso de metodos avanzados para la toma de decisiones.

References

Berends, Matthijs S., Christian F. Luz, Alexander W. Friedrich, Bhanu N. M. Sinha, Casper J. Albers and Corinna Glasner. 2022. "AMR: An R Package for Working with Antimicrobial Resistance Data." *Journal of Statistical Software* 104(3):1–31.

Fernández., Fernando, Jorge López, Laida María Ponce and Caridad Machado. 2003. "Resistencia bacteriana." *Rev Cubana Med Milit* 32:44–52.

Instituto Nacional de Salud. 2022. "Protocolo de vigilancia de resistencia bacteriana a los antimicrobianos en al ámbito hospitalario." pp. 1–27.
URL: *https://www.ins.gov.co/buscador-eventos/SitePages/Evento.aspx?Event=70*

World Health Organization. 2021. "Global Antimicrobial Resistance and Use Surveillance System (GLASS) Report.".

Predicción inteligente de diabetes mellitus tipo 2 usando R y mapas cognitivos difusos *

Kenia Hoyos *Clínica Salud Social, Sincelejo, Colombia*
Rander Ruíz *Universidad de Antioquia, Caucasia, Colombia*
William Hoyos *Universidad Cooperativa de Colombia, Montería, Colombia*

Resumen: El diagnóstico tardío de la diabetes mellitus tipo 2 (DM2) conlleva al aumento de las tasas de morbilidad y mortalidad a nivel mundial. El uso de herramientas computacionales para la predicción de DM2 podría acelerar el diagnóstico. Por tanto, el objetivo de la presente investigación fue desarrollar un modelo de predicción de DM2 basado en un mapa cognitivo difuso (MCD) implementado en R. El MCD puede predecir la DM2 con un 99% de exactitud, 100% de sensibilidad y 98% de especificidad y un indice Kappa de 0.98. Los resultados demuestran la capacidad del modelo para predecir y evaluar el comportamiento de las variables de interés en la DM2.

Keywords: diabetes mellitus tipo 2, mapa cognitivo difuso, diagnóstico, predicción

Introducción

En los últimos años, la diabetes ha incrementado su prevalencia convirtiéndose en un problema de salud pública a nivel global (World Health Organization, 2023). Se calcula que en 2021 había 537 millones de personas con diabetes en el mundo y se produjeron 6,7 millones de muertes (International Diabetes Federation, 2021). Más del 95% de la población con diabetes corresponde al tipo 2 y un diagnóstico tardío puede generar complicaciones que llevan a la muerte (World Health Organization, 2023). Para abordar esta problemática se han desarrollado estudios de predicción de diabetes, empleando técnicas de aprendizaje automático implementadas en R, como árboles de decisión Kalange et al. (2022) y Naive Bayes Marathe, Gawade and Kanekar (2021). Estos modelos obtuvieron una buena exactitud, sin embargo, no evaluaron el comportamiento de las variables. Por lo tanto, nuestro objetivo fue desarrollar un modelo de predicción inteligente de DM2 basado en MCD implementado en R que permite analizar la evolución de las variables usando gráficas de iteraciones simuladas. La siguiente sección describe la metodología empleada, luego se presentan los resultados y la ultima sección concluye el artículo.

Metodología

Utilizamos la base de datos de DM2 del Instituto Nacional de Diabetes y Enfermedades Digestivas y Renales de la India (PIMA) (Smith et al., 1988). La información corresponde a 768 pacientes (500 sin DM2 y 268 con DM2) y 9 variables (ver Tabla 1). Aplicamos la técnica SMOTE (Chawla et al., 2002) para balancear las clases. Para el entrenamiento y validación del modelo empleamos el 70% de los datos y el 30% restante, se utilizó para las pruebas de rendimiento. Construimos un MCD, el cual está compuesto por nodos que representan conceptos y flechas que representan las

*Autor de contacto: william.hoyos@campusucc.edu.co.

influencias o relaciones entre ellos (Kosko, 1986). Para encontrar las relaciones entre los conceptos usamos un algoritmo genético. Posteriormente, realizamos un proceso de inferencia usando el paquete de R (R Core Team, 2019) llamado *fcm* (Dikopoulou and Papageorgiou, 2017). El mejor modelo estaba conformado por los siguientes hiperparámetros, para algoritmo genético: *población inicial* = 200, *probabilidad de cruce* = 0.5, *probabilidad de mutación* = 0.5; para el MCD, *función de activación* = *sigmoidea*, *función de inferencia* = *rescaled*. Finalmente, el modelo seleccionado se aplicó al conjunto de datos de prueba (30%) para evaluar su desempeño. La figura 1 muestra el código principal de R para la predicción de DM2 y evaluación de variables involucradas. Después de importar las librerías necesarias, se carga la matriz de pesos del modelo y el conjunto de datos de prueba (30%) como se muestra en la sección A de la figura 1. El desempeño predictivo del modelo fue evaluado a través de métricas como exactitud, sensibilidad, especificidad y el índice de Kappa como se muestra en la sección B de la figura 1. Por último, realizamos iteraciones simuladas usando el paquete *ggplot2* (Wickham, 2016) para visualizar el comportamiento de las variables involucradas en la predicción. La sección C de la figura 1 muestra el código para generar esta gráfica.

Tabla 1: Variables incluidas en el conjunto de datos PIMA

Concepto	Nombre de la variable
C1	Número de embarazos
C2	Glucosa plasmática
C3	Presión sanguínea diastólica
C4	Espesor del pliegue cutáneo del tríceps
C5	Insulina sérica
C6	Índice de Masa Corporal (IMC)
C7	Función del pedigrí de diabetes
C8	Edad
C9	Diagnóstico

Resultados

El modelo obtuvo una exactitud del 99%, sensibilidad del 100% y especificidad del 98% en la predicción de DM2. Con relación al grado de concordancia entre la predicción de nuestro modelo y el diagnóstico real, se obtuvo un índice Kappa de Cohen de 0,98, un valor casi perfecto según Landis and Koch (1977) que indica que la fiabilidad del modelo es alta. Con respecto al comportamiento de las variables, la figura 2 muestra la simulación de un caso con antecedentes de embarazo, presión diastólica e IMC alterado. Conceptos como la concentración de glucosa, niveles de insulina sérica y espesor del pliegue cutáneo del tríceps, que no estaban activos inicialmente, posteriormente se activan y aparecen como curvas que incrementan sus valores a través de las iteraciones. De esta manera, estos resultados representados en forma gráfica le permiten al profesional médico realizar un análisis mas completo de la DM2 para cualquier paciente.

A

```r
#Leemos la base de datos de prueba
pima_test_dataset <- read.arff("diabetes_test_dataset.arff")

#Creamos un data frame con una fila de ceros (0) para rellenar el dataframe
inference_results <- data.frame(matrix(ncol = 9, nrow = 0))
#Le colocamos nombres a las columnas
names(inference_results) <- names(pima_test_dataset)

#Convertimos todas las columnas a tipo numerico
#pima_test_dataset_2 <- pima_test_dataset %>% mutate_if(is.factor, as.numeric)

#Convertimos las categorías de la clase
#pima_test_dataset_2$class <- ifelse(pima_test_dataset_2$class == 2,1,0)

for(i in 1:nrow(pima_test_dataset)){
        cat("Paciente: ", i)
        results <- fcm_infer(activation_vec = pima_test_dataset[i,],
                             weight_mat = adj_matrix,
                             infer = "rc",
                             transform = "s",
                             iter = 200)
        inference_results <- rbind(inference_results, results$values[results$iter_convergencia,
})
```

B

```r
#Extraemos las predicciones de inference_results
predicciones <- inference_results[,"c9"]
predicciones_2 <- ifelse(predicciones <= 0.5, 0, 1)

#Agregamos el vector de predicciones al dataframe de pacientes
resultados_finales <- data.frame(pima_test_dataset$c9, predicciones_2)
names(resultados_finales) <- c("Diagnostico", "Predicción")

#Sacamos la matriz de confusión
(matriz_confusion <- table(resultados_finales$Diagnostico,
resultados_finales$Predicción))
#Calculamos la exactitud
accuracy = 0
for (i in 1:nrow(matriz_confusion)){
        accuracy = accuracy + matriz_confusion[i, i] / sum(matriz_confusion)
}

#Calculamos la exactitud, sensibilidad, especificidad y el indice Kappa
cat("La exactitud del modelo es: ", accuracy * 100, "%")
cat("La sensibilidad del modelo es: ", sensitivity(matriz_confusion) * 100, "%")
cat("La especificidad del modelo es: ", specificity(matriz_confusion) * 100, "%")
Kappa.test(matriz_confusion)
```

C

```r
#Creamos un vector inicial que simula ser un paciente
initial_vector <- c(0,1,0,0,0,0,0,0,0)

#Realizamos la inferencia
results <- fcm_infer(activation_vec = initial_vector,
                     weight_mat = adj_matrix,
                     infer = "mk",
                     transform = "s",
                     iter = 10,
                     lambda = 1,
                     e = 0.001)

#Extraemos los resultados de las predicciones
resultados <- results$values[1:results$iter_convergencia,]

# Crea un vector llamado iteraciones
iterations <- as.numeric(rownames(results$values))
# Añadimos el vector de iteraciones al marco de datos df
df <- data.frame(iterations, results$values)
#Transforma el marco de datos df en formato largo
df2 <- melt(df, id="iterations")

#Creamos el grafico usando ggplot
ggplot(data = df2,
       aes(x = iterations, y = value, group = variable,
           colour = variable)) +
        theme_bw() +
        geom_line(size = 0.5) +
        geom_point(size = 2) +
  geom_vline(xintercept = 9, color = "black",
             linetype = "dashed", size = 1) +
        labs(x = "Iteraciones", y = "Valor del concepto",
             colour = "Conceptos") +
        theme(legend.position="bottom",
              legend.title = element_text(size = 15, face =
"bold"),      legend.text = element_text(size = 15),
              axis.title=element_text(size = 15, face = "bold"),
              axis.text = element_text(size = 15)) +
  scale_x_continuous(breaks = seq(0, 10, by = 1))
```

Figura 1: Código usado para la predicción de DM2 y evaluación de comportamiento de variables. A representa la carga de datos y el proceso de inferencia, B representa la evaluación del modelo usando metricas de desempeño y C representa el código para la generación de la gráfica que muestra el comportamiento de las variables predictoras.

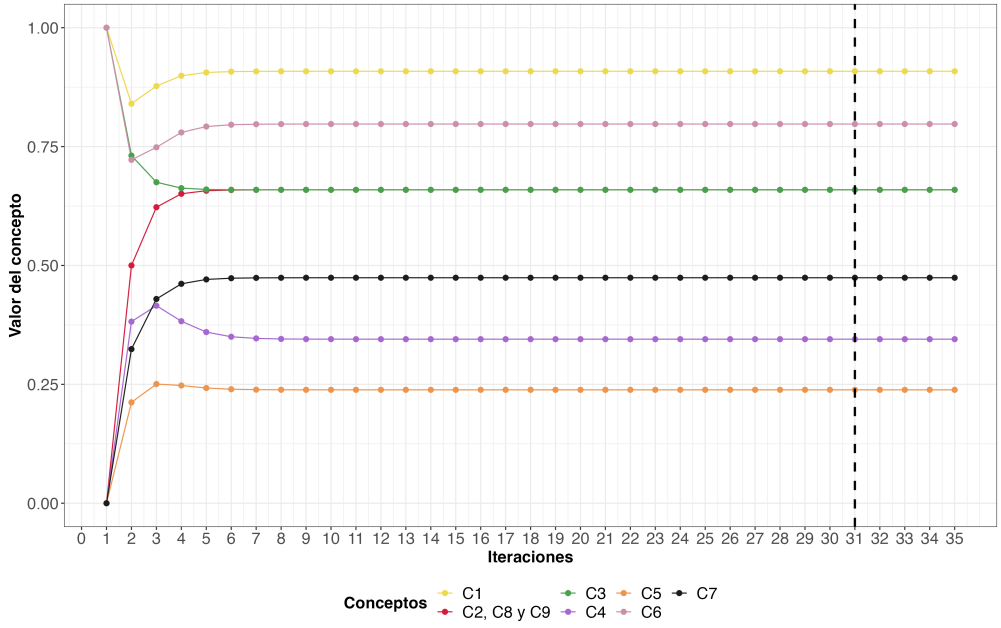


Figura 2: Representación gráfica del comportamiento de las variables predictoras de DM2

Conclusión

En este estudio, hemos propuesto un modelo de predicción inteligente de DM2 basado en MCD implementado en R. Los resultados demuestran el potencial de los MCD para la predicción de la DM2 con un excelente desempeño. Además de la predicción, el modelo permite el análisis del comportamiento de las variables predictoras. La presente investigación se podría ampliar mediante el uso de otras variables de importancia en el diagnóstico de la enfermedad e involucrando expertos que asignen y evalúen las relaciones entre los conceptos del MCD.

Referencias

Chawla, N. V., K. W. Bowyer, L. O. Hall and W. P. Kegelmeyer. 2002. "SMOTE: Synthetic Minority Over-sampling Technique." 16:321–357.
URL: *https://doi.org/10.1613/jair.953*

Dikopoulou, Zoumpoulia and Elpiniki Papageorgiou. 2017. *fcm: Inference of Fuzzy Cognitive Maps (FCMs)*. R package version 0.1.3.
URL: *https://CRAN.R-project.org/package=fcm*

International Diabetes Federation. 2021. *IDF Diabetes Atlas 10th edition*. Vol. 10 of *Diabetes Research and Clinical Practice*.
URL: *https://diabetesatlas.org/idfawp/resource-files/2021/07/IDF_Atlas_10th_Edition_2021.pdf*

Kalange, Omkar, Tejaswini Katale, Atharv Kale and Juwairia Sayyed. 2022. "Prediction of Diabetes using R." 4(12).
URL: *https://doi.org/10.35629/5252-0412885890*

Kosko, Bart. 1986. "Fuzzy cognitive maps." 24(1):65–75.
URL: *https://doi.org/10.1016/S0020-7373(86)80040-2*

Landis, J. R. and G. G. Koch. 1977. "The measurement of observer agreement for categorical data." 33(1):159–174.
URL: *https://pubmed-ncbi-nlm-nih-gov.udea.lookproxy.com/843571/*

Marathe, Ninad, Sushopti Gawade and Adarsh Kanekar. 2021. "Prediction of Heart Disease and Diabetes Using Naive Bayes Algorithm." pp. 447–453.
URL: *https://doi.org/10.32628/CSEIT217399*

R Core Team. 2019. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing.
URL: *https://www.R-project.org/*

Smith, Jack W, JE Everhart, WC Dicksont, WC Knowler and RS Johannes. 1988. "Using the ADAP Learning Algorithm to Forecast the Onset of Diabetes Mellitus." pp. 261–265.
URL: *https://www-ncbi-nlm-nih-gov.udea.lookproxy.com/pmc/articles/PMC2245318/*

Wickham, Hadley. 2016. *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York.
URL: *https://ggplot2.tidyverse.org*

World Health Organization. 2023. "Diabetes.".
URL: *https://www.who.int/news-room/fact-sheets/detail/diabetes*

Uso de R para el análisis y creación de informes de secuenciación de exomas en pacientes con asfixia perinatal *

Diego Mauricio Gómez Londoño *Comfamiliar Risaralda, Universidad de Manizales*
Hernán Felipe García Árias *Comfamiliar Risaralda*
Natalia Trujillo Árias *Comfamiliar Risaralda*
Jorge Mario Estrada Álvarez *Comfamiliar Risaralda*
Natalia Cardona Ramirez *Comfamiliar Risaralda*
Juan Alejandro Trujillo Posada *Universidad de Manizales*
Gloria-Liliana Porras Hurtado *Comfamiliar Risaralda*

Resumen: El análisis de secuenciación de exomas en pacientes con asfixia perinatal requiere herramientas eficientes. Presentamos una solución basada en R, un lenguaje de programación libre y ampliamente utilizado en ciencia de datos. RStudio, un entorno de desarrollo integrado para R, facilita la creación de scripts y la integración con herramientas como Quarto o Markdown para generar documentos dinámicos y reproducibles. Aplicamos filtros y realizamos búsquedas específicas de genes relacionados con el fenotipo de la enfermedad de cada paciente sobre los archivos provenientes del análisis de exomas para seleccionar variantes relevantes y generamos informes individuales para pacientes. El uso de R ofrece ventajas como alta calidad, accesibilidad gratuita, automatización, personalización y capacidad de generar documentos profesionales. Este trabajo demuestra el potencial de R en bioinformática para la investigación en genómica médica y la presentación de los resultados.

Keywords: Análisis de datos, Bioinformática, Secuenciación de exomas completos, r markdown,

Introducción

La secuenciación de exomas completos se ha convertido en un enfoque crucial para desentrañar los misterios genéticos detrás de condiciones médicas cruciales, como la asfixia perinatal. Este desafío bioinformático, derivado de la insuficiencia de oxígeno durante el parto, plantea interrogantes genéticos esenciales que requieren atención especializada (Carlson and Vora, 2017).

A pesar de la creciente importancia de la secuenciación de exomas en medicina, la información genética específica sobre la asfixia perinatal ha sido elusiva, obstaculizando la identificación precisa de variantes genéticas asociadas. Esta brecha en el conocimiento limita el desarrollo de intervenciones personalizadas (Gorovenko et al., 2010).

Ante esta necesidad crítica, se requieren herramientas eficientes y flexibles para abordar la vasta cantidad de datos generados por la secuenciación de exomas. R, un lenguaje de programación de código abierto, destaca como la elección natural. Su capacidad para manejar grandes conjuntos de datos, realizar análisis estadísticos avanzados y generar informes automatizados lo posiciona como la herramienta ideal para enfrentar el desafío de la secuenciación de exomas en pacientes con asfixia perinatal.

Este proyecto no solo busca llenar el vacío de información genética en la asfixia perinatal mediante la secuenciación de exomas completos, sino también resaltar la eficacia de R en el manejo

*Autor de contacto: diegomez@comfamiliar.com

de grandes volúmenes de datos genómicos. Utilizando RMarkdown para la generación y automatización de informes, el objetivo es identificar variantes genéticas asociadas a la asfixia perinatal y presentar un modelo replicable para futuras investigaciones en genómica médica. En última instancia, este estudio aspira a demostrar que, frente a la complejidad de la información genética, R es la herramienta idónea para avanzar hacia una comprensión más profunda de las bases genéticas de la asfixia perinatal.

Metodología

El desarrollo de una solución integral para abordar el análisis de secuenciación de exomas en pacientes con asfixia perinatal implicó la cuidadosa implementación de un flujo bioinformático respaldado por herramientas avanzadas. La elección central de R, un lenguaje de programación versátil y consolidado en la ciencia de datos, fue fundamental para garantizar la eficacia y reproducibilidad del análisis. El Análisis de las datos se realizó principalmete mediante filtros y búsquedas de genes relacionados con el fenotipo clínico de cada paciente. Se utilizó RMarkdown para la generación y de los documentos de reporte de cada paciente. Se utilizó el software R 4.3.1 sobre una estación de trabajo con Ubuntu 22.04 debido a la necesidad de ejecutar el flujo bioinformático en sistemas basados en Linux, optimizando así la compatibilidad y eficiencia del análisis.

El desarrollo de este trabajo se encuentra bajo el proyecto de investigación "Sistema de monitoreo Automático para la evaluación clínica de infantes con lateraciones neurológicas motoras mediante el análisis de volumetría cerebral y pratron de la marcha" que es financiado por el Ministrio de Ciencia, Tecnología y Educación. Adicionalmente, el proyecto se encuentra avalado por el comité de étcia de Comfamiliar Risaralda y se cuenta con consentimiento informado de los pacientes.

Resultados

Proceso de Análisis de Datos

La ejecución de scripts en R ha simplificado el procesamiento de datos complejos de la secuenciación de exomas. La integración de funciones específicas ha permitido un filtrado preciso de variantes, considerando criterios como la frecuencia alélica, la localización en genes relevantes y la presencia en bases de datos de enfermedades genéticas. Este enfoque ha agilizado el análisis, reduciendo posibles errores y generando resultados más confiables (Figura 1).

hpo_366665	14309 obs. of 7 variables
ID_raw_vcf	2282091 obs. of 92 variables
resumen_hpo	7 obs. of 24 variables
resumen_patho	7 obs. of 21 variables
vcf_paciente	300320 obs. of 105 variables
vcf_paciente_1	127677 obs. of 105 variables
vcf_paciente_2	104395 obs. of 105 variables
vcf_paciente_3	615 obs. of 105 variables
vcf_paciente_hpo_1	615 obs. of 111 variables
vcf_paciente_hpo_2	7 obs. of 111 variables
vcf_paciente_patho	7 obs. of 105 variables

Figure 1: Dataframes creados con distintos filtros.

La aplicación de filtros fue esencial para seleccionar las variantes más relevantes. Criterios como la frecuencia alélica, la localización en genes neuromusculares o relacionados con el fenotipo clínico, y la presencia en bases de datos de enfermedades genéticas se implementaron mediante un Rscript. Este script genera un dataframe conciso (inicialmente 105 columnas, finalmente 21 o 24) como se presenta parcialmente en la figura 2 y un conjunto limitado de genes, facilitando la revisión y selección de variantes genéticas por parte de los médicos genetistas.

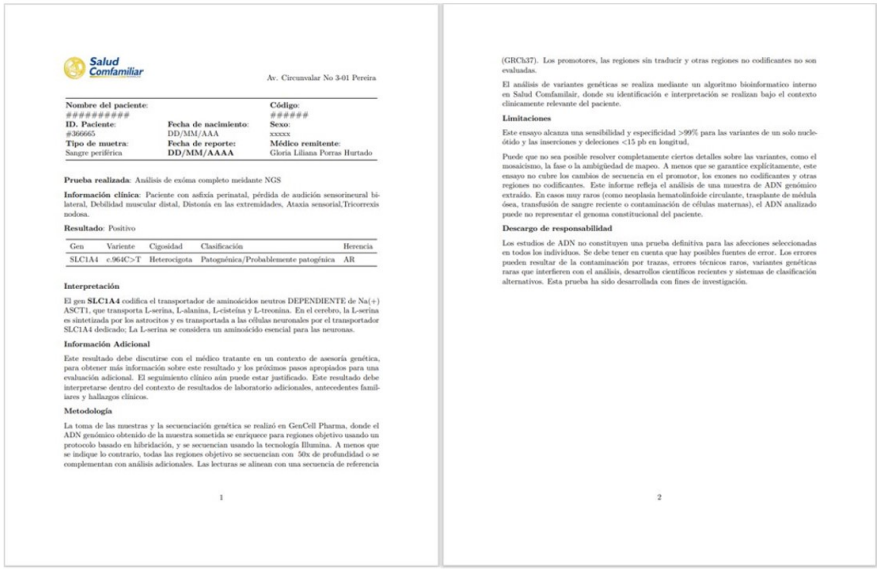
gene_name	nt_change	aa_change	effect	impact	CLNSIG	CLNDN
ITPKB	c.964G>A	p.Ala322Thr	missense_variant	MODERATE	Pathogenic	Myeloproliferative_neoplasm,_unclassifiable
EHBP1	c.1290+30064G>A		intron_variant	MODIFIER	Pathogenic	Prostate_cancer,_hereditary,_12
SLC1A4	c.964C>T	p.Arg322*	stop_gained	HIGH	Pathogenic/Likely_pathogenic	Spastic_tetraplegia-thin_corpus_callosum-progressiv...
RStudio	c.86A>T	p.Asn29Ile	missense_variant	MODERATE	Pathogenic	Myoepithelial_tumor|Hereditary_pancreatitis|Trypsin...
CTBP2	c.2287G>A	p.Val763Met	missense_variant	MODERATE	Pathogenic	Pulmonary_artery_atresia
KLK2	c.748C>T	p.Arg250Trp	missense_variant	MODERATE	Pathogenic	Acute_myeloid_leukemia
CBS	c.833T>C	p.Ile278Thr	missense_variant	MODERATE	Pathogenic	Connective_tissue_disorder|Homocystinuria|not_pro...

Showing 1 to 7 of 7 entries, 21 total columns

Figure 2: Dataframe resumido con variantes genéticas de interés.

La generación de informes de análisis se realizó con RMarkdown, proporcionando documentos estructurados y detallados por paciente (figura 3). Estos informes incluyeron datos sobre el paciente, tipo de estudio, tabla con variantes reportadas o resultados positivos, información clínica respaldada en literatura relevante sobre las variantes, y detalles técnicos del proceso de secuenciación por un laboratorio externo. Este enfoque integrado aseguró presentar los resultados de manera clara y completa.

La principal ventaja de RMarkdown es la automatización del proceso de generación de informes. La integración de código R en el documento facilita la reproducción de resultados, asegurando coherencia entre hallazgos y presentación. RMarkdown permite la inclusión dinámica de gráficos, tablas y referencias bibliográficas, mejorando la calidad y eficacia en la comunicación de los resultados.


Salud Comfamiliar

Av. Circunvalar No 3-01 Pereira

Nombre del paciente: ##########
Código: ######
ID. Paciente: #366665
Fecha de nacimiento: DD/MM/AAA
Sexo: xxxxx
Tipo de muetra: Sangre periférica
Fecha de reporte: DD/MM/AAAA
Médico remitente: Gloria Liliana Porras Hurtado

Prueba realizada: Análisis de exóma completo meidante NGS

Información clínica: Paciente con asfixia perinatal, pérdida de audición sensorineural bilateral, Debilidad muscular distal, Distonía en las extremidades, Ataxia sensorial,Tricorrexis nodosa.

Resultado: Positivo

Gen	Variante	Cigosidad	Clasificación	Herencia
SLC1A4	c.964C>T	Heterocigota	Patogenómica/Probablemente patogénica	AR

Interpretación

El gen **SLC1A4** codifica el transportador de aminoácidos neutros DEPENDIENTE de Na(+) ASCT1, que transporta L-serina, L-alanina, L-cisteína y L-treonina. En el cerebro, la L-serina es sintetizada por los astrocitos y es transportada a las células neuronales por el transportador SLC1A4 dedicado; La L-serina se considera un aminoácido esencial para las neuronas.

Información Adicional

Este resultado debe discutirse con el médico tratante en un contexto de asesoría genética, para obtener más información sobre este resultado y los próximos pasos apropiados para una evaluación adicional. El seguimiento clínico aún puede estar justificado. Este resultado debe interpretarse dentro del contexto de resultados de laboratorio adicionales, antecedentes familiares y hallazgos clínicos.

Metodología

La toma de las muestras y la secuenciación genética se realizó en GenCell Pharma, donde el ADN genómico obtenido de la muestra sometida se enriquece para regiones objetivo usando un protocolo basado en hibridación, y se secuencian usando la tecnología Illumina. A menos que se indique lo contrario, todas las regiones objetivo se secuencian con 50x de profundidad o se complementan con análisis adicionales. Las lecturas se alinean con una secuencia de referencia

1

(GRCh37). Los promotores, las regiones sin traducir y otras regiones no codificantes no son evaluadas.

El análisis de variantes genéticas se realiza mediante un algoritmo bioinformatico interno en Salud Comfamiliar, donde su identificación e interpretación se realizan bajo el contexto clínicamente relevante del paciente.

Limitaciones

Este ensayo alcanza una sensibilidad y especificidad >99% para las variantes de un solo nucleótido y las inserciones y deleciones <15 pb en longitud.

Puede que no sea posible resolver completamente ciertos detalles sobre las variantes, como el mosaicismo, la fase o la ambigüedad de mapeo. A menos que se garantice explícitamente, este ensayo no cubre los cambios de secuencia en el promotor, los exones no codificantes y otras regiones no codificantes. Este informe refleja el análisis de una muestra de ADN genómico extraído. En casos muy raros (como neoplasia hematolinfoide circulante, trasplante de médula ósea, transfusión de sangre reciente o contaminación de células maternas), el ADN analizado puede no representar el genoma constitucional del paciente.

Descargo de responsabilidad

Los estudios de ADN no constituyen una prueba definitiva para las afecciones seleccionadas en todos los individuos. Se debe tener en cuenta que hay posibles fuentes de error. Los errores pueden resultar de la contaminación por trazas, errores técnicos raros, variantes genéticas raras que interfieren con el análisis, desarrollos científicos recientes y sistemas de clasificación alternativos. Esta prueba ha sido desarrollada con fines de investigación.

2

Figure 3: Documento de reporte para analisis genético.

Conclusión

La implementación exitosa de scripts en R y Markdown no solo ha mejorado la eficiencia y la precisión en el análisis de datos genómicos, sino que también ha establecido un modelo valioso para la generación de informes en el campo de la bioinformática y la genómica médica. Este enfoque no solo representa un avance en la investigación actual sobre la asfixia perinatal, sino que también sienta las bases para futuros proyectos que busquen integrar análisis de datos genómicos de manera eficaz y reproducible.

References

Carlson, Laura M and Neeta L Vora. 2017. "Prenatal diagnosis: screening and diagnostic tools." *Obstetrics and Gynecology Clinics* 44(2):245–256.

Gorovenko, NG, ZI Rossokha, SV Podolskaya, VI Pokhylko and Gunilla A Lundberg. 2010. "The role of genetic determinant in the development of severe perinatal asphyxia." *Cytology and genetics* 44(5):294–299.

Boletines Epidemiológicos con R *

Carlos Andrés Barco Rojas *Escuela Superior de Administración Pública - Territorial Caldas*
Jorge Mario Estrada Alvarez *Secretaria de Salud Pública y Seguridad Social de Pereira - Comfamiliar Risaralda*

El objetivo primordial de este estudio fue desarrollar un flujo de trabajo destinado a mejorar el procesamiento de datos en el ámbito de la vigilancia de salud pública. Para este propósito, se empleó el software R, con el fin de agilizar la recolección, análisis y presentación de datos epidemiológicos, permitiendo la generación automática de informes. El diseño metodológico abarcó la selección de conjuntos de datos procedentes del Sistema de Información en Salud Pública (SIVIGILA), que contenían información relativa a más de 116 eventos de interés en salud pública. Se aplicó un código de preprocesamiento de datos que excluyó casos inadecuados y duplicados, y se categorizaron los casos según la naturaleza de la enfermedad y su ubicación, ya sea en el lugar de infección o residencia. Los resultados se consolidaron en tablas con codificación de colores específica para una semana epidemiológica determinada. También se implementaron herramientas epidemiológicas, como los canales endémicos, para detectar comportamientos inusuales y brotes en la ciudad. Este flujo de trabajo en R Software conlleva una reducción sustancial en el tiempo dedicado al preprocesamiento de datos y acelera la producción de informes automatizados en el campo de la salud pública. Como resultado, los epidemiólogos pueden emplear herramientas de análisis avanzado y disponer de más tiempo para interpretar resultados y detectar patrones inusuales. La adopción de esta metodología tiene el potencial de mejorar la eficiencia en la vigilancia de salud pública y de facilitar la toma de decisiones basadas en información sólida.

Keywords: Vigilancia en salud pública , R Markdown, Tidyverse, Boletines epidemiológicos

Introducción

La Vigilancia en Salud Pública es un proceso sistemático y constante que involucra la recolección, análisis, interpretación y difusión de datos específicos relacionados con la salud Brookmeyer and Stroup (2003). Estos datos se utilizan en la planificación, ejecución y evaluación de prácticas en salud pública, convirtiéndola en un componente esencial para el monitoreo y control de enfermedades, así como para la toma de decisiones informadas en el ámbito de la salud.

En Colombia, el Instituto Nacional de Salud desempeña un papel central como entidad rectora en la vigilancia de eventos de interés en salud pública a través del Sistema de Información para la Vigilancia (SIVIGILA). Este sistema agiliza la notificación de enfermedades catalogadas como de interés en salud pública debido a su impacto y capacidad de generar brotes y epidemias que afectan la salud colectiva.

Dentro de la vigilancia en salud pública, se incluye un componente de divulgación de resultados, que se lleva a cabo principalmente a través de la emisión de publicaciones periódicas que informan sobre el comportamiento de los eventos notificados en el sistema. Esto se realiza mediante la aplicación de la triada analítica epidemiológica, denominada tiempo, lugar y persona. Este

*Autores de contacto: carlos.barco@esap.edu.co, jmario.estrada.alvarez@gmail.com

enfoque implica el uso de diversos métodos analíticos y representaciones gráficas para resumir, presentar y analizar los resultados obtenidos a través de la vigilancia.

La complejidad de estos reportes se debe a la diversidad de fuentes de información que pueden ser utilizadas para un mismo reporte, así como a las estructuras de datos diferentes, algunas a nivel individual (sujetos) y otras a nivel agregado. Esto implica el procesamiento de múltiples bases de datos con estructuras distintas para generar un solo reporte. Esta diversidad ha dificultado la práctica del análisis en salud pública en las diversas entidades territoriales de salud, como las Secretarías de Salud departamentales y municipales. Ha generado desafíos en la gestión de varios formatos de datos y ha ralentizado la producción de informes de vigilancia, así como la implementación de métodos estadísticos más sensibles pero también más complejos.

En este contexto, el uso de herramientas tecnológicas se ha vuelto fundamental para agilizar la recopilación, análisis y presentación de datos epidemiológicos Khan (2013). Hasta el momento, a nivel nacional, Microsoft Excel ha sido una herramienta destacada entre los equipos de vigilancia en salud pública, pero es propenso a errores y ofrece a los usuarios promedio una funcionalidad analítica limitada. Del mismo modo, el software de "apuntar y hacer clic", como Tableau y PowerBI, ofrece un aprendizaje rápido, pero limita las posibilidades de análisis personalizado Neale Batra et al. (2021).

R software, desarrollado por el equipo principal de R R Core Team (2019), es una de las herramientas más utilizadas y referenciadas en el campo de la ciencia de datos. Es la más empleada en la implementación de análisis de datos epidemiológicos. La diversidad de librerias disponibles facilita el pre-procesamiento, análisis y presentación de resultados, además de permitir la combinación de diversas fuentes y estructuras de datos en un solo lugar. Esto, junto con la reproducibilidad deseada y la automatización de reportes, supone una ventaja significativa para la vigilancia en salud pública al ahorro de tiempo y la rápida disponibilidad de resultados para los tomadores de decisiones.

El objetivo principal de este trabajo consistió en estructurar un flujo de trabajo que abarcase desde la entrada de datos de la vigilancia en salud pública, su consolidación, pre-procesamiento y la producción de un reporte estandarizado de boletín epidemiológico. Este informe contendría los resultados sobre el comportamiento en tiempo, lugar y persona de eventos de interés en salud pública.

Materiales y metodos

Se diseñó un flujo de trabajo en R software que se ejecuta de manera semanal y abarca las siguientes etapas: la selección de conjuntos de datos recopilados del Sistema de Información en Salud Pública, SIVIGILA. Estos conjuntos de datos se componen de dos tipos de estructuras. En primer lugar, múltiples datasets que contienen información a nivel de casos notificados por parte de las instituciones de salud, abarcando más de 116 eventos de interés en salud pública de notificación obligatoria. En segundo lugar, se encuentran datasets con casos agregados, correspondientes a lo que se conoce bajo los protocolos del Instituto Nacional de Salud como notificación colectiva. Esto se aplica principalmente a eventos como la infección respiratoria aguda y la infección diarreica aguda.

Posteriormente, se estructuró un código de pre-procesamiento de datos que sigue reglas de depuración preestablecidas. Estas reglas incluyen la eliminación de casos descartados, casos que no cumplen con los criterios del protocolo de notificación, la supresión de duplicados basada en el documento, la fecha de consulta y el evento. Además, de acuerdo a la naturaleza de la enfermedad, se realiza la selección de casos por municipio de procedencia y/o residencia. Para

eventos de tipo transmisible, el análisis se enfoca en el lugar de posible infección, mientras que para eventos no transmisibles, el análisis se basa en el lugar de residencia del afectado.

Por último, se elaboró un informe en R-Markdown con una plantilla de LaTeX que incluye la representación de datos en tablas, gráficos y la implementación de funciones para la aplicación de algoritmos de detección de comportamientos inusuales en series de tiempo, específicamente en relación a los conteos semanales de los eventos trazadores de interés en salud pública.

Se emplearon algunas funciones de R base y librerias de R para el preprocesamiento, como `Tidyverse` de Wickham et al. (2019), y `lubridate` Grolemund and Wickham (2011). Además, se utilizó la libreria `gtsummary` de Sjoberg et al. (2021) para la construcción de tablas de informe, y se emplearon funciones específicas para el análisis de datos epidemiológicos, como `incidence`, desarrollada por Kamvar et al. (2019).

Resultados

Se ha desarrollado un flujo de trabajo que reduce el procesamiento de datos y la producción de reportes a cuestión de minutos, logrando esto mediante la creación de un código estandarizado en la fase de preprocesamiento, como se muestra a continuación:

```
# Filtrado de casos D, R, 6
datos<-filter(datos2, ajuste_=="0" | ajuste_=="3" |
                ajuste_=="4" | ajuste_=="5" | ajuste_=="7")
#Filtardo de procedencia Pereira
proce<-filter(datos2, ndep_proce=="RISARALDA" & nmun_proce=="PEREIRA")
proce<-filter(proce, cod_eve=="580"|cod_eve=="210"|cod_eve=="220"|
                cod_eve=="217"|cod_eve=="895"|
                cod_eve=="465"|cod_eve=="420"|
                cod_eve=="430"|cod_eve=="440"|
                cod_eve=="205"|cod_eve=="310")
#Eliminado duplicados por identificación y fecha consulta
procedencia<-distinct(proce, num_ide_, cod_eve, fec_con_, .keep_all = TRUE)
```

con una visualización agradable y presentación estándar ver figura 1.

Se obtuvieron resultados consolidados en tablas con resaltados en color, de acuerdo a una parametrización de incremento para una semana epidemiológica específica. Además, se implementaron herramientas epidemiológicas, como los canales endémicos, que posibilitan la vigilancia de comportamientos inusuales y brotes a nivel de la ciudad ver figura 2.

Conclusión

Se ha desarrollado un flujo de trabajo utilizando R Software que combina diversas fuentes de información, así como múltiples estructuras de datos recopiladas de manera sistemática a partir de eventos de vigilancia en salud pública. Esto conlleva a una reducción significativa del tiempo dedicado al pre-procesamiento de datos y acelera la producción de reportes automatizados. Como resultado, los epidemiólogos pueden emplear herramientas avanzadas de análisis y, al mismo tiempo, disponer de más tiempo para la interpretación de resultados y la detección e investigación de comportamientos inusuales.

Boletin Epidemiologico Municipio de Pereira

Índice

1 Eventos Trazadores **1**
1.1 Infección respiratoria aguda . . . 1
1.2 Circulación virus respiratorios . . . 5
1.3 Enfermedades transmitidas por vectores . . . 6
1.4 Infección Diarreica Aguda . . . 8

2 Eventos de interes en salud pública **8**
2.1 Mortalidad materno-perinatal . . . 8
2.2 Agresiones por animales potencialmente transmisores de rabia . . . 8
2.3 Tuberculosis . . . 8
2.4 VIH/SIDA . . . 8
2.5 Sífilis gestacional y congénita . . . 9
2.6 Cáncer . . . 9
2.7 Defectos congénitos y bajo peso al nacer . . . 9
2.8 Inmunoprevenibles . . . 9
2.9 Virus nuevo (COVID-19) . . . 9

3 Vigilancia de exantematica **11**
3.1 Vigilancia Varicela en distintos grupos poblacionales . . . 11

Figura 1: Portada boletin epidemiologico

De igual manera en el canal endémico para la notificación por IRA hospitalizados en Unidad de Cuidados Intensivos (**UCI**) (figura 3), con descenso para esta semana epidemiologica notificada. La proporción acumulada de hospitalizaciones por IRA en UCI alcanza un 2.99%.

Edad (años)	Hosp. UCI IRA	Hosp. UCI todas las causas	% de Hosp. UCI
< 1	0	41	0.0
1	2	5	40.0
2 a 4	0	6	0.0
5 a 19	0	22	0.0
20 a 39	0	33	0.0
40 a 59	1	38	2.6
mayor e igual 60	0	91	0.0

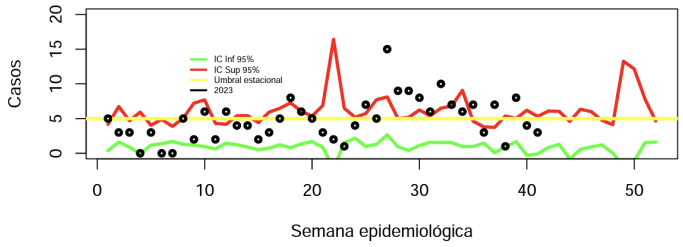


Figura 3: Canal endémico Hospitalizaciones por IRA en UCI , Pereira 2023

Figura 2: Salidas de tablas y graficas en boletin epidemiologico

References

Brookmeyer, R. and D.F. Stroup. 2003. *Monitoring the Health of Populations: Statistical Principles and Methods for Public Health Surveillance*. Oxford University Press.
URL: *https://books.google.com.co/books?id=7f3Y9M26StAC*

Grolemund, Garrett and Hadley Wickham. 2011. "Dates and Times Made Easy with lubridate." *Journal of Statistical Software* 40(3):1–25.
URL: *https://www.jstatsoft.org/v40/i03/*

Kamvar, Zhian N., Jun Cai, Juliet R.C. Pulliam, Jakob Schumacher and Thibaut Jombart. 2019. "Epidemic curves made easy using the R package incidence [version 1; referees: awaiting peer review]." *F1000Research* 8(139).
URL: *https://doi.org/10.12688/f1000research.18002.1*

Khan, Amir Maroof. 2013. "R-software: A Newer Tool in Epidemiological Data Analysis." *Indian J Community Med* 38:56–58.
URL: *https://doi.org/10.4103/0970-0218.106630*

Neale Batra et al. 2021. *The Epidemiologist R Handbook*. Applied epi.
URL: *https://epirhandbook.com/en/index.html*

R Core Team. 2019. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing.
URL: *https://www.R-project.org/*

Sjoberg, Daniel D., Karissa Whiting, Michael Curry, Jessica A. Lavery and Joseph Larmarange. 2021. "Reproducible Summary Tables with the gtsummary Package." *The R Journal* 13:570–580.
URL: *https://doi.org/10.32614/RJ-2021-053*

Wickham, Hadley, Mara Averick, Jennifer Bryan, Winston Chang, Lucy D'Agostino McGowan and Romain François et al. 2019. "Welcome to the tidyverse." *Journal of Open Source Software* 4(43):1686.

Diseño y validación de un instrumento de medida para el razonamiento estadístico de estudiantes de las Ciencias de la Salud *

Jaime A Gaviria Bedoya *Universidad de Antioquia*
Difariney González Gómez *Universidad de Antioquia*
Jhony A Villa Ochoa *Universidad de Antioquia*

Resumen: Se presenta el diseño y validación de un instrumento de medición para evaluar el razonamiento estadístico de estudiantes de posgrado de Ciencias de la Salud de una universidad pública colombiana. Se utilizó un formato de prueba objetiva de opción múltiple de 27 ítems. Los ítems se adaptaron a partir de instrumentos validados y se construyeron nuevos ítems a partir de resultados de artículos publicados en Ciencias de la Salud. La versión final del instrumento fue respondida por 149 estudiantes de posgrado de maestría y doctorado en las áreas de Salud. Se presentan resultados descriptivos de la muestra y la puntuación total del instrumento. Además, se muestran los resultados de un modelo de ecuaciones estructurales para la validez de constructo. Debido al tamaño reducido de la muestra, se utilizaron métodos de estimación especiales como el enfoque structural after measurement (SAM) (Rosseel and Loh, 2022). Se usó principalmente la librería de R lavan.

Keywords: razonamiento estadístico, validación instrumentos, Ciencias de la Salud, Modelo de ecuaciones estructurales

Introducción

El razonamiento estadístico se considera un objetivo de aprendizaje que es importante promover y desarrollar como parte de la formación de los estudiantes que toman cursos de estadística en diferentes niveles escolares (Ben-Zvi, Makar and Garfield, 2018). En particular, este razonamiento es esencial para los estudiantes de Ciencias de la Salud, ya que les permite comprender la información cuantitativa que encuentran en su contexto, cómo interpretar los riesgos y las probabilidades en los estudios médicos, así como tomar decisiones en situaciones en las que la variabilidad y la incertidumbre están presentes. A pesar de la reconocida importancia del razonamiento estadístico, especialmente en la educación universitaria, los investigadores sugieren realizar más estudios que aborden este razonamiento y su medición en estudiantes de Ciencias de la Salud (Fioravanti, Greca and Meneses, 2019). Además, diferentes revisiones bibliográficas coinciden en la importancia del uso de instrumentos validados para medir este constructo teórico (Langrall et al., 2017). Debido a que no existe consenso sobre la multidimensionalidad del razonamiento estadístico (Ferreras, 2014, Zieffler et al. (2008)), esta investigación tiene como pregunta de investigación: ¿cuál es la estructura de dimensionalidad del razonamiento estadístico de los estudiantes de las Ciencias de la Salud?. El objetivo de este estudio es describir el proceso de diseño y validación de un instrumento de medida para el razonamiento estadístico en estudiantes de posgrado de Ciencias

*Autor de contacto: jaime.gaviria@udea.edu.co.

de la Salud de una universidad pública colombiana.

La estructura del documento es la siguiente: En la segunda sección se presentará el diseño y valicación del instrumento propuesto. En la sección de resultados se presentará la carectetización sociodemográfica de la muestra de estudiantes, las medidas de resumen de sus puntajes totales de razonamiento estadístico y los resultados de los modelos de ecuaciones estructurales SEM. Finalmente, en la última sección se presentarán las conclusiones principales del estudio y las implicaciones para la investigación en educación estadística.

Diseño y validación del instrumento

Diseño del instrumento de medida para el razonamiento estadístico

El diseño del instrumento se llevó a cabo siguiendo las recomendaciones de los estándares para las pruebas en educación y psicología (American Educational Research Association, American Psychological Association and Nacional Council on Measurement in Education, 2014). Se optó por un formato de prueba objetivo de respuesta única, verdadero-falso y de opción múltiple porque este tipo de ítems es adecuado para evaluar las habilidades cognitivas. Luego, se construyó el test de especificaciones (blueprint) y se elaboró un banco inicial de 55 ítems que, luego del proceso de revisión de expertos y las entrevistas en voz alta a los estudiantes, se redujo a 27 ítems en la versión final. Para la selección de los ítems se tomaron dos tipos de fuentes: 1) instrumentos reconocidos, publicados y validados para el razonamiento estadístico y 2) se adaptaron ítems de investigaciones sobre el uso de la estadística en Ciencias de la Salud. Las áreas de contenido a evaluar corresponden al plan de estudios de los cursos de bioestadística de primer año para estudiantes de maestría y doctorado de las Ciencias de la Salud de la universidad, e incluyen estadística descriptiva, probabilidad, inferencia estadística paramétrica y no paramétrica. Siguiendo la Teoría Clásica de los Test (TCT), la puntuación total del instrumento se calculó como la suma de las respuestas correctas al instrumento.

Validación y análisis de la evaluación

La población de estudio se definió como estudiantes de posgrado activos pertenecientes a alguno de los programas de las facultades de las áreas de Ciencias de la Salud de la Universidad. Se definió una muestra por conveniencia. Se incluyeron en el estudio estudiantes de posgrado de maestría y doctorado de una de las diez áreas de salud de la Universidad. Para estimar las relaciones estructurales entre las dimensiones del razonamiento estadístico, se siguieron tres etapas (Kline, 2023), aunque por cuestiones de espacio en este documento solo se presentan los resultados de la última etapa. En la etapa 1 se realizó un Análisis Factorial Confirmatorio (AFC). Luego, en la etapa 2 se estableció la confiabilidad y validez del instrumento de medición. La confiabilidad se evaluó a través de la consistencia interna, utilizando el α de Cronbach y los coeficientes $G6$ de Gutman de forma global y para cada dimensión encontrada en la etapa 1. Finalmente, en la etapa 3 se estimó un modelo estructural siguiendo el enfoque de ecuaciones estructurales (SEM). El modelo de medición propuesto fue un modelo reflexivo de tres factores y, debido al pequeño tamaño de la muestra, se utilizaron métodos de estimación especiales, como el enfoque estructural después del de medida (SAM) (Rosseel and Loh, 2022). Todos los análisis estadísticos se realizaron en el software `@R` versión 4.3.1 y la librería lavaan (Rosseel, 2012).

Resultados

Descriptivos de la muestra y el puntaje

El trabajo de campo se realizó en línea utilizando Microsoft Forms entre los meses de noviembre de 2022 y abril de 2023. Un total de 150 estudiantes de posgrado de diez facultades diferentes de Ciencias de la Salud de la Universidad respondieron el instrumento para el razonamiento estadístico. El número de casos completos fue elevado (95.97%), por lo que el manejo de datos faltantes mediante el método pairwise deletion. Sin embargo, se realizó un análisis de sensibilidad en el que se realizaron 50 imputaciones múltiples con algoritmo de imputación multivariante por ecuaciones encadenadas (MICE) de la librería mice (Buuren and Groothuis-Oudshoorn, 2011) y al comparar los coeficientes de regresión y sus errores estándar se observó que eran muy similares.

Se encontró que el 53% de los estudiantes eran mujeres, el 54% de los estudiantes eran de la Facultad Nacional de Salud Pública, seguida de la Facultad de Medicina (25%). El nivel de posgrado predominante fue maestría (52.1%) y la media y desviación estándar de la edad fueron 36 años (8.8) respectivamente. La puntuación mínima fue de cuatro puntos y la máxima de 27 puntos. La media y la desviación estándar del instrumento fueron de 19.21 ± 5.58 puntos, respectivamente. Estos resultados indican una gran variabilidad en la puntuación total de razonamiento estadístico de los estudiantes de posgrado.

Modelo de ecuaciones estructurales SEM

Se estimó primero un modelo de análisis factorial confirmatorio con tres factores y debido a que todos los ítems fueron categóricos, se implementó el método de estimación diagonally weighted least squares (DWLS). Posteriormente se estimó un modelo de ecuaciones estructurales (SEM) con la librería lavaan, el cual convergió. El modelo propuesto fue un modelo reflexivo de tres factores y la sintaxis usada se muestra acontinuación

```
> ##### Modelo sam local con eliminación datos faltantes
>
> library(lavaan)
> fit2.1_cb.sam<-sam(modelo2.1CB,data=x_preguntas.f,ordered=T,cmd="sem",
+                    output="lavaan",mimic="Mplus",verbose=F,
+                    warn=F,missing="pairwise")
> summary(fit2.1_cb.sam,standardized=T,estimates=F)
## This is lavaan 0.6.16 -- using the SAM approach to SEM
##
##   SAM method                                    LOCAL
##   Mapping matrix M method                          ML
##   Number of measurement blocks                      3
##   Estimator measurement part                     DWLS
##   Estimator  structural part                       ML
##
##   Number of observations                          149
##   Number of missing patterns                        6
##
## Summary Information Measurement + Structural:
##
```

```
##   Block      Latent Nind  Chisq Df
##       1     problem    4  1.041  2
##       2    analysis   14 91.043 77
##       3 conclusions    9 15.763 27
##
##   Model-based reliability latent variables:
##
##   problem analysis conclusions
##     0.654    0.869       0.818
##
##   Summary Information Structural part:
##
##   chisq df cfi rmsea srmr
##       0  0   1     0    0
```

```
> parameterEstimates(fit2.1_cb.sam)[1:6,]
##            lhs op         rhs   est    se     z pvalue ci.lower ci.upper
## 28 conclusions  ~     problem 0.867 1.037 0.836  0.403   -1.166    2.899
## 29 conclusions  ~    analysis 0.288 0.435 0.661  0.509   -0.566    1.141
## 30     problem ~~     problem 0.100 0.080 1.237  0.216   -0.058    0.257
## 31    analysis ~~    analysis 0.456 0.091 5.020  0.000    0.278    0.634
## 32     problem ~~    analysis 0.190 0.080 2.371  0.018    0.033    0.347
## 33 conclusions ~~ conclusions 0.020 0.033 0.602  0.547   -0.045    0.085
```

Los resultados anteriores muestran que el modelo de ecuaciones estructurales SEM convergió normalmente apesar de tener un tamaño de muestra pequeño ($N < 200$). Las medidas de pseudo-ajuste (Kline, 2023) muestran que la fiabilidad para cada dimensión del razonamiento es aceptable, siendo la dimensión 1 la de menor fiabilidad. Finalmente, de los resultados de las estimaciones de los coeficientes de regresión de la parte estructural del modelo, se obtuvo que la dimensión 3 del razonamiento estadístico es explicada en mejor medida por la dimensión 1, problema, que por la 2, análisis, aunque ninguno de estos coeficientes resultó estadísticamente significativo. Por otro lado, la covarianza entre las dimensiones 1 y 2 fue significativa, lo que corrobora la interrelación entre ambas dimensiones. Estos resultados sugieren que se debe explorar mejor las relaciones estructurales entre las dimensiones del razonamiento estadístico.

Conclusiones e implicaciones para la investigación en educación estadística

El presente estudio busca realizar un aporte teórico al campo de la educación estadística en términos de conocimiento sobre el razonamiento estadístico de estudiantes de posgrado de Ciencias de la Salud. Los resultados del análisis factorial confirmatorio (que no se muestran por cuestiones de espacio) permitieron confirmar la multidimensionalidad del razonamiento estadístico, lo cual es consistente con los hallazgos de Ferreras (2014). A pesar de que los resultados mostrados son parciales, el diseño y validación de un instrumento de medición del razonamiento estadístico busca proporcionar a los docentes que imparten bioestadística a nivel universitario en facultades de salud información útil sobre los procesos cognitivos involucrados en el razonamiento estadístico, que permita identificar aquellos aspectos más relevantes para el aprendizaje y la adquisición de habilidades en la dimensión específica.

References

American Educational Research Association, American Psychological Association and Nacional Council on Measurement in Education. 2014. *The standards for educational and psychological testing*. American Educational Research Association.

Ben-Zvi, Dani, Katie Makar and Joan Garfield. 2018. *International handbook of research in statistics education*. Springer.

Buuren, Stef Van and Karin Groothuis-Oudshoorn. 2011. "mice: Multivariate Imputation by Chained Equations in R." 45(3).
URL: *http://www.jstatsoft.org/v45/i03/*

Ferreras, Soledad. 2014. "Desarrollo del razonamiento estadístico en estudiantes de enfermería [Tesis doctoral, Universidad Pontificia Comillas, Madrid].".
URL: *https://repositorio.comillas.edu/xmlui/handle/11531/1300*

Fioravanti, Rodrigo, Ileana Maria Greca and Jesus Ángel Meneses. 2019. "Caminos do ensino de estatística para a área da saúde." 22(1):67–96. Publisher: Comite Latinoamericano de Matematica Educativa.

Kline, Rex B. 2023. *Principles and Practice of Structural Equation Modeling*. Fifth edition ed. Guilford Press.

Langrall, Cynthia, Katie Makar, Michael Shaughnessy and Per Nilsson. 2017. Learning and Teaching Mathematics Content: Probability and Statistics. In *Compendiium for research in mathematics education*, ed. Jinfa Cai. National Council of Teachers of Mathematics pp. 490–525.

Rosseel, Yves. 2012. "lavaan: An R Package for Structural Equation Modeling." 48(1):1–36.

Rosseel, Yves and Wen Wei Loh. 2022. "A structural after measurement approach to structural equation modeling.".
URL: *http://doi.apa.org/getdoi.cfm?doi=10.1037/met0000503*

Zieffler, Andrew, Beng Chang, Kristine Holleque, Joan Garfield, Danielle Dupuis and Shirley Alt. 2008. "What Does Research Suggest About the Teaching and Learning of Introductory Statistics at the College Level? A Review of the Literature." 16(2):26.
URL: *https://www.tandfonline.com/doi/full/10.1080/10691898.2008.11889566*

Análisis de conglomerados jerárquicos para optimizar la distribución diferenciada de estudiantes de décimo grado del colegio Marymount de Barranquilla en la preparación de las Pruebas Saber 11. *

Elmer S. Rodríguez Stevez *Colegio Marymount - Barranquilla*
Sandra M. López Romano *Colegio Marymount - Barranquilla*

Resumen: El presente estudio se centra en la optimización de la distribución de los estudiantes de décimo grado del Colegio Marymount de Barranquilla, con el propósito de mejorar su preparación para las Pruebas Saber 11. Para lograr este objetivo, se emplea la técnica de análisis de conglomerados jerárquicos respaldada por datos previos de desempeño académico. A través del análisis detallado del dendrograma, se identifican patrones y similitudes que permiten agrupar a los estudiantes de manera óptima facilitando la implementación de estrategias de diferenciación pedagógica, el desarrollo de perfiles académicos específicos para cada grupo en espera de una mejora en los resultados de las pruebas simuladas. Esta estrategia tiene el potencial de transformar la manera en que se aborda la preparación de los estudiantes para exámenes estandarizados, brindando una solución innovadora y efectiva para mejorar la calidad de la educación. Este trabajo aspira a convertirse en un estudio de caso que pueda replicarse en otras instituciones educativas, ofreciendo una estrategia para optimizar la organización de grupos de estudio, aumentando así sus posibilidades de éxito en las Pruebas Saber 11.

Keywords: conglomerados jerárquicos, dendrograma, optimización, diferenciación pedagógica

1. Introducción

En el ámbito educativo, brindar una enseñanza efectiva a los estudiantes se presenta como un desafío que permite buscar caminos que lleven a mejorar el aprendizaje, evidenciado en un rendimiento académico y en los resultados obtenidos en pruebas estandarizadas. Este estudio se enfoca en cómo diferenciar a los estudiantes de décimo grado en el Colegio Marymount de Barranquilla, con el fin de fortalecer su preparación para las Pruebas Saber 11 (Pruebas Saber, 2022).

El objetivo principal de este estudio es desarrollar y aplicar una estrategia que optimice la distribución de estudiantes, utilizando el análisis de conglomerados jerárquicos. Esto se realiza con el propósito de identificar patrones y similitudes entre los estudiantes, facilitando una agrupación más efectiva que, a su vez, permita implementar estrategias de diferenciación pedagógica (Tomlinson, 2001) y desarrollar perfiles académicos específicos para cada grupo (Fernández, 2001).

La metodología seleccionada para abordar este problema se apoya en el análisis de conglomerados jerárquicos, respaldado por datos previos de desempeño académico y simulaciones de la prueba que llevan a realizar cortes parciales hasta llegar a un resultado final mejorado que permite

*Autor de contacto: elmer.rodriguez@marymountbq.edu.co.

visualizar el proceso llevado a cabo como una guía práctica para mejorar la organización de grupos de estudio e incrementar las posibilidades de éxito en las Pruebas Saber. La implementación exitosa de esta estrategia no solo beneficia a los estudiantes, sino que también contribuye al fortalecimiento de la institución, destacándola como un ejemplo a seguir en el ámbito educativo.

2. Metodología

El estudio propone la aplicación del Análisis de Conglomerados Jerárquicos (ACJ) como metodología central para optimizar la distribución de estudiantes. Esta herramienta estadística avanzada no solo facilita la asignación eficaz de grupos homogéneos, sino que también permite entender mejor las habilidades y necesidades particulares de los estudiantes en relación con las competencias evaluadas por las Pruebas Saber y así adaptar las estrategias pedagógicas, los contenidos y los estilos de enseñanza.

2.1 Análisis de Conglomerados Jerárquicos:

La recopilación de datos previos para estructurar los conglomerados se da a partir del desempeño académico de los estudiantes y las simulaciones realizadas para la prueba. A través del ACJ, se explora la agrupación de estudiantes en función de similitudes, creando un dendrograma que representa visualmente la jerarquía resultante. Este análisis proporciona una visión clara de cómo se relacionan entre sí los estudiantes, identificando grupos óptimos para una asignación estratégica. Con los procedimientos aglomerativos cada uno de los objetos empieza formando un conglomerado (grupos unitarios). Grupos cercanos se mezclan sucesivamente hasta que todos los objetos quedan dentro de un mismo conglomerado lo que genera una representación visual de la jerarquía denominada dendrograma. Este gráfico en forma de árbol permite la identificación intuitiva de patrones y relaciones entre los estudiantes agrupados que muestran niveles de similitud (Díaz, 2012).

La Figura 1 muestra cómo debería ser un buen diagrama de árbol. Si un investigador logra hacer uno parecido al de la Figura 1, puede estar bastante seguro de que los datos se dividen claramente en tres grupos diferentes (Johnson, 2000).

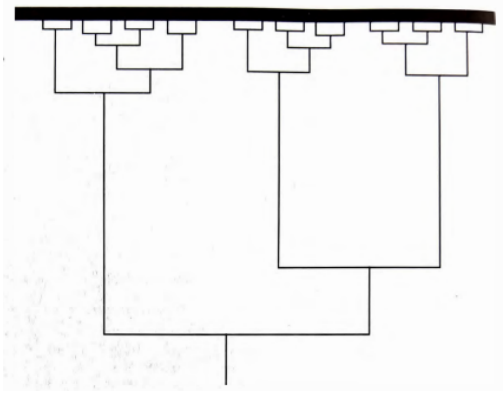


Figure 1: diagrama de árbol jerárquico o dendrograma.

2.2 Perfiles académicos específicos y diferenciación

Los perfiles académicos se establecen a partir de la agrupación realizada con el ACJ, proporcionando descripciones detalladas de las fortalezas y debilidades académicas de cada grupo, sirviendo como base para la implementación de estrategias educativas más específicas y efectivas (Bravo, 2017). En este sentido, una vez identificados los grupos mediante el ACJ, se implementa un trabajo diferenciado de acuerdo con el nivel de preparación, teniendo en cuenta que según Tomlinson (2001, 45) "los estudiantes aprenden mejor si las actividades que le son asignadas están estrechamente relacionadas con sus habilidades y comprensión de los temas". Esta estrategia implica adaptar la enseñanza para satisfacer las necesidades específicas de cada grupo, utilizando los perfiles académicos derivados de la agrupación (López, 1991).

3. Resultados

Para obtener información clara de los perfiles, los datos tenidos en cuenta fueron netamente cuantitativos, específicamente las notas académicas promedio del año anterior, centrándose exclusivamente en asignaturas evaluadas en las Pruebas Saber y los resultados de simulacros propuestos por una empresa externa, variables clave en el estudio. El Análisis de Conglomerados Jerárquicos (ACJ) se llevó a cabo mediante RStudio Cloud para optimizar la distribución de 66 estudiantes de décimo grado en el Colegio Marymount de Barranquilla. Este enfoque permitió la creación de grupos más homogéneos internamente y más heterogéneos entre ellos, en contraste con la diferenciación previa basada únicamente en los resultados de simulacros y el comportamiento disciplinario.

En lugar de la práctica anterior, que carecía de un método estadístico específico, se consideraron dos variables clave para la agrupación: el promedio de notas del año anterior en matemáticas, español, sociales y ciencias, y el promedio de las notas obtenidas en dos simulacros. La asignatura de inglés se excluyó debido al buen desempeño general de los estudiantes en esta área. Estas variables se promediaron y se normalizaron, debido a que éstas manejan diferentes escalas de evaluación.

Tras un análisis detallado de los dendrogramas generados en (Posit team, 2023) (Figura 2), en el que se realizó un análisis de agrupamiento utilizando el paquete `factoextra` versión 1.0.7 (Kassambara and Mundt, 2020) para la visualización de figuras y sabiendo de antemano que la cantidad de grupos más acorde a las condiciones organizacionales del colegio y la empresa quien entrena es de 6 grupos, se observó una destacada homogeneidad dentro de cada grupo, ya que coincide con sus perfiles académicos de años anteriores. Por ello, se puede decir que este estudio de caso, ha proporcionado una visión adecuada y personalizada de las necesidades, sirviendo como línea base para la implementación de estrategias pedagógicas adaptadas y, en última instancia, aspira mejorar la preparación de los estudiantes frente a las Pruebas Saber y otros desafíos académicos.

Es esencial resaltar que el proceso de agrupamiento se llevó a cabo mediante dendrogramas o diagramas de árbol jerárquico, utilizando el método del vecino más cercano. Este método se eligió por su capacidad para crear agrupamientos más compactos y cohesionados, considerando la conexión directa entre elementos vecinos. Aunque existen varios métodos de agrupación, la elección de esta técnica específica se alinea con la necesidad de generar grupos bien definidos y

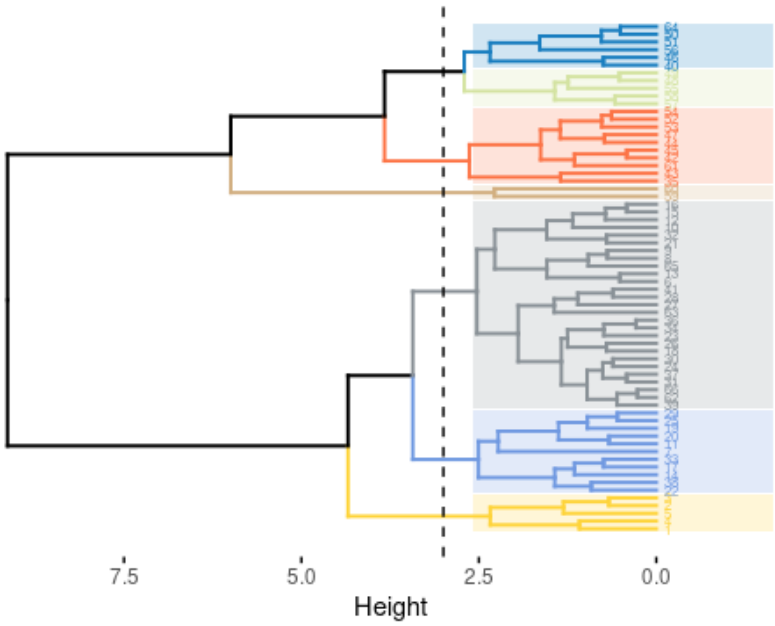


Figure 2: Dendrograma con 7 grupos diferenciados.

equilibrados en el contexto del colegio (Johnson, 2000).

4. Conclusiones

En conclusión, el estudio ha demostrado que la aplicación del Análisis de Conglomerados Jerárquicos (ACJ) en el Colegio Marymount de Barranquilla ha tenido un impacto significativo en la optimización de la distribución de estudiantes de décimo grado, específicamente en la preparación para las Pruebas Saber 11. La utilización del ACJ respaldado por datos de desempeño académico previo ha permitido identificar patrones y similitudes entre los estudiantes, facilitando la formación de grupos de manera óptima.

Esta metodología ha proporcionado una base sólida para la implementación de estrategias de diferenciación pedagógica y el desarrollo de perfiles académicos específicos para cada grupo. La limitación a seis grupos, establecida desde el inicio por consideraciones organizativas, ha demostrado ser acertada y ha asegurado una estructura manejable y eficiente para la adaptación de estrategias pedagógicas a las necesidades particulares de cada grupo con la expectativa de resultados a partir de la primera corte de simulacros.

Finalmente, podemos decir que la implementación de estrategias pedagógicas adaptadas a perfiles académicos específicos, derivados de este enfoque, se presenta como un camino prometedor para elevar el rendimiento de los estudiantes en las Pruebas Saber 11 y fortalecer su preparación general en el contexto educativo.

References

Bravo, M. y Salvo, S. 2017. "Perfiles de desempeño académico: la importancia de las expectativas familiares." *Perfiles Latinoamericanos* 25(50):361–386.

Díaz, G. y Morales, M. 2012. *Análisis Estadístico de Datos Multivariados*. Primera edición ed. Bogotá, D.C.,Colombia: Universidad Nacional de Colombia. ISBN 978-958-761-325-4.

Fernández, C. y Aqueveque, C. 2001. "Segmentación de mercados: buscando la correlación entre variables sicológicas y demográficas." *Revista Colombiana de Marketing* 2:1–15.

Johnson, D.E. 2000. *Métodos multivariados aplicados al análisis de datos*. Thomson Editores, México.

Kassambara, Alboukadel and Fabian Mundt. 2020. *factoextra: Extract and Visualize the Results of Multivariate Data Analyses*. R package version 1.0.7.
URL: *http://www.sthda.com/english/rpkgs/factoextra*

López, E. y González, M.A. 1991. "Hacia una pedagogía de las diferencias individuales: Reflexiones en torno al concepto de Pedagogía Diferencial." *Revista Complutense de Ciencias de la Educación* 2:83–92.

Posit team. 2023. *RStudio: Integrated Development Environment for R*. Boston, MA: Posit Software, PBC.
URL: *http://www.posit.co/*

Pruebas Saber, evaluación. 2022. "Ministerio de Educación Nacional.". November 17, 2023.
URL: *https://www.mineducacion.gov.co/portal/micrositios-preescolar-basica-y-media/Evaluacion/Evaluacion-de-estudiantes/397384:Pruebas-saber*

Tomlinson, C.A. 2001. *How to Differentiate Instruction in Mixed-ability Classrooms*. Segunda edición ed. Association for Supervision and Curriculum Development, Virginia USA. ISBN 0-87120-512-2.

Solución de problemas de prueba de hipótesis para promedio y proporción usando R *

Wilson Rodríguez Calderón *Escuela Superior de Administración Pública - sede Neiva*
Myriam R. Pallares Muñoz *Universidad Surcolombiana*

Resumen: Este trabajo presenta el planteamiento, planeación, montaje y desarrollo de tres casos de estudio del tema de prueba de hipótesis para promedio y proporción en el aula para estudiantes universitarios. Se trata del desarrollo de tres problemas modelo de prueba de hipótesis estadística para promedio (2) y proporción (1) usando como herramienta computacional el paquete estadístico libre R y como herramienta de verificación o comparación la hoja de cálculo Excel. En la actualidad a nivel mundial existen paquetes estadísticos especializados comerciales de gran capacidad, no obstante, se busca incentivar el uso de herramientas libres de disposición inmediata y amigables con los estudiantes que permitan descargar las fases de cálculo de los problemas, para privilegiar el esfuerzo y la atención en el análisis más que en el cálculo mismo. Para los casos se usó un procedimiento de revisión del estado del conocimiento del tema, planteamiento de los problemas, desarrollo de los códigos R y las hojas de cálculo en Excel por parte de los investigadores, prueba en el aula y trabajo en casa de los estudiantes y por último las conclusiones y recomendaciones. Los resultados muestran ventajas importantes de usar herramientas libres como R en el apoyo didáctico y de trabajo autónomo del alumno para apalancar experiencias de investigación formativa en el aula, experiencias de educación STEM y aprendizaje basado en problemas.

Palabras Clave: Pruebas de hipótesis, R, Estadística Inferencial.

Resultados

Problema 1. Aplicación en prueba de hipótesis para descarga promedio en máquina expendedora de gaseosas

Se trata de la aplicación de R al estudio de una prueba de hipótesis para descarga promedio en onzas por taza. La pregunta fundamental es: ¿Los datos presentan suficiente evidencia para indicar que la descarga media difiere de 7 onzas? (Wackerly et al., 2010). Si bien R posee funciones para pruebas de hipótesis estadística, para la investigación se desarrolló una herramienta que pudiera atender de manera general las variantes de los problemas de prueba de hipótesis para promedio y proporción. A continuación se muestra la solución en R y Excel encontrada y verificada.

En la Figura 1 se muestra la solución en R con su respectiva gráfica de las zonas de rechazo de la hipótesis nula marcadas en verde, por otra parte, la Figura 2 muestra la verificación satisfactoria en Excel que muestra como la herramienta desarrollada se adapta a la solución del problema. El R muestra gran versatilidad y la capacidad de rápidamente graficar las zonas de rechazo de la hipótesis nula, aspecto muy útil para la didáctica y compresión del problema.

*__Autor de contacto__: wilson.rodriguezc@esap.edu.co

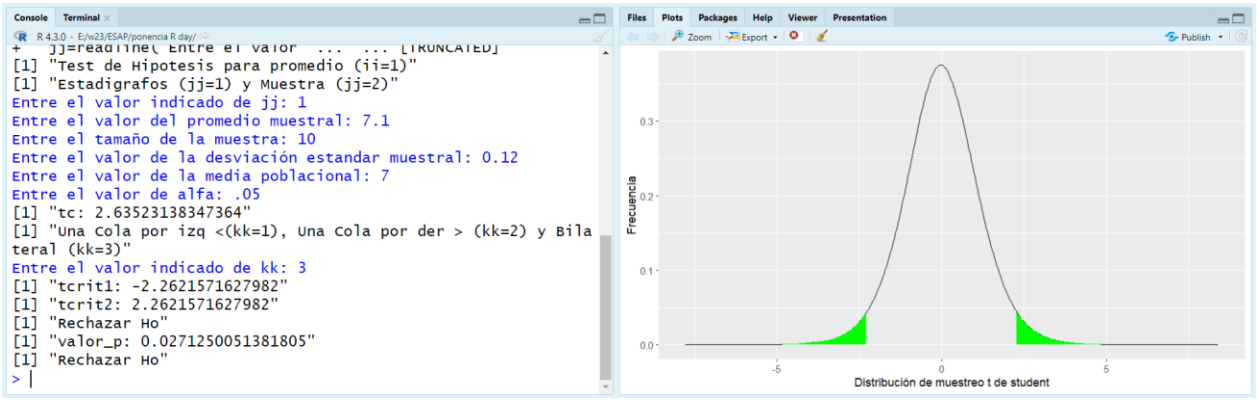


Figura 1: Problema de prueba de hipótesis para descarga promedio en máquina expendedora de gaseosas resuelto en R. Fuente: Autores

MÁQUINA EXPENDEDORA DE GASEOSAS

X: Descarga en onzas de líquido por taza

Ho: $\mu = 7$ (La descarga promedio de la máquina expendedora de gaseosas es de 7 onzas/taza)

Ha: $\mu \neq 7$ (La descarga promedio de la máquina expendedora de gaseosas es diferente de 7 onzas/taza)

$\bar{x}$	7.100	Media de la muestra	$\bar{x}$	7.100	Media de la muestra
n	10	Tamaño de la muestra	n	10	Tamaño de la muestra
s	0.12	Desviación estándar de la muestra	s	0.12	Desviación estándar de la muestra
μ_0	7	Media de la población	μ_0	7	Media de la población
α	0.05	Nivel de significancia	α	0.05	Nivel de significancia
$\alpha/2$	0.025		$\alpha/2$	0.025	
t_c	2.635231383		t_c	2.635231383	
$t_{\alpha/2:n-1}$	2.262157163				
$t_{1-\alpha/2:n-1}$	-2.262157163		Valor-p	0.027125005	$p=2*P(t>t_c)$
prueba	VERDADERO		prueba	VERDADERO	$p<\alpha$
	Rechazar Ho			Rechazar Ho	

$$t_c = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

La conclusión en el contexto del problema implica que, al nivel de significancia de 5%, hay evidencia suficiente para creer que descarga promedio de la máquina de gasesosas es diferente a 7 onzas/taza.

Figura 2: Problema de prueba de hipótesis para descarga promedio en máquina expendedora de gaseosas resuelto en Excel. Fuente: Autores

Problema 2. Aplicación en prueba de hipótesis para capacidad promedio de difusión de monóxido de carbono en fumadores

Se trata de la aplicación de R al estudio de una prueba de hipótesis para capacidad promedio de difusión de monóxido de carbono en fumadores. La pregunta fundamental es: ¿Estos datos indican que la lectura media de DL para fumadores actuales es menor que 100, el promedio de lectura de DL para los no fumadores? (Wackerly et al., 2010).

En la Figura 3 se muestra la solución en R con su respectiva gráfica de la zona de rechazo de la hipótesis nula marcada en verde, por otra parte, la Figura 4 muestra la verificación satisfactoria en Excel. En este caso se carga una muestra de 20 datos, en lugar de suministrar los estadígrafos de la muestra, que para el caso son calculados y usados para la solución.

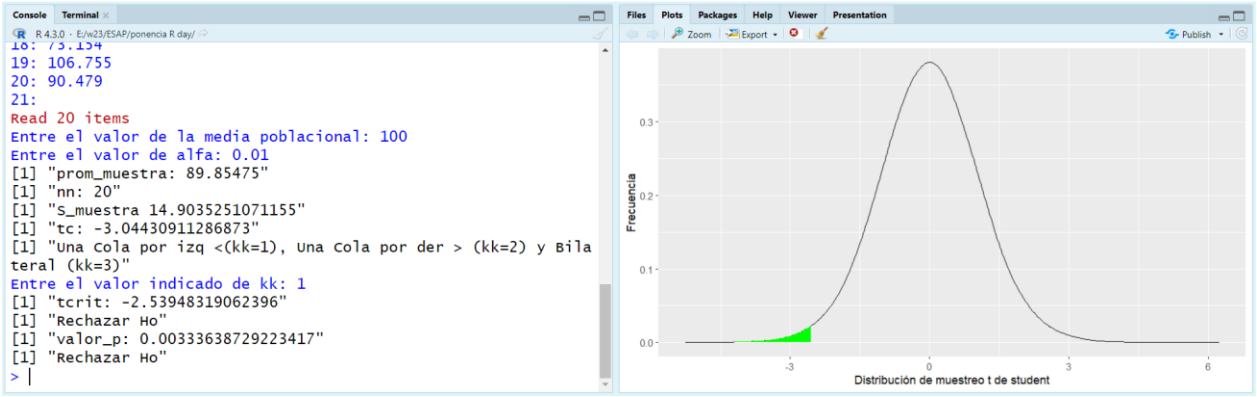


Figura 3: Problema de prueba de hipótesis para capacidad promedio de difusión de monóxido de carbono en fumadores resuelto en R. Fuente: Autores

CAPACIDAD DE DIFUSIÓN DE MONOXIDO DE CARBONO (DL) EN FUMADORES

X: Capacidad de difusión de monoxido de carbono (DL) en fumadores

Ho: μ = 100 (El promedio de capacidad de difusión de monóxido de carbono (DL) en fumadores es de 100)

Ha: μ < 100 (El promedio de capacidad de difusión de monóxido de carbono (DL) en fumadores es menor que 100)

$\bar{x}$	89.855	Media de la muestra
n	20	Tamaño de la muestra
s	14.90352511	Desviación estándar de la muestra
μ_0	100	Media de la población
α	0.01	Nivel de significancia
t_c	-3.04430911	
$t_{1-\alpha:n-1}$	-2.53948319	Punto crítico en la t de student $t_{0.95:99}$
prueba	VERDADERO	$t_c<t_{1-\alpha:n-1}$
	Rechazar Ho	

$\bar{x}$	89.855	Media de la muestra
n	20	Tamaño de la muestra
s	14.90352511	Desviación estándar de la muestra
μ_0	100	Media de la población
α	0.01	Nivel de significancia
t_c	-3.044309113	
Valor-p	0.003336387	$p=P(T_{n-1}<t_c)$
prueba	VERDADERO	$p<\alpha$
	Rechazar Ho	

La conclusión en el contexto del problema implica que, al nivel de significancia de 1%, hay evidencia suficiente para creer que la capacidad de difusión de monoxido de carbono (DL) promedio en fumadores es menor que 100 (el promedio de lectura del DL para no fumadores).

	DL
1	103.768
2	88.602
3	73.003
4	123.086
5	91.052
6	92.295
7	61.675
8	90.677
9	84.023
10	76.014
11	100.615
12	88.017
13	71.210
14	82.115
15	89.222
16	102.754
17	108.579
18	73.154
19	106.755
20	90.479
prom	89.855
s	14.90353

Figura 4: Problema de prueba de hipótesis para capacidad promedio de difusión de monóxido de carbono en fumadores resuelto en Excel. Fuente: Autores

Problema 3. Aplicación en prueba de hipótesis para proporción de percepción sobre la calidad del medio ambiente del país

Se trata de la aplicación de R al estudio de una prueba de hipótesis para la proporción de personas con percepción regular o mala sobre la calidad del medio ambiente del país. La pregunta fundamental es: ¿Hay evidencia convincente de que una mayoría de adultos de la nación piensa que la calidad del medio ambiente es regular o mala? (Wackerly et al., 2010).

En la Figura 5 se muestra la solución en R con su respectiva gráfica de la zona de rechazo de la hipótesis nula marcada en verde, por otra parte, la Figura 6 muestra la verificación satisfactoria en Excel. En este caso se entrega el estadígrafo de proporción muestral directamente, junto con el tamaño de muestra.

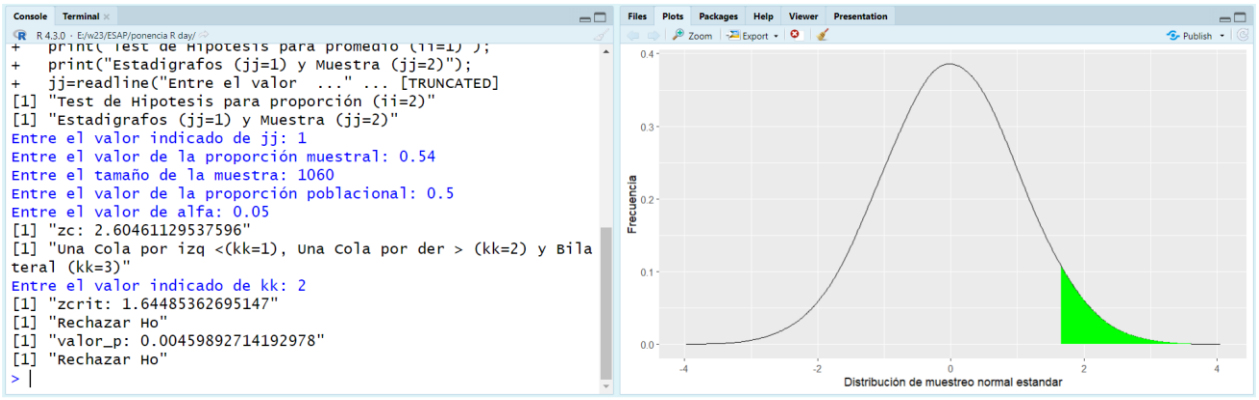


Figura 5: Problema de prueba de hipótesis para proporción de percepción sobre la calidad del medio ambiente del país resuelto en R. Fuente: Autores

PERCEPCIÓN SOBRE LA CALIDAD DEL MEDIO AMBIENTE DEL PAÍS

X: Número de personas que consideran que la calidad del medio ambiente es regular o mala

Ho: $\pi = 0.5$ (La proporción de personas que consideran que la calidad del medio ambiente del país es regular o mala es del 50%)

Ha: $\pi > 0.5$ (La proporción de personas que consideran que la calidad del medio ambiente del país es regular o mala es mayor del 50%)

x	572	# individuos que cumplen la característica x
n	1060	Tamaño de la muestra
p	0.54	Proporción de la muestra
π_0	0.5	Proporción de la población
α	0.05	Nivel de significancia
Z_c	2.604611295	
Z_α	1.644853627	
prueba	VERDADERO	Zc > Zα
	Rechazar Ho	

$$Z_C = \frac{p - \pi_0}{\sqrt{\frac{\pi_0(1-\pi_0)}{n}}}$$

x	572	# individuos que cumplen la característica x
n	1060	Tamaño de la muestra
p	0.54	Proporción de la muestra
π_0	0.5	Proporción de la población
α	0.05	Nivel de significancia
Z_c	2.604611295	
Valor-p	0.004598927	p=P(Z>Z_c)
prueba	VERDADERO	p<α
	Rechazar Ho	

La conclusión lleva a creer que, al nivel de significancia de 5%, que los datos proporcionan evidencia suficiente para pensar que la mayoria de personas piensan que la calidad del medio ambiente es regular o mala.

Figura 6: Problema de prueba de hipótesis para proporción de percepción sobre la calidad del medio ambiente del país resuelto en Excel. Fuente: Autores

Referencias

R Core Team. 2019. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing.
URL: *https://www.R-project.org/*

Wackerly, D., L. Scheaffer, R. y Mendenhall, W. (2010). *Estadística matemática con aplicaciones*. Cuajimalpa de Morelos, Mexico: Cengage Learning Editores.

Distribución Discreta Poisson XLindley *

Mariana Blandón Mejía *Universidad Nacional de Colombia - sede Medellín*
Freddy Hernandez Barajas *Docente Universidad Nacional de Colombia - sede Medellín*

Resumen: Se resaltarán las ventajas de la Poisson-XL, su función masa de probabilidad y su función de distribución acumulada,previamente se realizó la creación de la nueva distribución en RStudio utilizando los modelos gamlss,lo que permite elaborar estudios de simulación y modelamiento con datos reales.Se encontró que las propiedades de la PXL se pueden expresar en formas cerradas,lo que la convierte en una herramienta de probabilidad propuesta para establecer modelos de regresión y series de tiempo ;la nueva función masa de probabilidad se puede utilizar para modelar datos sesgados positivamente con forma leptocúrtica,además,la nueva distribución PXL,es útil para el modelamiento de fenómenos equidispersos y sobredispersos con una función de tasa de riesgo creciente.

Keywords: gamlss,leptocúrtica, equidisperso,sobredisperso.

Introducción

Se estudiará una nueva distribución de conteo discreta de un parámetro la cual combina las distribuciones Poisson y XLindley ,se obtiene como resultado la "Poisson-XL", esta nueva distribución tiene múltiples ventajas como la capacidad de describir datos equidispersos y sobredispersos,además,puede ser utilizada como una herramienta estadística adecuada para modelar datos sesgados positivamente con forma leptocúrtica.

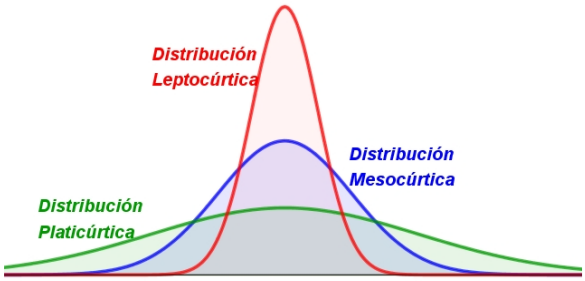


Figure 1: Curtosis.

El coeficiente de curtosis se utiliza para medir la forma de la distribución de los datos. En una distribución leptocúrtica, el coeficiente de curtosis es positivo, indicando colas más pesadas en comparación con una distribución normal.La leptocurtosis es el opuesto de la platicurtosis, que se refiere a colas más ligeras en la distribución. La forma leptocúrtica puede deberse a diversos factores, como la presencia de eventos extremos o la naturaleza de los datos en estudio.

*Autor de contacto: mblandonm@unal.edu.co.

Dado que existe la necesidad de un modelo más flexible para modelar datos estadísticos Mahmoudi y Zakerzadeh,docentes asociados al departamento de estadística de la Universidad de Yazd, ampliaron la distribución de Poisson-Lindley y revelaron que su distribución generalizada es más flexible a la hora de evaluar los datos de recuento , en este estudio se ahondará en una una distribución discreta flexible combinando las distribuciones de Poisson y XL, llamada *Poisson-XLindley*.
En este estudio se abordarán las principales características de la distribución discreta de un solo parámetro Poisson XLindley,propiedades estadísticas y la implementación de esta al modelamiento de datos reales y simulados.

Propiedades Estadísticas

La función masa de probabilidad de la distribución Poisson-XL está dada por:

$$f(x) = \frac{\mu^2(2+\mu+x)e^{-\mu x}}{(1+\mu)^2}; x > 0, \mu > 0$$

La función de probabilidad conjunta para Poisson-XL está dada por:

$$F(x) = 1 - \frac{(1+\mu(x+4+\mu(3+\mu)))}{(1+\mu)^{4+x}}$$

Se presentará un gráfico de la función masa de probabilidad para la distribución PoissonXL variando el valor del parámetro μ

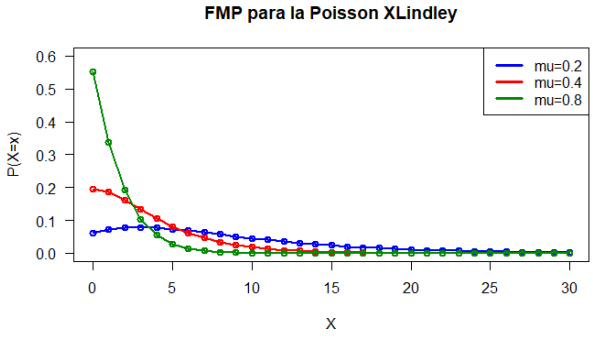


Figure 2: función masa de probabilidad.

Del gráfico anterior se puede analizar que a medida que se incrementa el valor del parámetro μ la función masa presenta una probabilidad más alta para valores de muestra pequeños, luego de una muestra de 5 unidades esta se estabiliza y comporta de manera muy similar a valores más pequeños de μ como lo son 0.2 y 0.4.

Implementación de la distribución Poisson XL

Ejemplo con datos Reales.

Los datos con los que se trabajará fueron tomados del estudio del cual fue tomada esta distribución(l-Haq,Al-Bossly.2022),este conjunto de datos contiene el número de lesiones dosimétricas citogenéticas de mamíferos producidas por exposición a estreptogramina.

Las estreptograminas son conocidas por su actividad contra ciertos tipos de bacterias, especialmente aquellas resistentes a otros antibióticos más comunes. Por lo general, se utilizan en combinación para aumentar su eficacia y reducir el riesgo de resistencia bacteriana, el objetivo de este estudio es analizar la cantidad de lesiones presentes en el ADN de los conejos luego de aplicar diferentes dósis de estreptogramina.

Con el objetivo de analizar la robustez de la distribución Poison-XL y como esta se adapta a estos datos de tipo científico se realizó una prueba en la que se comparará el comportamiento de esta distribución con respecto a los datos reales.

Table 1: Ajuste PXL vs datos reales.

X	Frecuencia Observada	Frecuencia(promedio) Esperada
1	200	194.6
2	57	68.5
3	30	24.0
4 $\geq$	13	12.9
Total	300	300

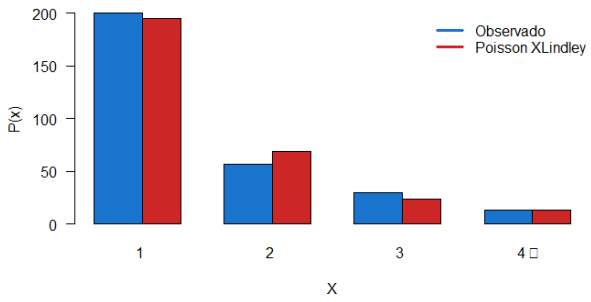


Figure 3: Resultados ajuste a datos reales.

Con base en los resultados de la tabla se puede observar que en este tipo de situaciones la distribución Poisson XL tiene un muy buen rendimiento en el ajuste para este tipo de datos..

Generación de algunos valores aleatorios con μ conocido

GAMLSS (Generalized Additive Models for Location, Scale, and Shape) es un enfoque estadístico que proporciona una metodología flexible para modelar diferentes aspectos de una distribución de probabilidad, incluyendo la ubicación, la escala y la forma. Los modelos GAMLSS son una extensión de los modelos de regresión generalizados (GLM) y los modelos lineales generalizados aditivos (GAM).

En el siguiente código se generará una muestra con $n = 1000$ valores que siguen una distribución Poisson XLindley con μ conocido , en este caso 0.5, luego de generar los valores se ajustará un modelo de la familia gamlss el cual tiene como objetivo acercarse lo más posible al verdadero valor de μ

```
y <- rPOISXL(n=1000, mu=0.5)
library(gamlss)
mod1 <- gamlss(y~1, family=POISXL,
               control=gamlss.control(n.cyc=500, trace=FALSE))

exp(coef(mod1, what='mu'))
(Intercept)
  0.4820785
```

El resultado del modelo arroja que $\mu = 0.48$ lo cual es bastante cercano al μ que se estableció inicialmente, así que este modelo cumple el objetivo.

Conclusiones

En general,se encontró que las propiedades de PXL se pueden expresar en formas cerradas, lo que convierte a esta distribución en una herramienta de probabilidad propuesta para establecer modelos de regresión , series de tiempo y es ideal para modelamiento de datos de tipo científico; esto hace de la distribución PXL un elemento muy versátil para el análisis de datos en diversos campos.

Referencias

l-Haq,Al-Bossly.2022.Poisson XLindley Distribution for Count Data: Statistical and Reliability Properties with Estimation Techniques and Inference
URL:https://www.hindawi.com/journals/cin/2022/6503670/

Hassan,Shalbaf,Bilal y Rashid.2020.Una nueva distribución discreta flexible con aplicaciones para contar datos.Journal of Statistical Theory and Applications,vol. 19
URL:https://www.atlantis-press.com/journals/jsta/125935241/view

Grine y Zeghdoudi.2017.Sobre la distribución cuasi-lindley de Poisson y sus aplicaciones.Journal of Modern Applied Statistical Methods.
URL:https://www.semanticscholar.org/paper

Metaanálisis de metaheurísticas empleando R. *

Daniela Alcázar N. *Universidad de Antioquia*
Aura María Molina *Universidad de Antioquia*
Alejandro Arenas-Vasco *Universidad de Antioquia*
Juan G. Villegas *Analítica e Investigación para la toma de Decisiones, Departamento de Ingeniería Industrial, Facultad de Ingeniería, Universidad de Antioquia*

La divergencia en los resultados de estudios análogos es un problema en la investigación de operaciones, debido a que los investigadores suelen centrarse en el desarrollo de soluciones algorítmicas complejas, dejando de lado la evaluación del rendimiento de las existentes. El objetivo de esta investigación es replicar el metaanálisis realizado por Turkeš, Sörensen and Hvattum (2021) utilizando los datos públicos disponibles de Turkeš et al. (2020) y el lenguaje de programación R. En este metaanálisis, se analizó el impacto de agregar el componente adaptativo (ALNS) a la metaheurística Large Neighborhood Search (LNS). Para ello, se ejecutó un modelo de efectos aleatorios en R, utilizando funciones de las librerías meta, metafor y dmetar para obtener el efecto del componente adaptativo y el diagrama de bosque, en conjunto con ggplot2 para la presentación descriptiva de la información fuente.

Keywords: metaanálisis, modelo de efectos, metaheurísticas

Introducción

El metaanálisis es una técnica estadística que se emplea para reunir y combinar los resultados de diversos estudios. El término hace referencia a una revisión sistemática de la literatura que utiliza técnicas estadísticas para integrar y resumir los hallazgos de varios estudios independientes. En contraste con las revisiones tradicionales, que dependen de la subjetividad del revisor y carecen de transparencia en los métodos de búsqueda, las revisiones sistemáticas reducen el sesgo, ofreciendo resultados más confiables. El propósito de esta revisión es abordar una misma pregunta científica y lograr una estimación más precisa del impacto de una intervención o tratamiento, que se define como la diferencia en los resultados entre grupos experimentales y de control en relación con una variable de interés. Esta metodología no solo facilita la síntesis de la evidencia científica, sino que también posibilita la identificación de patrones comunes en los resultados de la investigación y la evaluación de la magnitud de los efectos. El metaanálisis se emplea para combinar los resultados en un único estimador puntual, bajo el enfoque de que no se debe concentrar la investigación en la significancia estadística de los estudios individuales, sino en la magnitud del efecto o su tamaño (Crowther, Lim and Crowther, 2010).

En general, un metaanálisis se realiza de acuerdo con los siguientes pasos:

1. Identificación de los estudios: búsqueda bibliográfica.
2. Evaluación de calidad de los estudios: calidad metodológica.
3. Extracción de datos: tamaños de efectos, estadísticas significativas y características de los estudios.

*Autor de contacto: daniela.alcazar@udea.edu.co.

4. Análisis de los datos, empleando métodos estadísticos efectos fijos y efectos aleatorios.
5. Interpretación de resultados, teniendo en cuenta las limitaciones del estudio.

Herramientas estadísticas libres como el lenguaje de programación R (R Core Team, 2019) son de mucha utilidad en la realización de revisiones de literatura basadas en metaanálisis. Esto se debe a que el metaanálisis abarca desde estadísticas descriptivas de los estudios analizados hasta pruebas de hipótesis y meta-regresiones, entre otras técnicas estadísticas (Harrer et al., 2021; Balduzzi, Rucker and Schwarzer, 2019).

Por otro lado, ha habido un aumento en la calidad y la frecuencia de las revisiones de literatura en el ámbito de la investigación de operaciones. Según Schryen and Sperling (2023), la mayoría de estas revisiones tienden a tener un alcance limitado y adoptan enfoques narrativos o selectivos, mientras que las revisiones integrativas, sistemáticas y los metaanálisis son menos comunes.

En particular, Turkeš, Sörensen and Hvattum (2021) llevaron a cabo un metaanálisis que abarcó 25 estudios sobre el efecto del componente de adaptabilidad en la búsqueda adaptativa de vecindarios de gran escala (ALNS – Adaptive large neighborhood search). La ALNS constituye una técnica metaheurística que se utiliza en la resolución de problemas de optimización combinatoria. El objetivo del metaanálisis de Turkeš, Sörensen and Hvattum (2021) fue determinar si la adaptabilidad de la ALNS tiene un efecto significativo en su eficacia. Como resultado, encontraron que la adaptabilidad tiene un efecto positivo significativo en la eficacia de la ALNS, pues para los estudios analizados, se obtuvo en general mejores resultados cuando se incluía este componente, en comparación con aquellas veces donde la búsqueda era no adaptativa. Cabe resaltar que los autores señalan que, si bien la capa adaptativa puede aportar valor (y en un número limitado de estudios lo hace), también agrega complejidad, por lo que su recomendación se limita a situaciones específicas.

Metaanálisis en R con los datos de Turkeš et al. (2020)

A continuación se detalla el procedimiento para reproducir el estudio de Turkeš, Sörensen and Hvattum (2021) utilizando los datos públicos de Turkeš et al. (2020) y las directrices de Harrer et al. (2021), guía práctica proporciona instrucciones detalladas y ejemplos para realizar un metaanálisis con el lenguaje de programación R (R Core Team, 2019). Se empleó RStudio (Allaire, 2012) como entorno de desarrollo integrado.

Turkeš et al. (2020) recopilaron datos de 25 estudios para el metaanálisis. De estos, 22 abordaron problemas de minimización, y solo tres buscaban maximizar la función objetivo. Cada estudio definió un conjunto de instancias y un número de repeticiones específico. El promedio de instancias por estudio fue de aproximadamente 150, exceptuando uno que tenía más de 11000 instancias. En cuanto a las repeticiones, 13 estudios resolvieron cada instancia cinco veces, 10 realizaron 10 repeticiones, y los dos restantes llevaron a cabo una y 20 repeticiones, respectivamente.

1. Preparación de los datos.

   En esta etapa inicial se utilizan los datos no procesados proporcionados por Turkeš et al. (2020), datos que contienen la información sobre los valores obtenidos en cada repetición de las instancias del problema en cuestión. Se cargan al entorno de **RStudio** (Allaire, 2012), donde se realiza una exploración de los datos, imputando valores faltantes, eliminando

duplicados y corrigiendo errores de entrada, y se analiza gráficamente la distribución de los datos obtenidos por factores y sus características generales, usando los paquetes **skimr** (Waring et al., 2022) y **ggplot2** (Wickham, 2016). Tras esto, el paquete por excelencia en manipulación de marcos de datos **dplyr** (Wickham et al., 2023) se emplea para así poder sintetizar la información por instancias, siguiendo lo definido por Turkeš, Sörensen and Hvattum (2021) acerca de tomar el promedio de las instancias como valor de la función objetivo para la metaheurística con y sin el componente, para posteriormente hallar el efecto del componente adaptativo en cada una de ellas y el error estándar asociado.

2. Metaanálisis.

   Siguiendo la guía práctica de Harrer et al. (2021), se usan los paquetes **meta** (Balduzzi, Rucker and Schwarzer, 2019) y **metafor** (Viechtbauer, 2010) para la creación del modelo de efectos aleatorios y el diagrama de bosque, que representa visualmente las estimaciones obtenidas en el modelo de efectos.

3. Análisis de sensibilidad.

   Se evalúa la robustez de los resultados del metaanálisis mediante un análisis de sensibilidad, identificando los estudios altamente influyentes en la estimación del efecto global, utilizando el paquete **dmetar** (Harrer et al., 2019).

4. Evaluación de sesgo de publicación.

   Se verifica la presencia de sesgo de publicación en los estudios analizados utilizando el paquete **dmetar** (Harrer et al., 2019).

5. Interpretación y publicación de los resultados.

   Por último, se presentan los resultados obtenidos durante el metaanálisis usando R Markdown (Xie, Dervieux and Riederer, 2020) para crear el informe, que facilita la combinación de texto plano, código y salidas de R (R Core Team, 2019) en un solo documento.

Resultados y discusión

Turkeš, Sörensen and Hvattum (2021) proponen que el efecto del componente adaptativo en la metaheurística de la ALNS para cada estudio como la mejora promedio. Utilizan la Ecuación 1 si el objetivo es maximizar y la Ecuación 2, si es minimizar. Donde A_k representa la mejora promedio atribuida al componente adaptativo de la metaheurística en el estudio k, N_k es el número de instancias, $\mathcal{I}$ es el conjunto de instancias, $\bar{f}_k(x_{r_k}(I))$ es el valor promedio de la función objetivo para la instancia I con el componente adaptativo (con un factor de adaptatividad r definido para el estudio k), y $\bar{f}_k(x_0(I))$ es el valor promedio de la función objetivo sin la capa adaptativa de la metaheurística.

$$A_k = \frac{1}{N_k} \sum_{I \epsilon \mathcal{I}} \frac{\bar{f}_k(x_{r_k}(I)) - \bar{f}_k(x_0(I))}{\bar{f}_k(x_0(I))} \tag{1}$$

$$A_k = \frac{1}{N_k} \sum_{I \epsilon \mathcal{I}} \frac{\bar{f}_k(x_0(I)) - \bar{f}_k(x_{r_k}(I))}{\bar{f}_k(x_0(I))} \tag{2}$$

El error estándar del efecto se calcula mediante la Ecuación 3, donde σ_k^2 representa la varianza del efecto entre las instancias del estudio y N_k es el número de instancias.

$$SE_k = \frac{\sigma_k^2}{N_k} \tag{3}$$

De los datos de Turkeš et al. (2020) se excluyeron tres estudios con valores atípicos para el error estándar (error estándar muy grande). Se aplicó un modelo de efectos aleatorios para abordar la heterogeneidad mencionada, mediante el cuál se obtuvo un promedio de efecto del componente adaptativo para la ALNS del 0.136%, con un intervalo al 95% de confianza $(-0.09; 0.36)$. El resumen del modelo, representado en la Figura 1, incluye el autor principal y el año de publicación del artículo, el efecto promedio, el error estándar, el intervalo de confianza y el peso asignado a cada estudio. El diagrama de bosque visualiza estos datos, destacando el efecto, el peso (a través del tamaño), y el intervalo de confianza (la línea horizontal alrededor del efecto), con un índice de heterogeneidad del 94.4% y una varianza del efecto real de 0.015.

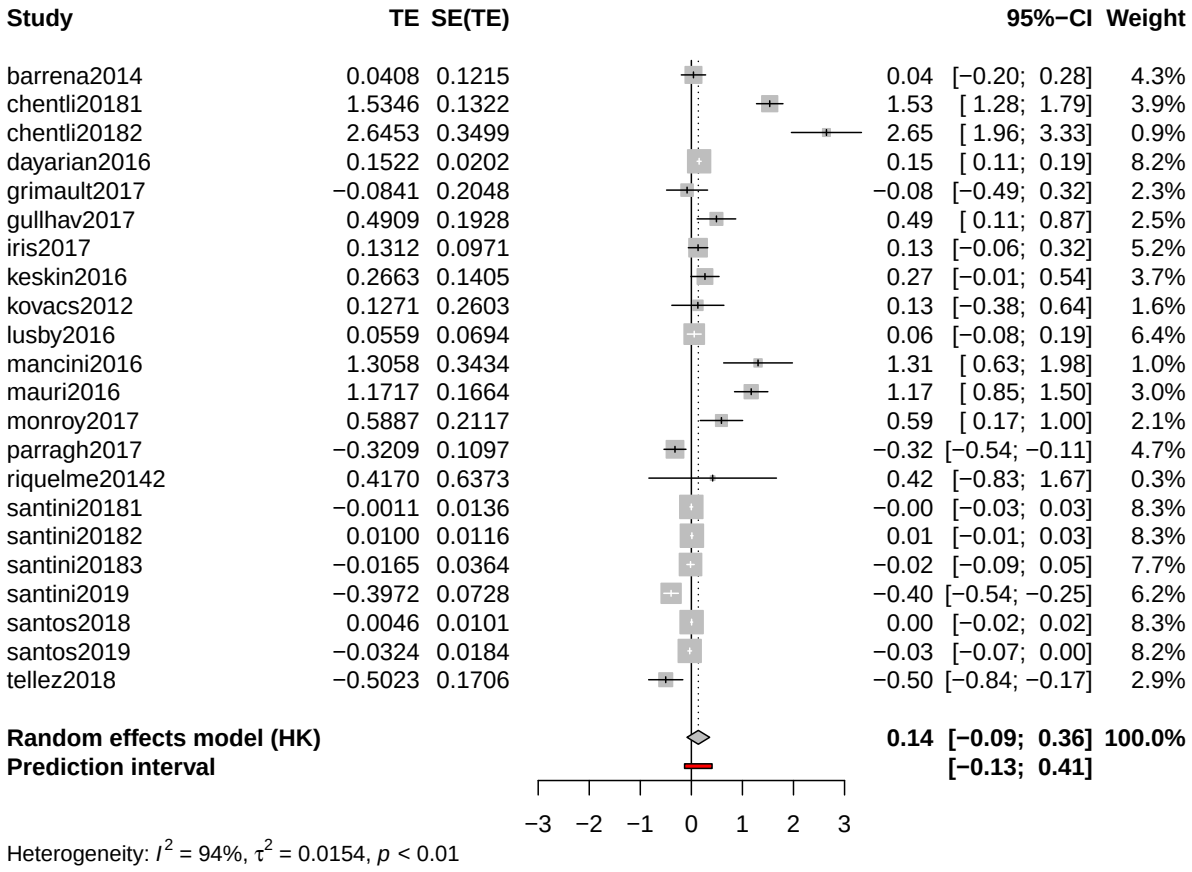


Figure 1: Diagrama de bosque

Según Valentine, Pigott and Rothstein (2010), se considera que al menos 10 estudios son necesarios para llevar a cabo un metaanálisis confiable. No obstante, esta cifra puede variar según diversos factores, como las características requeridas y los recursos disponibles. En este contexto, los 25 estudios utilizados por Turkeš, Sörensen and Hvattum (2021) podrían considerarse 'pocos', especialmente al tener en cuenta la complejidad del ALNS. Es importante señalar que la limitación en la obtención de datos, ya que no todos los estudios que emplean ALNS reportan resultados con y sin el componente de adaptabilidad, llevó a la exclusión de aproximadamente 40 estudios de la lista preliminar de elegibles.

Aunque no es posible identificar directamente la presencia de sesgo de manera estadística, existen herramientas que permiten examinar ciertas propiedades de los datos que podrían indicar su presencia. Algunos de estos métodos se enfocan en analizar los efectos de los estudios pequeños y parten de la suposición de que los estudios pequeños tienen más probabilidad de ser víctimas del sesgo de publicación, pues, al no implicar un gran compromiso de recursos y tiempo, si los resultados no son tan favorables suelen quedar archivados (Harrer et al., 2021). Un estudio pequeño se traduce en un error estándar alto (pocas instancias o mucha variación); a pesar de que esto se abordó mediante la eliminación de atípicos, en el diagrama de embudo de la Figura 2 se puede apreciar un posible sesgo de publicación en los datos incluidos para el metaanálisis, ya que los estudios más pequeños (o con error estándar más grande) son los que tienen resultados más positivos.

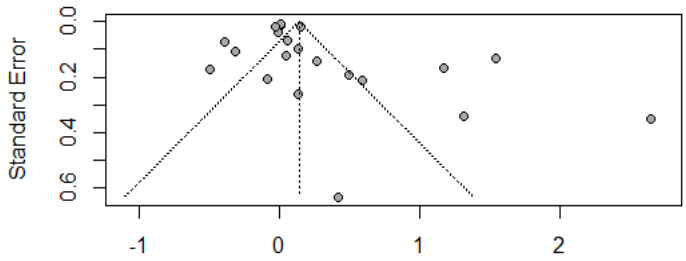


Figure 2: Diagrama de embudo

Conclusiones y trabajo futuro

Como señalan Turkeš, Sörensen and Hvattum (2021), la investigación en metaheurística se ha centrado en desarrollar métodos que resuelvan mejor los problemas de optimización, pero se ha desarrollado poco entendimiento de la razón del desempeño de los métodos y el aporte individual de los componentes. Su trabajo es el primer metaanálisis realizado en este campo de estudio. Las conclusiones de dicho estudio permiten ganar entendimiento relacionado con un camino deseable en la investigación en metaheurísticas, donde se ha reiterado recientemente que la verdadera innovación no se logra a partir de otro método que funcione mejor que sus competidores si no se comprende por qué el método funciona bien.

Por esta razón, como línea de investigación futura se espera utilizar la infraestructura computacional desarrollada en este trabajo para estudiar las metaheurísticas que utilizan post-optimización en la solución problemas de enrutamiento de vehículos con partición de conjuntos, trabajo que actualmente se encuentra en proceso.

References

Allaire, J. 2012. "RStudio: integrated development environment for R." *Boston, MA* 770(394):165–171.

Balduzzi, Sara, Gerta Rucker and Guido Schwarzer. 2019. "How to perform a meta-analysis with R: a practical tutorial." *Evidence-Based Mental Health* (22):153–160.

Crowther, Mark, Wendy Lim and Mark A Crowther. 2010. "Systematic review and meta-analysis methodology." *Blood, The Journal of the American Society of Hematology* 116(17):3140–3146.

Harrer, Mathias, Pim Cuijpers, Toshi Furukawa and David Daniel Ebert. 2019. *dmetar: Companion R Package For The Guide 'Doing Meta-Analysis in R'*. R package version 0.1.0.

Harrer, Mathias, Pim Cuijpers, Toshi Furukawa and David Ebert. 2021. *Doing meta-analysis with R: A hands-on guide*. Chapman and Hall/CRC.

R Core Team. 2019. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing.
URL: *https://www.R-project.org/*

Schryen, Guido and Martina Sperling. 2023. "Literature reviews in operations research: A new taxonomy and a meta review." *Computers & Operations Research* p. 106269.

Turkeš, Renata, Kenneth Sörensen and Lars Magnus Hvattum. 2021. "Meta-analysis of metaheuristics: Quantifying the effect of adaptiveness in adaptive large neighborhood search." *European Journal of Operational Research* 292(2):423–442.

Turkeš, Renata, Kenneth Sörensen, Lars Magnus Hvattum, Eva Barrena, Hayet Chentli, Leandro C Coelho, Iman Dayarian, Axel Grimault, Anders N Gullhav, Çağatay Iris et al. 2020. "Data for a meta-analysis of the adaptive layer in adaptive large neighborhood search." *Data in Brief* 33:106568.

Valentine, Jeffrey C, Therese D Pigott and Hannah R Rothstein. 2010. "How many studies do you need? A primer on statistical power for meta-analysis." *Journal of Educational and Behavioral Statistics* 35(2):215–247.

Viechtbauer, Wolfgang. 2010. "Conducting meta-analyses in R with the metafor package." *Journal of Statistical Software* 36(3):1–48.

Waring, Elin, Michael Quinn, Amelia McNamara, Eduardo Arino de la Rubia, Hao Zhu and Shannon Ellis. 2022. *skimr: Compact and Flexible Summaries of Data*. R package version 2.1.5.
URL: *https://CRAN.R-project.org/package=skimr*

Wickham, Hadley. 2016. *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York.
URL: *https://ggplot2.tidyverse.org*

Wickham, Hadley, Romain FranC'ois, Lionel Henry, Kirill MC<ller and Davis Vaughan. 2023. *dplyr: A Grammar of Data Manipulation*. R package version 1.1.3.
URL: *https://CRAN.R-project.org/package=dplyr*

Xie, Yihui, Christophe Dervieux and Emily Riederer. 2020. *R Markdown Cookbook*. Boca Raton, Florida: Chapman and Hall/CRC.
URL: *https://bookdown.org/yihui/rmarkdown-cookbook*

Estudio de simulación y análisis de la Distribución Discreta Invertida de Kumaraswamy. *

Daniel Felipe Villa Rengifo *Universidad Nacional de Colombia - sede Medellín*
Freddy Hernández *Universidad Nacional de Colombia - sede Medellín*

Resumen: En este estudio se ha investigado la Distribución Discreta Invertida de Kumaraswamy (*DIKUM*) utilizando datos reales y simulación. Se evaluó la idoneidad de *DIKUM* como modelo estadístico mediante ajuste de distribuciones. Se realizaron simulaciones con diferentes parámetros y tamaños de muestra, comparándolas con los datos reales. Los resultados respaldan las conclusiones del estudio original, demostrando la precisión de *DIKUM* en la representación de datos discretos asimétricos. Este estudio valida y aplica *DIKUM* en diversas áreas de estudio.

Keywords: pandoc, r markdown, knitr

Introducción

En la presente investigación, hemos explorado a fondo la Distribución Discreta Invertida de Kumaraswamy (*DIKUM*), empleando tanto datos reales como simulación. Nuestro enfoque se centró en evaluar la capacidad de la *DIKUM* como modelo estadístico, sometiéndola a un ajuste meticuloso mediante distribuciones. A través de simulaciones con variados parámetros y tamaños de muestra, contrastadas con datos reales, hemos validado la pertinencia y eficacia de la *DIKUM* en la representación de datos discretos asimétricos. Los resultados obtenidos refuerzan las conclusiones del estudio original, consolidando la posición de la *DIKUM* como un modelo preciso y aplicable en diversas áreas de investigación.

Objetivo

Investigar y validar la Distribución Discreta Invertida de Kumaraswamy (*DIKUM*) como un modelo estadístico preciso y aplicable, utilizando datos reales y simulación.

Distribución *DIKUM*

La Distribución Discreta Invertida de Kumaraswamy (*DIKUM*) (Hegazy et al., 2022) se origina a partir de la Distribución Invertida Kumaraswamy (*IKUM*) mediante un proceso de discretización. La *IKUM*, presentada por Abd AL-Fattah et al. (2017) (Al-Fattah, EL-Helbawy and Al-Dayian, 2017), representa una generalización del Pareto estándar de segundo tipo. La construcción de la *DIKUM* implica la aplicación de una agrupación en el eje del tiempo, resultando en una variable discreta dX que sigue una distribución *DIKUM* con dos parámetros, μ y σ.

*Autor de contacto: dvilla@unal.edu.co.

La función de masa de probabilidad (PMF) de la distribución *DIKUM* se define como:

$$p(x) = (1-(2+x)^{-\mu})^{\sigma} - (1-(1+x)^{-\mu})^{\sigma}, \quad x = 0,1,2,...;\ \mu,\sigma > 0, \tag{1}$$

donde x representa los posibles valores de la variable discreta X, variando en el rango de $x = 0,1,2,...$, y los parámetros μ y σ deben ser mayores que cero.

La distribución *DIKUM* exhibe una cola derecha larga en comparación con otras distribuciones comúnmente utilizadas. Esto sugiere que las predicciones de confiabilidad a largo plazo pueden ser optimistas para eventos raros que ocurren en la cola derecha de la distribución. No obstante, la *DIKUM* ha demostrado ajustarse adecuadamente a diversos conjuntos de datos en la literatura.

Su Función de Distribución Acumulativa (CDF) (Hegazy et al., 2022) está definida como:

$$F(x) = \left(1-(2+x)^{-\mu}\right)^{\sigma},\ x = 0,1,2,\ldots \tag{2}$$

A continuación se mostrarán algunas parametrizaciones de estas funciones,

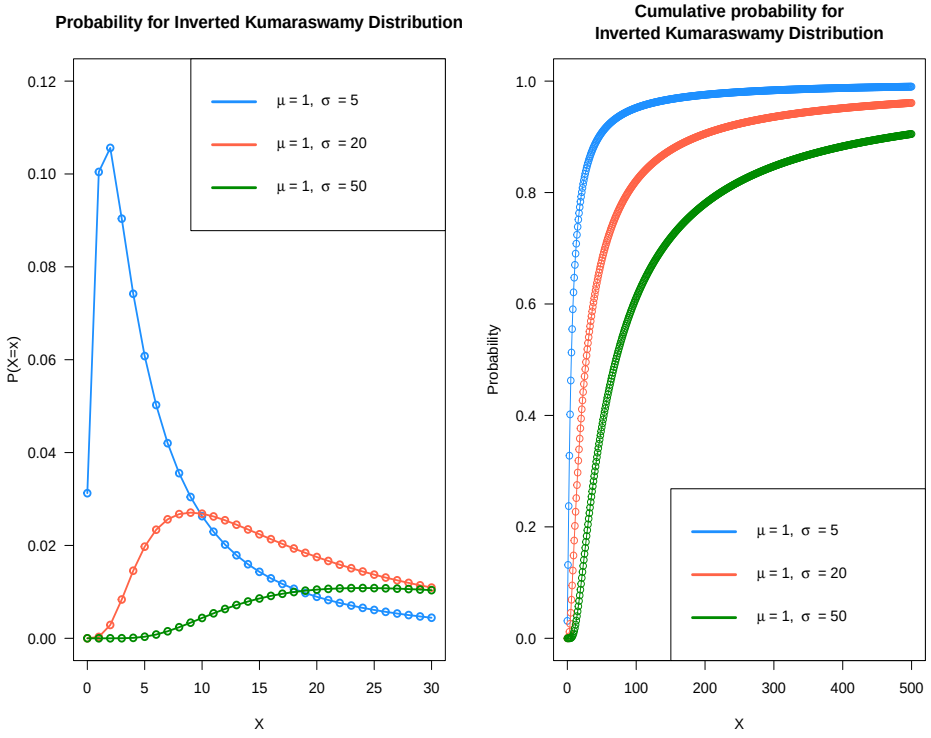


Figure 1: Distribución DIKUM (pmf & cdf) con diferentes parametrizaciones

Implementeaciones en `R`

Paquete `DiscreteDists`

La distribución Discreta Invertida de Kumaraswamy (*DIKUM*) se ha implementado de manera efectiva en el entorno R R Core Team (2019) mediante el siguiente código:

```
if (!require('devtools')) install.packages('devtools')
devtools::install_github('fhernanb/DiscreteDists', force=TRUE)
library(DiscreteDists)
```

Este paquete (Hernandez-Barajas et al., 2023) facilita la interacción con la distribución *DIKUM* a través de funciones específicas, como `dDIKUM()` para la densidad, `pDIKUM()` para la función de distribución acumulativa, `qDIKUM()` para el cuantil, `rDIKUM()` para la generación de números aleatorios, y `DIKUM()` para la familia de distribuciones. Estas funciones han sido sometidas a exhaustivas pruebas mediante diversos test visuales y estadísticos para asegurar su conformidad con los atributos característicos de la distribución *DIKUM*. Los usuarios pueden ahora beneficiarse de estas herramientas para explorar y trabajar con la *DIKUM* de manera flexible y confiable en el entorno R.

Estudio con datos reales

En este estudio, se examinó el tiempo de espera para la atención de pacientes con COVID-19 en un centro de salud. El enfoque central fue abordar la modelación y comprensión de la distribución de los tiempos de espera. Se optó por aplicar la Distribución Discreta Invertida de Kumaraswamy (*DIKUM*) con el propósito de contribuir a la mejora de la eficiencia y calidad de la atención médica. Cabe destacar que, aunque el estudio abarcó a 76 pacientes.

Table 1: Tiempo de espera de los pacientes con COVID-19

Paciente	Tiempo de Espera (en min.)
1	2
2	7
3	3
4	3
5	10
...	...
72	2
73	6
74	4
75	6
76	6

Se llevó a cabo una prueba de bondad de ajuste utilizando el test de Kolmogorov-Smirnov para evaluar la adecuación de los datos de los tiempos de espera a la distribución *DIKUM*. Se aplicaron distintos tamaños de muestra a partir de los 76 tiempos de espera de atención de pacientes con

COVID-19 para realizar la prueba.

Se eligieron tamaños de muestra específicos, $n = 20, 30, 50, 60, 70$. Para cada tamaño, se llevó a cabo una estimación de los parámetros de la distribución *DIKUM* mediante el método de máxima verosimilitud (MLE), repitiendo este proceso 1000 veces para cada tamaño de muestra.

Posteriormente, se calculó el estadístico de prueba D para cada repetición, representando la discrepancia entre la función de distribución empírica y teórica de la distribución *DIKUM*. Se obtuvieron valores promedio de D para cada tamaño de muestra, siendo estos 0.0922, 0.0553, 0.0419, 0.0409, y 0.0412.

El valor crítico D_α para el nivel de significancia deseado fue determinado como 0.1534. Al comparar los valores promedio de D con D_α, se llegó a la conclusión de que, para todos los tamaños de muestra, la prueba no rechaza la hipótesis nula. Esto sugiere que los datos se ajustan bien a la distribución *DIKUM*, respaldando así la elección de utilizar esta distribución para modelar los tiempos de espera de atención de pacientes con COVID-19 en el centro de salud.

En la aplicación del test de Kolmogorov-Smirnov para evaluar la adecuación de los datos de tiempo de espera de pacientes con COVID-19 a la distribución Discreta Invertida de Kumaraswamy (*DIKUM*), se llevaron a cabo exhaustivos ajustes. Se realizaron 1000 corridas para cada tamaño de muestra, buscando las estimaciones óptimas de los parámetros μ y σ. Los resultados de estos ajustes se reflejan de manera visual en el gráfico adjunto, donde se observa la variación de las estimaciones en función del tamaño de muestra. Tras un análisis detenido, se llegó a la conclusión de que los valores más óptimos para los datos de tiempo de espera de COVID-19 son $\mu = 2.5$ y $\sigma = 50$. Estas estimaciones proporcionan un ajuste robusto y preciso, respaldando así la elección de la distribución *DIKUM* para modelar los tiempos de espera en este contexto médico.

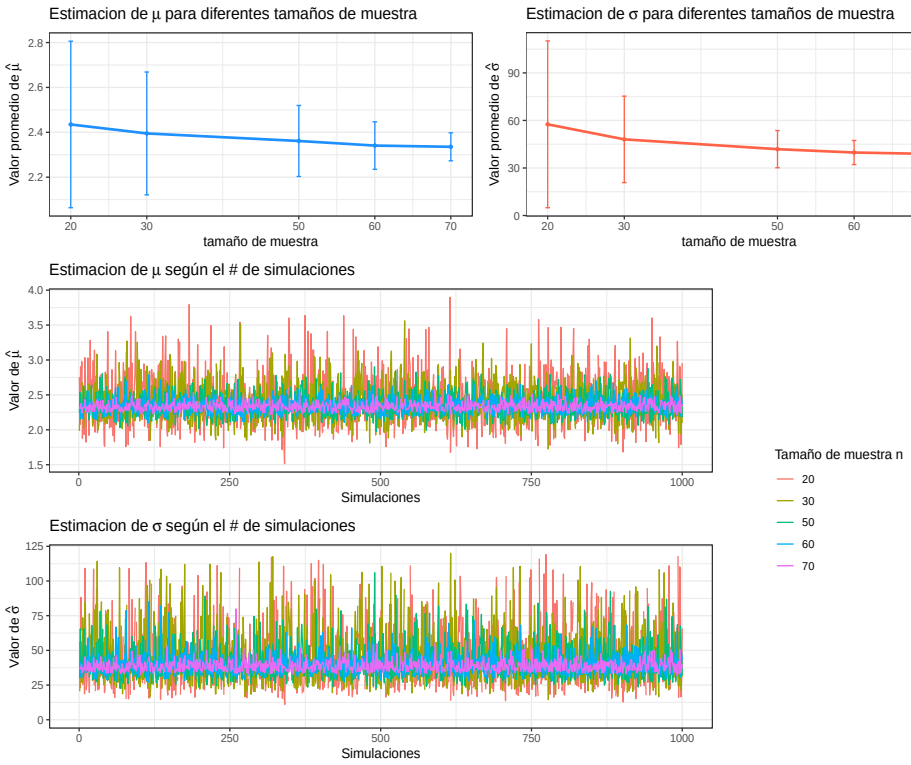


Figure 2: Estimaciones de μ y σ por medio de simulaciones

Conclusiones

En resumen, los resultados obtenidos a través del estudio de datos reales respaldan la eficacia del ajuste de los datos a la distribución *DIKUM*, validado mediante pruebas como el Kolmogorov-Smirnov, que confirma con un nivel de confianza del 95% la idoneidad de la distribución para representar adecuadamente el conjunto de datos. Aunque estos hallazgos son alentadores para la optimización de decisiones en situaciones similares, se reconoce la necesidad de realizar pruebas estadísticas adicionales y un análisis más exhaustivo para garantizar la fiabilidad y precisión integral de los modelos en relación con los datos reales.

References

Al-Fattah, A.M., Abeer EL-Helbawy and Gannat Al-Dayian. 2017. "Inverted Kumaraswamy distribution: Properties and estimation." 33:37–61.

Hegazy, M., R. Abd EL-Kader, G. AL-Dayian and A.A.-A. EL-Helbawy. 2022. "Discrete Inverted Kumaraswamy Distribution: Properties and Estimation." *Pakistan Journal of Statistics and Operation Research* 18(1):297–328.
URL: *https://doi.org/10.18187/pjsor.v18i1.3634*

Hernandez-Barajas, Freddy, Fernando Marmolejo-Ramos, Jamiu Olumoh and Osho Ajayi. 2023. *DiscreteDists: Discrete statistical distributions*. R package version 0.0.0.9000.

R Core Team. 2019. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing.
URL: *https://www.R-project.org/*

Métodos de selección de variables en R para incrementar el poder discriminatorio del Análisis Envolvente de Datos (DEA) *

Andrés Mauricio Gómez *Universidad de Antioquia*
Andrés Mauricio Villegas *Universidad de Nueva Gales del Sur*
Juan Guillermo Villegas *Universidad de Antioquia*

Resumen: El análisis envolvente de datos (DEA) es una técnica no paramétrica muy utilizada en la medición de la eficiencia relativa. Sin embargo, esta no proporciona pautas claras para la selección de las variables. En este trabajo se presenta un estudio comparativo de DEA combinado con técnicas estadísticas para robustecer sus estimaciones y evitar los criterios ad hoc o juicios particulares en la elección de las variables de entrada y salida que se incluyen en los modelos de DEA. Para ello, se implementó en el lenguaje R la combinación de DEA con Análisis de Componentes Principales, Regresión Lasso y un heurístico de búsqueda iterativa. En particular, se usaron las librerías de R: `stats`, `benchmarking`, `glmnet`, `roi` y `ompr`. El desempeño de DEA se midió en función de la diversificación en la clasificación de las unidades productoras evaluadas (denominadas DMU), garantizando la mayor retención en la varianza total de los datos.

Palabras claves: Análisis envolvente de datos, Selección de variables, Problema de dimensionalidad, Medición del desempeño

Introducción

El análisis envolvente de datos (DEA) es una herramienta popular de los métodos cuantitativos para la toma de decisiones, que mide el desempeño relativo de un conjunto de unidades productoras (DMUs) con múltiples métricas de valoración (entradas y salidas de sus procesos productivos). Sin embargo, el número inicial de variables incluidas en un modelo DEA suele ser muy grande, y la formulación de DEA no proporciona pautas objetivas para la selección de entradas y salidas (Villanueva-Cantillo y Munoz-Marquez, 2021). Por lo cual, los problemas de discriminación entre DMUs eficientes e ineficientes a menudo surgen cuando hay un número relativamente grande de medidas de desempeño (variables) en comparación con el número de DMU; esto puede llevar a que las unidades eficientes se clasifiquen incorrectamente como ineficientes y las unidades ineficientes se clasifiquen erróneamente como eficientes (Charles, Aparicio, y Zhu, 2019).

Así mismo, Liu, Lu, y Lu (2016) en su estudio sobre los frentes de investigación en DEA, identificaron que la selección de variables era una subárea de investigación sólida en la literatura de DEA. Aunque en la metodología de aplicación de DEA se contempla la utilización de reglas ad hoc para la selección de variables de entrada y salida, no es un procedimiento sistemático lo cual deja en manos del tomador de decisiones la elección de las variables. Estas reglas carecen de medidas cuantitativas que indiquen el impacto que tiene la eliminación de variables tanto en el desempeño de las DMU como en la retención de información de los datos originales (Dyson y cols., 2001) (Cook, Tone, y Zhu, 2014).

En consecuencia, existen estudios que se han enfocado en mejorar el poder discriminatorio de DEA, algunos con la intención de aumentar el número de DMUs y conservar el mismo número de variables, usando datos de corte transversal y series de tiempo (Charles y cols., 2019). En cambio, otros han incorporado técnicas estadísticas como el análisis de covarianza parcial (Jenkins y Anderson, 2003), o análisis de componentes principales combinado con DEA (Adler y Golany, 2002), con el objetivo de reducir el número de variables utilizadas pero conservando el mismo número de DMUs.

Metodología

Con el fin de ilustrar el desempeño de estas aproximaciones tanto estadísticas como heurísticas, descritas anteriormente, usaremos un conjunto de datos existente en la literatura, reportados en los trabajos de Wong y Beasley (1990) y Adler y Golany (2002) para presentar sus resultados. En esta ilustración numérica, se comparan siete DMUs (facultades universitarias) con tres variables de insumos (número de docentes, salarios de los docentes, número de empleados

*Autor de contacto: andres.gomez8@udea.edu.co

administrativos) y tres variables de salida (número de estudiantes de pregrado, número de estudiantes de posgrado, y cantidad de artículos publicados), como puede verse en la Tabla 1.

Tabla 1: Datos DEA – Facultades universitarias

	Entradas (Inputs)			Salidas (Outputs)		
DMU	**I1** Empleados Docentes	**I2** Salarios Docentes	**I3** Empleados Administrativos	**O1** Estudiantes de pregrado	**O2** Estudiantes de posgrado	**O3** Publicaciones (Artículos)
DMU1	12	400	20	60	35	17
DMU2	19	750	70	139	41	40
DMU3	42	1500	70	225	68	75
DMU4	15	600	100	90	12	17
DMU5	45	2000	250	253	145	130
DMU6	19	730	50	132	45	45
DMU7	41	2350	600	305	159	97

En este trabajo se realiza la combinación de DEA con: (a) el análisis de componentes principales (PCA); (b) la regularización de variables con Regresión Lasso y (c) una aproximación heurística, basada en la eliminación iterativa de variables, tanto de entrada como de salida. Esto con el propósito de mejorar el poder discriminatorio de los modelos de DEA.

(a). PCA – DEA

Como un número excesivo de variables en un modelo DEA provoca en los resultados una gran cantidad de unidades eficientes, es preferible mantener baja la relación entre el número de entradas y salidas con respecto al número de DMU, y para tal fin Adler y Golany (2001) usaron el Análisis de Componentes Principales (PCA) con el propósito de agregar entradas o salidas, con una pérdida mínima de información, desarrollando una nueva formulación del modelo DEA, denominada PCA–DEA.

Se implementó en R (R Core Team, 2021) el modelo aditivo de DEA combinado con PCA presentado por Adler y Golany (2002) (véase la Ecuación 1), con la ayuda de la función `prcomp::stats` (R Core Team, 2021) para el análisis de componentes principales, así como de las librerías `ROI` (Theußl, Schwendinger, y Hornik, 2020) y `ompr` (Schumacher, 2023) encargadas de la infraestructura de optimización en R. Esta formulación para la estimación de eficiencia de la DMU_a $(z = 1, 2, 3, ..., n;\ n =$ número de DMUs), agrega las variables originales y las variables transformadas por las componentes principales para las entradas $(X = \{X_o, X_{Lx}\})$ y salidas $(X = \{Y_o, Y_{Ly}\})$, donde X_o (Y_o) representa las entradas (salidas) de las variables originales, mientras que X_{Lx} (Y_{Ly}) las variables de entrada (salida) transformadas por PCA. Así mismo, L_x (L_y) representa la matriz de ponderaciones para las entradas (salidas) obtenidos con PCA, con la cual, $X_{pc} = L_x X_{Lx}$ y $X_{pc} = L_y Y_{Ly}$.

$$
\begin{aligned}
\underset{s_o, \sigma_o, s^+_{pc}, s^-_{pc}, \sigma^+_{pc}, \sigma^-_{pc}}{\text{Minimizar}} \quad & -e^T s_o - e^T L'^{-1}(s^+_{pc} - s^-_{pc}) - e^T \sigma_o - e^T L'^{-1}(\sigma^+_{pc} - \sigma^-_{pc}) \\
\text{Sujeto a:} \quad & Y_o\lambda - s_o = Y^a_o \\
& Y_{pc}\lambda - (s^-_{pc} - s^+_{pc}) = Y^a_{pc} \\
& -X_o\lambda - \sigma_o = -X^a_o \\
& -X_{pc}\lambda - (\sigma^-_{pc} - \sigma^+_{pc}) = -X^a_{pc} \\
& L_y^{-1}(s^-_{pc} - s^+_{pc}) \geq 0 \\
& L_x^{-1}(\sigma^-_{pc} - \sigma^+_{pc}) \geq 0 \\
& \lambda, s_o, \sigma_o, s^+_{pc}, s^-_{pc}\sigma^+_{pc}, \sigma^-_{pc} \geq 0
\end{aligned}
\tag{1}
$$

Aquí, las holguras para determinar las ineficiencias están dadas para las entradas (σ_o) y salidas (s_o) originales, como para las variables transformadas $(\sigma^+_{pc}, \sigma^-_{pc}, s^+_{pc}, s^-_{pc})$, como variables auxiliares no negativas. Con el propósito de traducir los resultados del modelo adictivo, el cual arroja resultados entre $[0, \infty)$ (donde una holgura igual a cero significa ser eficiente), en un intervalo $[0, 1]$, se usa la propuesta por Adler y Volta (2019) para la comparación con otros modelos.

(b). Lasso – DEA

Lasso (*Least Absolute Shrinkage and Selection Operator - Lasso*) pretende seleccionar un modelo de menor dimensión, llevando a cero el efecto estimado de algunas variables mediante la incorporación de un coeficiente de regularización o penalización al problema original, usualmente por mínimos cuadrados (Tibshirani, 1996). Esta regularización ayuda a minimizar el error de predicción del modelo, haciéndolo más parsimonioso y fácil de explicar. Este método es popular cuando la dimensión del problema es mayor que el tamaño de la muestra (Chen, Tsionas, y Zelenyuk, 2021).

Para esta aproximación se usó la librería `Benchmarking` (Bogetoft y Otto, 2020) para el cálculo de eficiencia de los modelos, y de manera conjunta `glmnet` (Friedman, Tibshirani, y Hastie, 2010) para la selección de variables. Aquí, las variables independientes eran las métricas de valoración (entradas y salidas del proceso) y la variable dependiente era la estimación de eficiencia, e iterativamente tras la regularización Lasso, se depuraba una a una las variables, creando diferentes modelos parsimoniosos que permitieran identificar las DMUs con mejor desempeño en el grupo evaluado.

(c). ISA – DEA

Finalmente, se realizó la comparación con una propuesta heurística para la selección de características, tanto de entrada como de salida, basada en la eliminación iterativa de variables (Iterative Search Algorithm, ISA-DEA). La metodología propuesta elige en cada iteración la configuración de variables donde se maximiza una métrica de impureza (índice Gini o entropía) de las eficiencias de las DMU, proporcionando así un conjunto de modelos seleccionados por índices estadísticos de dispersión (Gómez Ardila, Villegas Ramírez, y Villegas Ramírez, 2021).

Resultados

Como punto de partida, al aplicar DEA con todas las variables para las siete unidades productoras, se encuentra que la DMU_4 es la única ineficiente (véase la Tabla 2). A continuación, se presentan los resultados de las técnicas PCA-DEA, Lasso-DEA e ISA-DEA, las cuales buscan mejor la clasificación de eficiencia en DEA.

Tabla 2: Puntajes de eficiencia con DEA con todas las variables

Puntajes de eficiencia (DMU eficiente= 1, DMU ineficiente ∈ (0,1))							
DMU	DMU1	DMU2	DMU3	DMU4	DMU5	DMU6	DMU7
Puntaje	1	1	1	0.820	1	1	1

Se aplico la técnica de PCA-DEA, con la formulación de la Ecuación 1 para todas las posibles configuraciones de componentes principales, con el objetivo de abarcar todo el espectro en la reducción de dimensionalidad y su impacto en la estimación de eficiencia. Para los nueve posibles modelos evaluados, se presentan en la Tabla 3 las métricas de impureza (Gini para la eficiencia, la ineficiencia y el ponderado) (Gómez Ardila y cols., 2021), la cantidad y la proporción de DMUs eficientes, las varianzas retenidas para las entradas y salidas (métricas propias de PCA), y la varianza retenida por el total de variables (usando la Covarianza Parcial de Jenkins y Anderson (2003))).

Tabla 3: Métricas de impureza y varianza retenida para los modelos con PCA-DEA

Modelo	Componentes Principales		Gini	Gini	Gini	DMUs	% DMUs	Varianza Retenida		
	Entradas (CPi)	Salidas (CPo)	Eficiencia	Ineficiencia	Ponderado	Eficientes	Eficientes	Entradas	Salidas	Total
PCA_DEA_1	3	3	0.0412	0.7500	0.3956	6	85.7 %	1.0000	1.0000	1.0000
PCA_DEA_2	3	2	0.0398	0.7500	0.3949	6	85.7 %	1.0000	0.9755	1.0000
PCA_DEA_3	3	1	0.0363	0.5546	0.2955	3	42.9 %	1.0000	0.9456	1.0000
PCA_DEA_4	2	3	0.1036	0.5663	0.3349	4	57.1 %	0.9995	1.0000	1.0000
PCA_DEA_5	2	2	0.1010	0.5638	0.3324	4	57.1 %	0.9995	0.9755	0.9728
PCA_DEA_6	2	1	0.0673	0.2255	0.1464	1	14.3 %	0.9995	0.9456	0.9122
PCA_DEA_7	1	3	0.1253	0.5431	0.3342	4	57.1 %	0.8679	1.0000	0.9839
PCA_DEA_8	1	2	0.1204	0.4907	0.3056	2	28.6 %	0.8679	0.9755	0.8893
PCA_DEA_9	1	1	0.0803	0.2167	0.1485	1	14.3 %	0.8679	0.9456	0.7882

Resulta claro que al utilizar menos componentes principales, la varianza retenida disminuye, y se evidencia en la Tabla 3 como esto tiene un impacto en la reducción de DMUs estimadas como eficientes, pasando de un 85.7 % a 14.3 % de DMUs eficientes entre el PCA_DEA1 y el PCA_DEA9 , modelos con la máxima y mínima retención de varianza respectivamente.

Por otra parte, tras emplear la regresión Lasso en la búsqueda de aquellas variables que mejor explican la eficiencia, se evidencia en la Tabla 4 el resultado de la penalización Lasso sobre todas las variables disponibles (entradas y salidas), y al igual que en el ejercicio anterior, se calcular las métricas de impureza y la covarianza parcial para cada uno de los modelos, con el propósito de unificar los resultados de las diferentes técnicas presentes en este trabajo.

Tabla 4: Métricas de impureza y varianza retenida para los modelos con Lasso-DEA

Modelo	λ	Varibles						Gini	Gini	Gini	DMUs	% DMUs	Varianza Retenida		
		I1	I2	I3	O1	O2	O3	Eficiencia	Ineficiencia	Ponderado	Eficientes	Eficientes	Entradas	Salidas	Total
LASSO_DEA$_1$	0	✓	✓	✓	✓	✓	✓	0.0198	0.7500	0.3849	6	85.7 %	1.0000	1.0000	1.0000
LASSO_DEA$_2$	0.0012	✓	✓	✓	✓	✓		0.0198	0.7500	0.3849	6	85.7 %	1.0000	0.9602	1.0000
LASSO_DEA$_3$	0.0021	✓	✓		✓	✓	✓	0.0334	0.6274	0.3304	5	71.4 %	0.9958	1.0000	1.0000
LASSO_DEA$_4$	0.0037		✓	✓	✓	✓	✓	0.0334	0.6368	0.3351	5	71.4 %	0.9983	1.0000	1.0000
LASSO_DEA$_5$	0.0095			✓	✓	✓	✓	0.2400	0.4161	0.3281	2	28.6 %	0.6955	1.0000	0.9920
LASSO_DEA$_6$	0.0115			✓	✓		✓	0.2426	0.3898	0.3162	1	14.3 %	0.6955	0.9631	0.9879
LASSO_DEA$_7$	0.0429			✓	✓			0.2629	0.3773	0.3201	1	14.3 %	0.6955	0.8913	0.9435
LASSO_DEA$_8$	0.0518	✓		✓	✓			0.0435	0.5863	0.3149	4	57.1 %	0.9992	0.8913	0.9649
LASSO_DEA$_9$	0.0754	✓			✓			0.0719	0.3742	0.2230	1	14.3 %	0.7515	0.8913	0.9222

En la Tabla 4 se resumen los modelos para cada λ de penalización para el cual se dio una cambio en la configuración de variables, es decir, la inclusión u omisión de alguna variable. Por ejemplo, el LASSO_DEA$_1$ tiene un $\lambda = 0$ para el cual se marca que se usaron todas las variables. Entre las nueve configuraciones de variables, se encuentran que los índices Gini para la eficiencia más altos son 0.2400, 0.2426 y 0.2629, y corresponden al LASSO_DEA$_5$, LASSO_DEA$_6$ y LASSO_DEA$_7$, respectivamente, en los cuales se logra obtener una reduccción en el porcentaje de DMUs eficientes por debajo al 28.5 %.

En cuanto a los resultados del algoritmo heurístico (ISA-DEA), tras realizar la búsqueda iterativa de modelos orientada por la maximización del "Gini ponderado" ($GiniPonderado = \alpha(GiniEficiencia) + (1 - \alpha)(GiniIneficiencia)$) propuesto por Gómez Ardila y cols. (2021) para diferentes ponderaciones con valores de λ entre [0, 1], se identifican siete modelos con métricas únicas después de omitir los resultados para aquellos λ donde no se presentó un cambio en los resultados.

Tabla 5: Métricas de impureza y varianza retenida para los modelos con ISA-DEA

Modelo	α	Variables						Gini	Gini	Gini	DMUs	% DMUs	Varianza Retenida		
		I1	I2	I3	O1	O2	O3	Eficiencia	Ineficiencia	Ponderado	Eficientes	Eficientes	Entradas	Salidas	Total
ISA_DEA$_1$	0	✓		✓	✓	✓	✓	0.0202	0.7500	0.7500	6	85.7 %	0.9992	1.0000	1.0000
ISA_DEA$_2$	0.02	✓		✓	✓	✓		0.0202	0.7500	0.7354	6	85.7 %	0.9992	0.9602	0.9954
ISA_DEA$_3$	0.46	✓		✓		✓		0.1636	0.5062	0.3486	3	42.9 %	0.9992	0.8998	0.9903
ISA_DEA$_4$	0.49			✓		✓	✓	0.2661	0.4108	0.3399	2	28.6 %	0.6955	0.9565	0.9660
ISA_DEA$_5$	0.62			✓			✓	0.2662	0.3470	0.2969	1	14.3 %	0.6955	0.8957	0.9553
ISA_DEA$_6$	0.68			✓		✓		0.3201	0.2339	0.2925	1	14.3 %	0.6955	0.8998	0.9129
ISA_DEA$_7$	0.93	✓				✓		0.1945	0.3240	0.2036	1	14.3 %	0.7515	0.8998	0.9359

Como se ha mencionado y expuesto en todo el documento, la importancia de la selección de variables es crucial en DEA, sobre todo bajo criterios objetivos, por ello para las tres metodologías en la Tabla 6 se presentan solo aquellos modelos donde la métrica de impureza es máxima y los que son aptos bajo la mirada de las reglas empíricas. Esta regla busca que la relación entre la cantidad de variables y unidades de evaluación esté en el rango $[\frac{1}{3}, \frac{1}{2}]$.

Tabla 6: Modelos sugeridos con PCA-DEA, LASSO-DEA e ISA-DEA

Modelo	Gini Eficiencia	Gini Ineficiencia	Gini Ponderado	DMUs Eficientes	% DMUs Eficientes	Varianza Retenida
PCA_DEA$_7$	0.1253	0.5431	0.3342	4	0.571	0.9839
PCA_DEA$_7$	0.1204	0.4907	0.3056	2	0.286	0.8893
LASSO_DEA$_7$	0.2629	0.3773	0.3201	1	0.143	0.9435
LASSO_DEA$_8$	0.0435	0.5863	0.3149	4	0.571	0.9646
ISA_DEA$_3$	0.1636	0.5262	0.3486	3	0.429	0.9903
ISA_DEA$_4$	0.2661	0.4108	0.3399	2	0.286	0.966
ISA_DEA$_6$	0.3201	0.2339	0.2925	1	0.143	0.9129

Como resultado general, se evidencia que los modelos sugeridos por la metodología propuesta (ISA-DEA) presentan las mejores valoraciones, considerando las métricas trasversales anteriormente mencionadas, e independientemente de las particularidades metodológicas de cada técnica, ya sea la sustitución de los datos por nuevas variables no correlacionadas o la identificación de unas cuantas variables con la mayor relación ante una variable independiente

(en este caso la estimación de eficiencia con DEA). El ISA_DEA3 e ISA_DEA4 con valores de α de 0.46 y 0.49 respectivamente, obtienen los valores más altos para el Gini Ponderado y de varianza explicada (véase la Tabla 6), con los cuales se logra disminuir considerablemente el porcentaje de DMUs clasificadas como eficientes, usando la mitad de las variables iniciales.

En definitiva, el ISA_DEA3 es el de mejor rendimiento, ya que reduce del 85.7 % al 42.9 % el número de DMUs clasificadas como eficientes, con tan solo la selección del 50 % de las variables iniciales. Este modelo usa dos insumos (I1: Empleados Docentes, e I3: Empleados Administrativos) y un producto (O2: Estudiantes de posgrado) en la estimación de eficiencia de las siete facultades universitarias (DMUs), variables con las cuales se explica el 99.03 % de la varianza total de los datos.

Conclusiones

En este trabajo se ilustra el problema de dimensionalidad presente en DEA ante la modelación con muchas variables de entrada y salida, y pocas DMUs, donde es alta la probabilidad de clasificar una DMU como eficiente cuando no lo es. Resulta claro que cada metodología tiene sus bondades y desventajas, como por ejemplo el PCA que aprovecha todas las variables y las sintetiza por medio de combinaciones lineales no correlacionadas, de ahí que este enfoque combinado con DEA resulte una alternativa muy beneficiosa para la solución de la maldición de la dimensionalidad. Sin embargo, con respecto a las otras aproximaciones como Lasso-DEA e ISA-DEA, con PCA-DEA no se puede identificar de forma directa cuáles variables están impactando el modelo. Estas otras aproximaciones indican las variables usadas y omitidas en cada modelo, lo cual le permite al analista de información ver exploratoriamente que variables son más relevantes y contrastarlo con su experticia y conocimiento acerca del sector estudiado.

Los resultados en este estudio permiten determinar, dada una configuración de variables y bajo cualquiera de las tres aproximaciones, el nivel de entropía o grado de desigualdad de los puntajes de eficiencia (índice Gini). Además, se indica la varianza explicada para los modelos elegidos en cada iteración, lo cual resulta relevante para el entendimiento del sacrificio en la eliminación de variables en función de aumentar el poder discriminatorio de DEA.

Referencias

Adler, N., y Golany, B. (2001). Evaluation of deregulated airline networks using data envelopment analysis combined with principal component analysis with an application to western europe. *European Journal of Operational Research*, *132*(2), 260–273.

Adler, N., y Golany, B. (2002). Including principal component weights to improve discrimination in data envelopment analysis. *Journal of the Operational Research Society*, *53*(9), 985–991.

Adler, N., y Volta, N. (2019). Ranking methods within data envelopment analysis. En *The palgrave handbook of economic performance analysis* (pp. 189–224). Springer.

Bogetoft, P., y Otto, L. (2020). Benchmarking with dea and sfa [Manual de software informático]. (R package version 0.29)

Charles, V., Aparicio, J., y Zhu, J. (2019). The curse of dimensionality of decision-making units: A simple approach to increase the discriminatory power of data envelopment analysis. *European Journal of Operational Research*, *279*(3), 929–940.

Chen, Y., Tsionas, M., y Zelenyuk, V. (2021). Lasso+ dea for small and big wide data. *Omega*, 102419.

Cook, W. D., Tone, K., y Zhu, J. (2014). Data envelopment analysis: Prior to choosing a model. *Omega*, *44*, 1–4.

Dyson, R. G., Allen, R., Camanho, A. S., Podinovski, V. V., Sarrico, C. S., y Shale, E. A. (2001). Pitfalls and protocols in dea. *European Journal of operational research*, *132*(2), 245–259.

Friedman, J., Tibshirani, R., y Hastie, T. (2010). Regularization paths for generalized linear models via coordinate descent. *Journal of Statistical Software*, *33*(1), 1–22. doi: 10.18637/jss.v033.i01

Gómez Ardila, A., Villegas Ramírez, A., y Villegas Ramírez, J. (2021). Método heurístico de selección de variables para el incremento del poder discriminatorio de dea: caso de aplicación a las eps colombianas. *XXX Simposio Internacional de Estadística 2021 - Evento virtual*, 183–190.

Jenkins, L., y Anderson, M. (2003). A multivariate statistical approach to reducing the number of variables in data envelopment analysis. *European Journal of Operational Research*, *147*(1), 51–61.

Liu, J. S., Lu, L. Y., y Lu, W.-M. (2016). Research fronts in data envelopment analysis. *Omega*, *58*, 33–45.

R Core Team. (2021). R: A language and environment for statistical computing [Manual de software informático]. Vienna, Austria. Descargado de https://www.R-project.org/

Schumacher, D. (2023). ompr: Model and solve mixed integer linear programs [Manual de software informático]. Descargado de https://github.com/dirkschumacher/ompr (R package version 1.0.4.9000)

Theußl, S., Schwendinger, F., y Hornik, K. (2020). Roi: An extensible r optimization infrastructure. *Journal of Statistical Software*, *94*(15), 1–64. Descargado de https://www.jstatsoft.org/index.php/jss/article/view/v094i15 doi: 10.18637/jss.v094.i15

Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, *58*(1), 267–288.

Villanueva-Cantillo, J., y Munoz-Marquez, M. (2021). Methodology for calculating critical values of relevance measures in variable selection methods in data envelopment analysis. *European Journal of Operational Research*, *290*(2), 657–670.

Wong, Y.-H., y Beasley, J. (1990). Restricting weight flexibility in data envelopment analysis. *Journal of the Operational Research Society*, *41*(9), 829–835.

Implementación de la distribución Burr Hatke para evaluar el proceso de estimación de parámetros en datos sobre dispersos *

Valentina Hurtado Sepúlveda *Universidad Nacional de Colombia - sede Medellín*
Freddy Hernández Barajas *Universidad Nacional de Colombia - sede Medellín*

Resumen: En áreas del conocimiento como la medicina o ingeniería, existen conjuntos de datos que no se pueden modelar con distribuciones tradicionales. En modelación de datos discretos, lo usual es emplear la distribución Poisson, sin embargo, al tener varianza igual a su media (equidispersión), podría representar un limitante a la hora de analizarlos. Se estudia la distribución Burr Hatke (DBH), con varianza mayor a su media, propiedad útil para modelar datos excesivamente dispersos. En el presente estudio, se implementó Burr-Hatke (DBH) en el paquete DiscreteDists de R y se llevó a cabo un estudio de simulación para evaluar el proceso estimación de parámetros. Se realizó una aplicación con datos reales, donde se ponen a competir, resultando que el mejor ajuste fue el de la distribución DBH frente a la PO. Es así como su implementación resultaría de gran importancia para llevar a cabo posteriores estudios académicos.

Keywords: Distribución Burr-Hatke, Simulación estadística, Estimación de parámetros, Lenguaje de programación R

1. Introducción

Los datos se manifiestan de múltiples formas, y la estadística es el área encargada de crear y fomentar nuevas herramientas para el tratamiento e interpretación de datos. Desde la academia es importante estar al tanto de las nuevas distribuciones que van surgiendo. El tratamiento de datos discretos típicamente se ha modelado con la distribución Poisson (PO), sin embargo, al ser equidispersa, resulta más conveniente hacer uso de nuevas distribuciones alternas. La distribución Burr-Hatke (DBH) es adecuada para modelar datos sobredispersos, sin embargo, para fines prácticos no era posible usarla, es por esto que en este trabajo se implementó dicha distribución en el paquete DiscreteDists de R con el fin de tenerla a disposición en posteriores investigaciones. Adicionalmente se realizó un estudio de simulación para evaluar el proceso de estimación de parámetros y un pequeño ejemplo con datos reales donde se usó los modelos gamlss por su gran flexibilidad. Este documento está estructurado de la siguiente manera: en la sección 2, revisión de la distribución discreta Burr-Hatke y su implementación en R a través del paquete DiscreteDists. La sección 3 presenta el estudio de simulación, en la sección 4 los resultados, en la sección 5, se ilustra la aplicación de la distribución DBH vs PO con el modelo gamlss en un contexto específico, con el fin de destacar su desempeño en situaciones prácticas.

2. Metodología e implementación

- Crear funciones para implementar la distribución bajo estudio (DBH) en R

*Autor de contacto: vhurtados@unal.edu.co.

- Analizar el proceso de estimación de parámetros a través de dos modelos: con covariables y sin covariables.
- Comparar dos modelos gamlss con datos reales.

Distribución Burr-Hatke

La DBH fue introducida por Maniu & Voda, 2008. Tiene un parámetro μ, y su función de masa de probabilidad (f.m.p) y función de densidad acumulada (f.d.a) está dada por

$$f(x;\mu) = \left(\frac{1}{x+1} - \frac{\mu}{x+2}\right)\mu^x$$

$$F(x;\mu) = 1 - \frac{\mu^{x+1}}{x+2}$$

donde, $0 < \mu < 1$ y $x \in \mathbb{N}_0$

Implementación

Para llevar a cabo la implementación de la DBH se crearon las siguienets funciones: función de densidad de probabilidad, función de densidad acumulada, función quantil y la generadora de números aleatorios. Se pueden encontar de la siguiente manera:

```
dDBH()  # Densidad
pDBH()  # P(X<=x)
qDBH()  # Cuantil
rDBH()  # Generador de números aleatorios
 DBH()  # Familia
```

Ejemplo

```
library(DiscreteDists)  # To use the DBH family
library(gamlss)    # To use gamlss

set.seed(190)
y <- rDBH(n=1000, mu=0.74)

mod <- gamlss(y~1, family=DBH,
              control=gamlss.control(n.cyc=500, trace=FALSE)) # To fit the model

inv_logit <- function(x) exp(x) / (1+exp(x)) # using the inverse link function
inv_logit(coef(mod, what='mu')) # Extracting the fitted values for mu
```

```
## (Intercept)
##   0.7429384
```

3. Estudio de Simulación

Se llevó a cabo un estudio de simulación Monte Carlo donde se consideraron dos casos: "con covariables" y "sin covariables". Las medidas para evaluar el rendimiento del procedimiento de estimación de un parámetro θ, fueron el valor medio y el error cuadrático medio (MSE) del estimador $\hat{\theta}$, definidos respectivamente

$$Mean = \frac{\sum_{i=1}^{i=k} \hat{\theta}_i}{k}$$

$$MSE = \frac{\sum_{i=1}^{i=k} (\hat{\theta}_i - \theta)^2}{k}$$

donde k representa el núero de estimaciones para θ.

La metodología para los casos analizados en el estudio de simulación es la siguiente.

- Caso 1: Simulación sin covariables

  En este caso, se analizó el comportamiento asintótico del parámetro estimado $\hat{\mu}$ simulando datos de una distribución $DBH(\mu = 0.416)$ considerando diferentes tamaños de muestra $n = 10, 20, ..., 300$.

$$y_i \sim DBH(\mu)$$
$$\mu = 0.416$$

- Caso 2: Simulación con covariables

  En el segundo caso, se analizó el comportamiento asintótico de los coeficientes estimados β_0 y β_1 del modelo de regresión DBH, considerando diferentes tamaños de muestra $n = 10, 20, ..., 300$. Los datos se generan del siguiente modelo:

$$y_i \sim DBH(\mu_i)$$
$$logit(\mu_i) = \beta_0 + \beta_1 \times X_{1i}$$
$$X_1 \sim U(0, 1)$$

  El vector de parámetros en este caso fue $\theta = (\beta_0 = 1.064, \beta_1 = -0.7)^\top$. Del modelo (4) se tiene que $X_1 \sim U(1, 0)$, lo cual implica que $E(X_1) = 0.5$, entonces $\mu = \exp(0.335 - 0.012(0.5))/(1 + \exp(0.335 - 0.012(0.5)) = 0.416$.

4. Resultados

Se presenta la media y el MSE con el fin de explorar la evolución del parámetro estimado. La figura 1 muestra los reultados del modelo sin covariables, y las figuras 2 y 3 las del modelo con covariables:

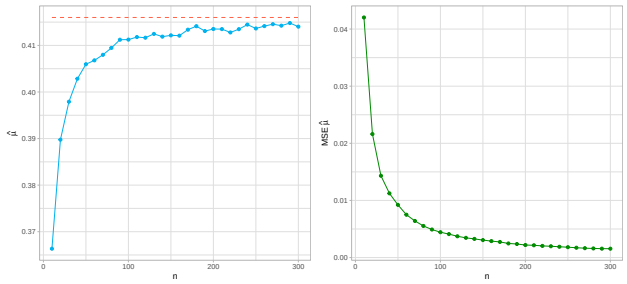


Figure 1: A la izquierda, el promedio de los parámetros estimados $\hat{\mu}$ versus n. La línea roja corresponde al valor real $\mu = 0.416$. A la derecha, el error cuadrático medio para los parámetros estimados $\hat{\mu}$ versus n.

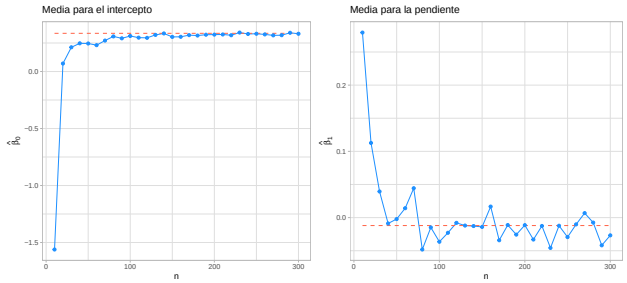


Figure 2: Promedio de los parámetros estimados $\hat{\beta}_0$ y $\hat{\beta}_1$ versus n. La línea roja corresponde al valor objetivo.

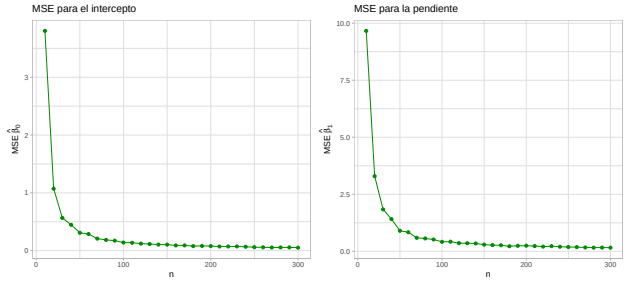


Figure 3: Error cuadrático medio para la estimación de parámetros β_0 y β_1 versus n.

5. Aplicación

En esta sección se presentan resultados de la implementación de modelos GAMLSS con la base de datos "Doctor'' del paquete `Ecdat` para explicar el número de visitas al médico (y) usando como covariables children (número de niños en el hogar) y health (estado de salud) para dos modelos: DBH y PO. Se utiliza como medida de comparación el criterio de información Akaike (AIC) (Akaike, 1973), para medir la calidad de los modelos y además se analizan los residuales.

La Tabla 2 muestra valores AIC para cada modelo, se prefiere el modelo con el menor AIC.

Table 1: Modelos DBH vs. PO.

Dist	Modelo	AIC
DBH	`gamlss(y∼children+health,family=DBH())`	1616.209
PO	`gamlss(y∼children+health,family=PO())`	2213.905

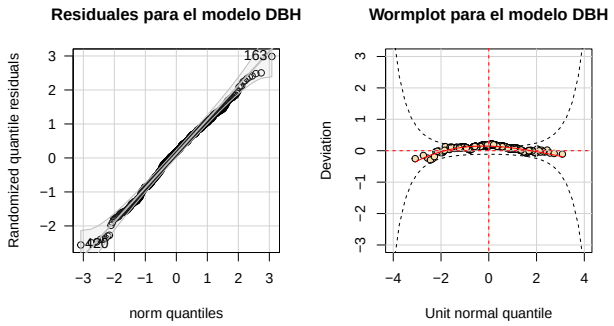


Figure 4: Estimaciones para DBH

Table 2: Modelos DBH vs. PO.

Model	Estimate	Std.Error	t value	P-value
Intercept	2.7256	0.3855	7.070	5.45e-12
Children	-0.3313	0.1214	-2.729	0.00659
Health	0.6612	0.1999	3.308	0.00101

6. Conclusiones

Se encontró que la estimación de parámetros tiende a ser más precisa a medida que incrementa el tamaño de muestra n. Al comparar los modelos gamlss implementando la DBH frente a la PO, resultó ser el modelo de la DBH el que mejor se ajustó a los datos. Es así como la implementación de esta nueva distribución resulta ser una gran alternativa y demostró su capacidad para modelar sobredispersión.

7. Referencias

1. **R: A Language and Environment for Statistical Computing**

   - *Autores:* R Core Team
   - *Organización:* R Foundation for Statistical Computing
   - *Dirección:* Vienna, Austria
   - *Año:* 2019
   - *URL:* https://www.R-project.org/

2. **Discrete Burr-Hatke Distribution With Properties, Estimation Methods and Regression Model**

   - *Autores:* El-Morshedy, M., Eliwa, M. S., Altun, Emrah
   - *Revista:* IEEE Access
   - *Año:* 2020
   - *Volumen:* 8
   - *Número:*
   - *Páginas:* 74359-74370
   - *DOI:* 10.1109/ACCESS.2020.2988431

3. **Generalized Additive Models for Location, Scale and Shape**

   - *Autores:* Rigby, R.A., Stasinopoulos, D.M.
   - *Revista:* Journal of the Royal Statistical Society: Series C (Applied Statistics)
   - *Volumen:* 54
   - *Páginas:* 507–554
   - *Año:* 2005

RESUMEN: Heramientas Matemáticas para el Análisis de Actividad Física *

Oscar Eduardo Martínez Castiblanco *Universidad Sergio Arboleda*

Resumen: *Este resumen no incluye gráficas ni tablas.*
El auge de la actividad física post pandemia ha estado ligado a las aplicaciones y dispositivos que permiten hacer seguimiento de las mismas. Esto sumado a la popularidad que ganaron algunos deportes que favorecen el distanciamiento social (ciclismo, atlelistmo) da origen a una gran cantidad de datos para ser analizados. En este trabajo se analiza la topografía del Alto de Guasquita, ubicado a 40 km de la ciudad de Bogotá, con base en datos recolectados a través de un GPS. Aplicando conceptos trigonométricos, de cálculo y estadística en R, se obtiene una comprensión de la estructura del puerto, y sugerencias para optimizar el desempeño deportivo de ciclistas que transitan esta zona.

Keywords: Ciencia de datos, Estadística, Cálculo, Trigonometría Esférica, Deporte, Ciclismo, Matemática Aplicada, R, XML, knitr, plotly, pracma, dplyr, forecast, cluster

Introducción

La bicicleta hace parte de la vida y las rutinas de muchos colombianos; desde el niño que recibe una como regalo de navidad hasta el gran campeón que conquista las rutas europeas, pasando por quien se gana la vida trabajando en ella. Este trabajo tiene sus orígenes en el ciclismo aficionado, entendido como la práctica esporádica de este deporte con fines recreativos o de salud. Esta práctica, combinada con la proliferación de dispositivos GPS y redes sociales, han dado origen a una gran cantidad de información obtenida a través de colaboración abierta distribuida (crowdsourcing). Estos datos han sido utilizados en trabajos académicos que permiten entender tanto el desempeño individual (Wolf et al., 2018) (Repici, 2019) (Wamsley, 2014) como las tendencias grupales de los ciclistas urbanos y recreativos (Pogodzinska, Kiec and D'Agostino, 2020) (Fischer, Nelson and Winters, 2022) (Sun and Mobasheri, 2017). En este trabajo, se toman datos generados en competencia, recolectados con un ciclocomputador, y descargados de la red social Strava para analizar el perfil del Alto de Guasquita, dar una interpretación adecuada a su pendiente, y ponderar su dificultad (desde lo deportivo) con respecto a otros puertos de la zona con pendiente similar.

Las matemáticas del ciclismo

La bicicleta es un vehículo de propulsión humana. La fuerza de las piernas se aplica a dos bielas a través de pedales y hacen girar una rueda dentada conocida como plato. El plato transfiere dicha fuerza a una rueda dentada más pequeña llamada piñón, que se encuentra sujeta a la rueda trasera, y de esta manera fuerza aplicada se convierte en energía cinética, la rueda gira

*Autor de contacto: oscar.martinez@usa.edu.co.

y se produce el movimiento. La eficiencia de la bicicleta se debe a las relaciones existentes entre los tamaños del plato y del piñón.

Sea D el diámetro del plato, d el diámetro del piñón, F la frecuencia con la que el plato gira y f la frecuencia con la que el piñón girara. La velocidad angular con la que gira el plato está dada por $2\pi F$ y al aplicar la ecuación fundamental de velocidades para transmisiones por correa y despejar f se obtiene $f = \frac{FD}{d}$. Teniendo en cuenta que $D > d$, se concluye que $f > F$, es decir, la frecuencia con la que gira el piñón es mayor a la del plato, en otras palabras, una vuelta del plato genera más de 1 vuelta del piñón y por ende, más de 1 vuelta de la rueda trasera. Sin pérdida de generalidad, la relación de transmisión $\frac{D}{d}$ se puede interpretar en términos de los dientes de cada engranaje, ya que tienen el mismo tamaño tanto en el plato como en el piñon. Si N es la cantidad de dientes del plato, y n la del piñón, la razón de marchas está dada entonces por $\frac{N}{n}$, y se interpreta como las vueltas que da el piñón por cada vuelta del plato. Estas vueltas se multiplican por el diámetro de la rueda, obteniendo así la distancia recorrida por cada vuelta completa de los pedales. Cabe anotar que la fuerza necesaria para poner en marcha el sistema es directamene proporcional a las razones previamente mencionadas. En otras palabras: a mayor razón se genera mayor avance, y se requiere más fuerza para poner en marcha el sistema.

La inclinación de las vías se calcula con la fórmula de la pendiente de una recta, y se interpreta de manera porcentual. En términos prácticos, los dispositivos GPS permiten obtener longitud, latitud y altitud, lo que permite calcular la pendiente. En ese sentido, si entre coordenadas planas (longitud, latitud) se avanzan 100m y se gana 1m de elevación, la vía tiene una inclinación del 1%. El problema radica ahora en calcular las distancia recorrida dadas dos coordenadas planas. Para tal fin, se utiliza la fórmula de Haversine (Brummelen, 2013). Esta expresión permite calcular la distancia entre dos puntos $P = (x_{lat}, x_{lon})$ y $q = (y_{lat}, y_{lon})$ sobre el globo terraqueo, a partir de sus coordenadas. Esta fórmula se puede calcular en R a través de la función `haversine` dentro de la librería `pracma`. Una vez calculadas las distancias horizontales, y teniendo los datos de altitud, es posible visualizar la ruta, así como calcular las inclinaciones de la misma punto a punto, y obtener una mayor comprensión de la vía.

Contexto: Alleycat race

Los datos a ser modelados en este trabajo corresponden a la carrera ciclística "XChallenge". Dicha carrera se realizó el 26 de febrero de 2022 con partida en el Alto de Patios (La Calera, Cundinamarca). Esta carrera ha sido la única realizada en esta zona con la modalidad de "Alleycat Race". Al momento de la inscripción, los participantes solo conocían la distancia y desnivel positivo acumulado a recorrer, y que el tiempo de los ganadores se determinaría en cuatro "X" (puertos de montaña cronometrados) cuya ubicación solo será conocida durante la carrera (Gómez and Aristizabal, 2022). El día de la competencia, los participantes se dirigían al punto de partida donde recibían la indicación para llegar a la primera X (alto cronometrado), su longitud y porcentaje de inclinación. Al finalizar el primer puerto cronometrado, los participantes reciben la indicación del siguiente para dirigirse allí y continuar la carrera. Teniendo en cuenta el tipo de competencia, la interpretación que el competidor hace de la distancia y porcentaje de inclinación del puerto (en muchos casos desconocido) es fundamental para diseñar una estrategia de carrera óptima que permita recorrer cada una de las "X" en el menor tiempo posible.

La segunda "X" era el Alto de Guasquita, con 2.7 km y una inclinación de 5.2%. Si bien es cierto

que el porcentaje de inclinación es considerable, este es mucho menor que el primero. Con base en la longitud del puerto y la experiencia en otros ascensos con inclinación similar era plausible pensar en una relación de transmisión entre 2.5 y 3, que con una cadencia de 60 rpm permitiera realizar el ascenso tomando entre 7 y 9 minutos. Sin embargo, los primeros metros del ascenso evidenciaron una dificultad mucho más alta de la que indicaba el procentaje de inclinación, lo que motivó a realizar un análisis detallado del puerto, para tener una mayor comprensión de su dificultad, no explicada totalmente por el porcentaje de inclinación.

Procesamiento y análisis de datos

Una vez finalizada la carrera y por ende, el registro de los datos, se descargan dos archivos a través de la aplicación Strava, con extensiones gpx y fit. Dada la naturaleza de los archivos, la librería `XML` permite extraer la información requerida de este tipo de archivos a un DataFrame. Con este conjunto de datos es posible realizar varias visualizaciones de la ruta. Entre ellas, el recorrido de la vía. Además, es posible calcular las distancias recorridas entre cada punto, y así realizar el análisis de la pendiente.También es posbile visualizar la vía en 3D utilizando el paquete `plotly`.

Utilizando la ecuación **??** con la función `haversine` sobre las columnas de latitud y longitud es posible obtener la distancia entre cada par de coordenadas, y con vectores de diferencias `diff` se pueden obtener las variaciones de altitud y tiempo entre puntos. Con esta información es posible calcular la velocidad e inclinación en cada punto. Aunque todas las medidas están en metros y segundos, la velocidad se expresa en kilómetros por hora en aras de facilitar su interpretación.

Con estos datos es posbile obtener un primer acercamiento a la pendiente de la montaña, realizando el cociente entre la suma de las elevaciones y las distancias punto a punto. Este primer dato que se obtiene es el que aparece referenciado en la aplicación Strava.

Resultados

Con los datos procesados es posible visualizar y analizar la pendiente, en aras de comprender mejor la inclinación de la montaña.El perfil permite evidenciar algunos tramos de menor inclinación, casi planos, lo cual quiere decir que otros tramos deben tener pendiente que excede el promedio. Para comprender mejor este concepto, es posible interpretar la pendiente como una señal. Para clasificar las pendientes, se asignan cuatro categorías: $[0,2)$,$[2,6)$,$[6,10)$,$[10,40)$. Estos grupos se plantean agrupando pendientes con dificultad similar.Estos porcentajes distribuidos a lo largo de la vía dan cuenta de las tensiones del recorrido, con curvas de alta pendiente seguidas de segmentos lineales cortos de aparente descanso.

```
## Warning: package 'forecast' was built under R version 4.3.2
```

```
## Registered S3 method overwritten by 'quantmod':
##   method            from
##   as.zoo.data.frame zoo
```

Finalmente, para comprender cómo se relacionan las pendientes entre ellas, y generar una agrupación que permita comparar el puerto con otros de pendiente similar, se utiliza el algoritmo

k-means sobre la inclinación, distancia y velocidad en cada punto. Con base en el método del codo se generan 4 grupos sobre los datos. Los grupos etiquetados 3 (azul) y 2 (verde) corresponden a segmentos de baja inclinación, y se diferencian principalmente por la velocidad alcanzada en los mismos. Esta velocidad depende de la longitud del tramo y de la inclinación anterior, es decir, el grupo 1 representa tramos más largos que el tramo 2, lo que permite descansar y aumentar la velocidad, mientras que en el grupo 2 los tramos son más cortos, y aunque permiten descansar, su cercanía con un tramo de pendiente mayor no permite que la velocidad aumente como en el grupo anterior. Por otra parte, los grupos 1 (amarillo) y 4 (rojo) corresponden a los tramos de mayor difucultad debido a su pendiente, lo que disminuye el avance en los mismos. Esta información permite identificar dos tramos al final del puerto donde, de acuerdo a la categorizacíon obtenida, se podría aumentar la potencia para obtener mejoras significativas en el tiempo de ascenso.

Los grupos etiquetados 3 (azul) y 2 (verde) corresponden a segmentos de baja inclinación, y se diferencian principalmente por la velocidad alcanzada en los mismos. Esta velocidad depende de la longitud del tramo y de la inclinación anterior, es decir, el grupo 1 representa tramos más largos que el tramo 2, lo que permite descansar y aumentar la velocidad, mientras que en el grupo 2 los tramos son más cortos, y aunque permiten descansar, su cercanía con un tramo de pendiente mayor no permite que la velocidad aumente como en el grupo anterior.

Finalmente, para ponderar la dificultad del Alto de Guasquita, se analiza otro puerto de la zona con una inclinación promedio similar: el Alto del Neusa. Ubicado a 80 km del Alto de Guasquita, cuenta con 6,9 km de longuitud y una inclinación promedio del 5.2%. Estos valores se obtienen aplicando el mismo procesamiento de datos presentadio previamente sobre archivos .gpx y .fit. Posterior a ello, se clasifica el Alto del Neusa con los centroides generados con el Alto de Guasquita para contrastar los dos recorridos. A diferencia de Guasquita, Neusa tiene un alto porcentaje de recorrido con inclinaciones cercanas a la inclinación promedio. En otras palabras, el procentaje promedio de inclinación en el Alto del Neusa describe mejor la dificultad del mismo, permitiendo planificar estrategias de potencia y cadencia constantes para el ascenso.

En conclusión, aunque ambos puertos de montaña tengan un porcentaje de inclinación similar, la topografía de los mismos hace que las estrategias de ascenso generadas a partir de uno de ellos no sean del todo aplicables al otro. Además, el análisis desarrollado permite entender la estructura del ascenso con el fin de identificar tramos relevantes al diseñar estrategias de competencia cuyo propósito sea minimizar el tiempo en dicho recorrido.

References

Brummelen, Glen Van. 2013. *Heavenly Mathematics: The Forgotten Art of Spherical Trigonometry*. Princeton University Press.

Fischer, Jaimy, Trisalyn Nelson and Meghan Winters. 2022. "Riding through the pandemic: Using Strava data to monitor the impacts of COVID-19 on spatial patterns of bicycling." *Transportation Research Interdisciplinary Perspectives* 15:100667.
URL: *https://www.sciencedirect.com/science/article/pii/S2590198222001270*

Gómez, Sergio and Juan Aristizabal. 2022. *Guía del Atleta X Challenge*. TNC Games.

Pogodzinska, Sylwia, Mariusz Kiec and Carmelo D'Agostino. 2020. "Bicycle Traffic Volume Estimation Based on GPS Data." *Transportation Research Procedia* 45:874–881. Transport Infrastructure and systems in a changing world. Towards a more sustainable, reliable and smarter mobility.TIS Roma 2019 Conference Proceedings.
URL: *https://www.sciencedirect.com/science/article/pii/S2352146520301319*

Repici, Michael. 2019. Because My Garmin Told Me To: A New Materialist Study of Agency and Wearable Technology Phd thesis University of South Florida South Florida, FL: . Available at https://www.proquest.com/openview/ce940cfa2eed18380a7476f7085543ee/1?pq-origsite=gscholar&cbl=18750&diss=y.

Sun, Yeran and Amin Mobasheri. 2017. "Utilizing Crowdsourced Data for Studies of Cycling and Air Pollution Exposure: A Case Study Using Strava Data." *International Journal of Environmental Research and Public Health* 14(3).
URL: *https://www.mdpi.com/1660-4601/14/3/274*

Wamsley, Kyle. 2014. Optimal power-based cycling pacing strategies for Strava segments Phd thesis Kutztown University of Pennsylvania Pennsylvania, PA: . Available at https://www.proquest.com/openview/17c398b22550ef77615a6b5dfcdc89fa/1?pq-origsite=gscholar&cbl=18750.

Wolf, Stefan, Alexander Artiga Gonzalez, Raphael Bertschinger and Dietmar Saupe. 2018. "Modeling in Road Cycling for Optimal Pacing Strategies: Theory vs. Practice." 7:18–19.
URL: *https://www.jsc-journal.com/index.php/JSC/article/view/397*

Analítica descriptiva de la evaluación de desempeño financiero de las PYMES individuales en Colombia [*]

Luis Felipe Marulanda *Universidad de Antioquia*
Gloria Lucía Ramírez *Universidad de Antioquia*
Olga Cecilia Usuga *Universidad de Antioquia*

Resumen: Este estudio presenta los resultados de la evaluación del desempeño financiero de las pequeñas y medianas empresas (PYMES) de Colombia en el año 2022. Las PYMES realizan un reporte anual a la Superintendencia de Sociedades con la respectiva información contable, el cálculo y análisis de indicadores financieros de liquidez, rentabilidad y endeudamiento, permiten comprender qué características comparten las empresas, según su ubicación o sector económico. Los resultados financieros se analizaron en R para ampliar el estudio descriptivo, para lo cual se usó el reporte de 23.744 PYMES individuales y se encontraron características significativas de relación entre los indicadores y las empresas.

Keywords: PYMES, indicadores financieros, dplyr, ggplot2, qcc.

Introducción

En el año 2022, la economía colombiana logró un crecimiento del PIB de 7,3 %, mostrando nuevamente señales de su recuperación después de la pandemia causada por el COVID19. Bajo este panorama, resulta interesante evaluar el desempeño financiero de las PYMES que reportaron información financiera del año 2022 a la Superintendencia de Sociedades. El análisis financiero se realizó por grupos económicos, con el objetivo de contrastar los resultados sectoriales frente al comportamiento del PIB sectorial, pues según cifras del DANE, las actividades económicas que más contribuyeron a la dinámica del valor agregado durante el año 2022 fueron: Comercio al por mayor y al por menor, y Reparación de vehículos automotores y motocicletas (G); Transporte y almacenamiento (H); Alojamiento y servicios de comida (I); Industrias manufactureras (C); Actividades artísticas, de entretenimiento y recreación y otras actividades de servicios (R); Actividades de los hogares individuales en calidad de empleadores, y Actividades no diferenciadas de los hogares individuales como productores de bienes y servicios para uso propio (T).

El desarrollo de este estudio se estructura de la siguiente manera: comienza con una breve descripción de los datos y la metodología utilizada; luego se presentan los principales resultados financieros obtenidos y su análisis a partir de la aplicación de analítica descriptiva y, por último, se plantean algunas consideraciones finales sobre los resultados encontrados en el estudio.

Datos y metodología

El objetivo del estudio es mostrar un análisis descriptivo de indicadores financieros de las PYMES colombianas en el año 2022, siguiendo como metodología el cálculo y análisis de los indicadores financieros con base en la información contable reportada a la Superintendencia de Socie-

[*] **Autor de contacto**: luis.marulandag@udea.edu.co.

dades de Colombia. Los indicadores financieros seleccionados se pueden agrupar en términos de liquidez, rentabilidad y endeudamiento, de tal forma que se pueda comprender la salud financiera de las PYMES.

La base de datos de información contable de las PYMES del año 2022 fue obtenida del Sistema Integrado de Información Societario (SIIS), del cual se eligieron los reportes de las PYMES individuales, con un total de 23.744 empresas. Una vez organizada la base de datos, se eliminan las empresas con ingresos de actividades ordinarias u otros ingresos inferiores a $1.000.000, con lo cual la base de datos quedó con un total 18.482 PYMES que cumplen con este criterio, es decir, se realiza el análisis con el 77,84 % de los datos reportados.

Con la información contable disponible en la base de datos, se calcularon algunos indicadores para medir la gestión financiera de las empresas. Para entender la liquidez de las empresas, se calcularon la razón corriente, la prueba ácida y la importancia del activo corriente. Para analizar el endeudamiento, se calcularon el nivel de endeudamiento, el impacto de la carga financiera y la cobertura de intereses. Por otro lado, para medir la productividad de los recursos comprometidos en las empresas, se calcularon la rentabilidad del activo, la rentabilidad del patrimonio, la productividad del capital de trabajo y la productividad del activo fijo. Finalmente, para medir la efectividad de la administración para controlar los costos y gastos, y de esta forma convertir las ventas en utilidades, se calcularon el margen bruto, el margen operativo, el margen EBITDA y el margen neto.

Una vez obtenidos los resultados, se realiza un análisis descriptivo de los indicadores financieros, agrupados por actividad económica en 21 grupos, para lo cual se usó la clasificación industrial CIIU, así: (A) Agricultura, ganadería, caza, silvicultura y pesca, (B) Explotación de minas y canteras, (C) Industrias manufactureras, (D) Suministro de electricidad, gas, vapor y aire acondicionado, (E) Distribución de agua; evacuación y tratamiento de aguas residuales, gestión de desechos y actividades de saneamiento ambiental, (F) Construcción, (G) Comercio al por mayor y al por menor; reparación de vehículos automotores y motocicletas, (H) Transporte y almacenamiento, (I) Alojamiento y servicios de comida, (J) Información y comunicaciones, (K) Actividades financieras y de seguros, (L) Actividades inmobiliarias, (M) Actividades profesionales, científicas y técnicas, (N) Actividades de servicios administrativos y de apoyo, (O) Administración pública y defensa; planes de seguridad social de afiliación obligatoria, (P) Educación, (Q) Actividades de atención de la salud humana y de asistencia social, (R) Actividades artísticas, de entretenimiento y recreación, (S) Otras actividades de servicios, (T) Actividades de los hogares individuales en calidad de empleadores; actividades no diferenciadas de los hogares individuales como productores de bienes y servicios para uso propio y (U) Actividades de organizaciones y entidades extraterritoriales.

Para realizar el análisis descriptivo de la evaluación de desempeño financiera de las PYMES individuales en Colombia se realizaron dos etapas en R (R Core Team, 2019): transformación de base de datos y análisis exploratorio. Para la primera etapa se usó la librería dplyr (Wickham et al., 2023) y para la segunda etapa se usó la librería qcc (Scrucca, 2004) y ggplot2 (Wickham, 2016).

Resultados

En términos de liquidez, los boxplot presentados en la Figura 1 de los indicadores de razón corriente y de prueba ácida, permiten determinar que los resultados tienen una variabilidad muy grande en casi todos los sectores económicos, excepto en los sectores D (suministro de electricidad, gas, vapor y aire acondicionado) y E (distribución y tratamiento de agua), probablemente porque son pocas las empresas que se dedican a dichas actividades económicas y, al ser sectores tan específicos de servicios públicos, deben tener una estructura operativa y financiera similar.

Adicionalmente, es posible identificar que las empresas que se dedican a las actividades E (distribución y tratamiento de agua), F (Construcción), y K (Actividades financieras y de seguros) son las que tienen un valor central mayor, indicando que son empresas que cuentan con mayor disponibilidad de activos corrientes para enfrentar sus pasivos de corto plazo.

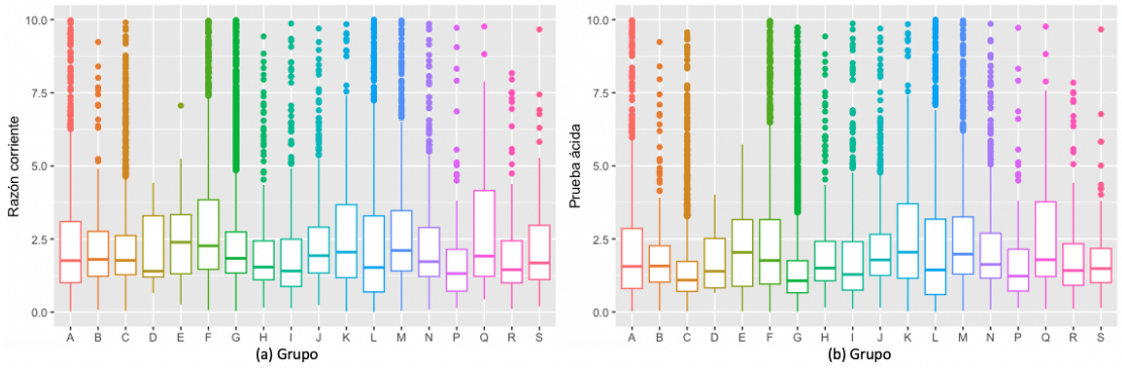


Figura 1: Boxplot de (a) Razón corriente vs Grupo y (b) Prueba ácida vs Grupo.

Para caracterizar el nivel de endeudamiento de las PYMES colombianas se calcularon varios indicadores, tales como el nivel de endeudamiento. Según la Figura 2(a), las empresas de la muestra tienen un nivel de endeudamiento cercano del 50 %, es decir, que el 50 % de los activos que poseen están siendo financiados por terceras personas (proveedores, entidades financieras, entre otros). Del boxplot de este indicador se resalta el bajo nivel de endeudamiento de las empresas que se dedican a las actividades K (Actividades financieras y de seguros) y L (actividades inmobiliarias), mientras que las empresas D (suministro de electricidad, gas, vapor y aire acondicionado) son las que mayor endeudamiento presentan. Por otro lado, se analiza el impacto de la carga financiera, que es un indicador que mide el porcentaje que representan los intereses del total de ingresos operacionales. Como se puede observar en la Figura 2(b), hay mucha variabilidad en los resultados, aunque todos los valores centrales (medianas) están alrededor del 2 %, indicando que la carga de intereses es relativamente baja, pues lo ideal es que este indicador esté por debajo del 10 %.

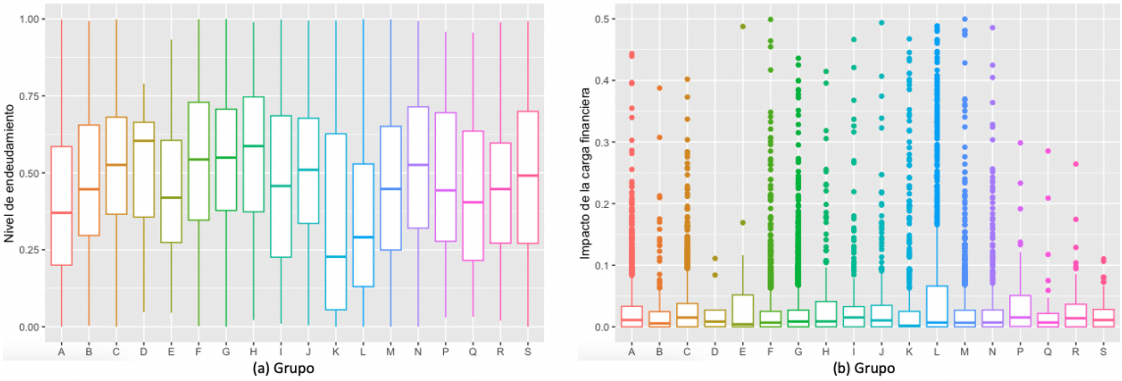


Figura 2: Boxplot de (a) Nivel de endeudamiento vs Grupo y (b) Impacto de la carga financiera vs Grupo.

En términos de rentabilidad, de acuerdo a la Figura 3, encontramos que en el año 2022 las empresas que obtuvieron mejores resultados fueron las que se dedicaron a las actividades eco-

nómicas R (actividades artísticas, de entretenimiento y recreación) y B (explotación de minas y canteras), pues el 50 % de las empresas de esos grupos tuvieron lograron generar mayores utilidades operativas con el uso de sus activos (15 % y 13 % respectivamente). Por su parte, los socios de las empresas dedicadas a la actividad económica J (información y comunicaciones) fueron los que lograron un mayor rendimiento neto del dinero que tienen invertido en sus negocios (15 %). Como se puede observar en las siguientes gráficas, los resultados de rentabilidad tienen mucha variabilidad en casi todos los sectores económicos analizados, aunque es importante mencionar que los valores centrales (mediana) de estos indicadores son positivos, lo cual valida los buenos resultados obtenidos por la economía en el año 2022. Específicamente, cuando se analizan las cifras de cada sector, es posible validar que las empresas dedicadas a las actividades económicas que más contribuyeron a la dinámica del valor agregado durante el año 2022 (actividades G, H, I, C, R), según cifras del DANE sobre el PIB sectorial, obtuvieron muy buenos resultados de rentabilidad, tanto del activo como del patrimonio, con lo cual se concluye que fueron muy eficientes en el uso de sus recursos. Por otro lado, al analizar los indicadores que permiten la productividad de las empresas en el manejo de su capital de trabajo neto operativo (KTNO) y su activo fijo, se encuentra que dichos sectores económicos también tuvieron muy buenos resultados de productividad, a lo cual se suman los sectores J (información y comunicaciones) y N (actividades de servicios administrativos y de apoyo).

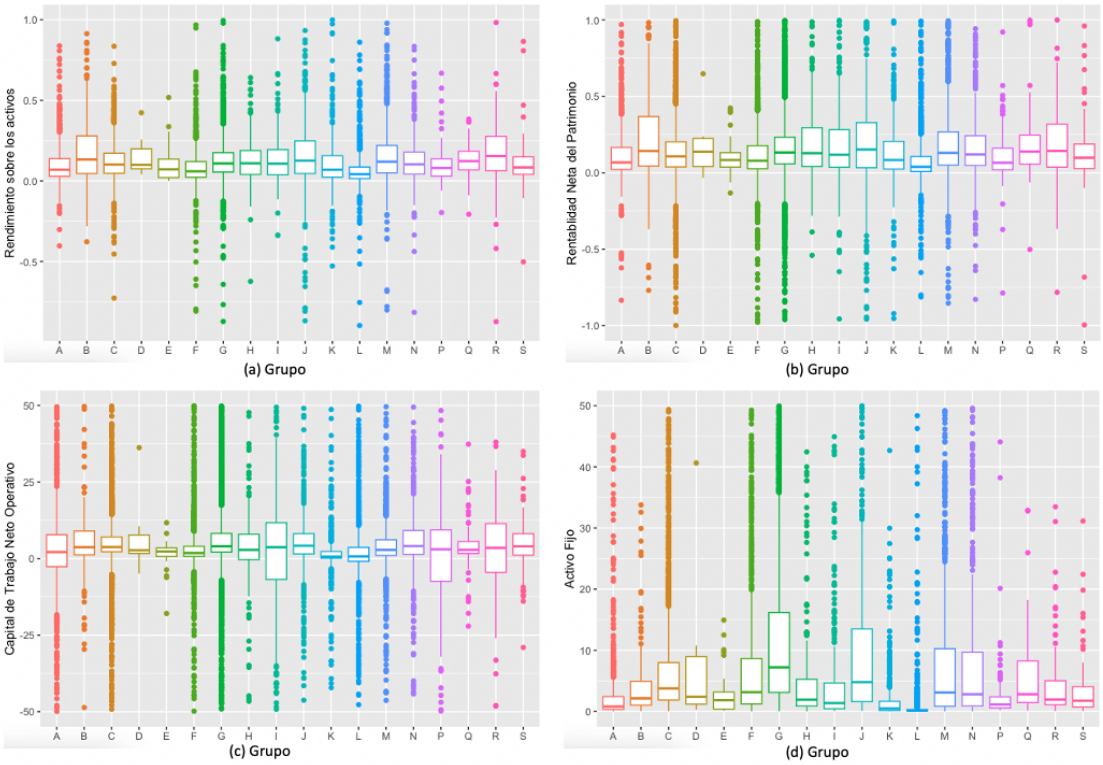


Figura 3: Boxplot de (a) Rendimiento sobre los activos vs Grupo, (b) Rentabilidad Neta del Patrimonio vs Grupo, (b) Capital de Trabajo Neto Operativo vs Grupo, y (d) Activo Fijo vs Grupo.

Referencias

R Core Team. 2019. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing.
URL: *https://www.R-project.org/*

Scrucca, Luca. 2004. "qcc: an R package for quality control charting and statistical process control." *R News* 4/1:11–17.
URL: *https://cran.r-project.org/doc/Rnews/*

Wickham, Hadley. 2016. *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York.
URL: *https://ggplot2.tidyverse.org*

Wickham, Hadley, Romain François, Lionel Henry, Kirill Müller and Davis Vaughan. 2023. *dplyr: A Grammar of Data Manipulation*. R package version 1.1.2.
URL: *https://CRAN.R-project.org/package=dplyr*

Estimaciones espaciales de evapotranspiración multianual usando R para aplicaciones hidrológicas *

Breiner Dan Bastidas Osejo *Universidad de Antioquia*
Laura Ximena Echeverri Gutierrez *Universidad Nacional de Colombia*

Resumen: La evapotranspiración es un flujo hidrológico fundamental en los análisis de recursos hídricos, especialmente en lo relacionado con el balance hídrico a escala de cuencas, a su vez es uno de los flujos más difíciles de medir y estimar, por tanto, para diversas aplicaciones hidrológicas es clave estimar este flujo por diversos métodos, con el fin de reducir la incertidumbre asociada y poder realizar dichas estimaciones espacialmente distribuidas. La estimación espacial se realiza frecuentemente en software SIG, sin embargo, no resultan ser tan eficientes cuando se trata de la implementación de diversos métodos y a escalas espaciales de alta resolución, por ello, en este trabajo proponemos un código simple que utiliza el lenguaje R como software SIG para estimar la evapotranspiración potencial (ETP) y real (ETR) a escala multianual mediante cinco métodos típicos de estimación: Turc, Thornthwaite, Cenicafé, Hargreaves y Countagne. La implementación de estos métodos en R muestra un notable mejor desempeño en comparación con los softwares SIG tradicionales, dada la facilidad de incorporar en R funciones matemáticas, funciones condicionales y bucles, requeridos en los diversos métodos de estimación, adicionalmente permite ejecutar un proceso más simplificado y consistente, limitando errores típicos de SIG. Los resultados del código se muestran a manera de ejemplo para una región climática y topográficamente compleja de Colombia. El código permite obtener salidas raster de ETP y ETR multianual para los cinco métodos implementados, además de la ETP mensual – multianual y del índice de Aridez (IA) definido por el IDEAM.

Keywords: Indice de Aridez, Análisis espacial, SIG, flujos hidrológicos

Introducción

La evapotranspiración es un elemento clave en el ciclo hidrológico, fundamental en los análisis de recursos hídricos y en las evaluaciones agrícolas (Wanniarachchi and Sarukkalige, 2022; Amani and Shafizadeh-Moghadam, 2023), aplicaciones tales como el cálculo del balance hídrico (Chow, Maidment and Mays, 1994; Bastidas-Osejo, Vargas and Martinez, 2019), análisis de condiciones de aridez y sequía (Amani and Shafizadeh-Moghadam, 2023), estimaciones de la oferta hídrica y de la demanda hídrica agrícola (Amani and Shafizadeh-Moghadam, 2023; Raza et al., 2021), dependen notablemente de esta variable. A su vez es uno de los flujos más difíciles de medir y estimar (Chow, Maidment and Mays, 1994), en especial para cuencas no instrumentadas, por lo anterior, para diversas de las aplicaciones mencionadas es clave poder estimar este flujo por diversos métodos con el fin de reducir la incertidumbre asociada y poder realizar dichas estimaciones espacialmente distribuidas.

La evapotranspiración (ET) es el flujo de agua (en estado gaseoso - vapor de agua) de inter-

* **Autor de contacto**: breiner.bastidas@udea.edu.co

cambio desde la superficie hacia la atmósfera, a partir de dos procesos combinados: el proceso físico de evaporación desde los cuerpos de agua y del suelo, y el proceso biológico de transpiración desde los seres vivos, fundamentalmente desde la vegetación (Chow, Maidment and Mays, 1994; Shuttleworth, 2012; Amani and Shafizadeh-Moghadam, 2023). El comportamiento espacio-temporal de la ET depende de tres factores fundamentales: suministro de energía (vía radiación solar), disponibilidad de agua para el cambio de fase y el estado aerodinámico de la atmósfera para asimilar y permitir el transporte de vapor de agua (Chow, Maidment and Mays, 1994).

Se evidencia así, que una estimación precisa y directa de ET requiere de una gran cantidad de datos hidrometeorológicos y de superficie, que para muchas regiones no se encuentran disponibles, especialmente en cuencas no instrumentadas. Por lo anterior, es una práctica común en hidrología la aplicación de expresiones empíricas basadas en variables meteorológicas con mayor facilidad de medición, tales como precipitación, temperatura, entre otras (Xu and Singh, 2002; Bastidas-Osejo, Vargas and Martinez, 2019). En muchas ocasiones la estimación de ET por métodos indirectos se realiza de manera puntual (en la estación disponible), sin embargo, para diversas aplicaciones hidrológicas es deseable conocer el comportmaiento de ET a escala espacial.

La tarea de estimación espacial se realiza frecuentemente en software SIG (Sistemas de Información Geográfica) como *QGIS* y *ARCGIS*, sin embargo, dichos softwares no resultan ser tan eficientes cuando se trata de la implementación de diversos métodos y a escalas espaciales de alta resolución, por ello, el objetivo de este trabajo es proponer un código simple que ilustra como el lenguaje R Core Team (2019) puede ser utilizado como un software SIG para análisis espaciales eficientes, en particular para estimar la evapotranspiración potencial (ETP) y real (ETR) a escala multianual mediante métodos indirectos. A continuación, se describen los datos utilizados, en particular para una zona de estudio en Colombia que se ha seleccionado para ilustrar la aplicabilidad del código, seguido de la metodología general y estructura del código, finalmente se presentan los resultados, conclusiones y una breve discusión.

Materiales y métodos

Zona de estudio

Para ilustrar el uso del código propuesto, se ha seleccionado una región climática y topográficamente compleja en el noreste de Colombia, al sur del departamento del Cesar y el oeste de Norte de Santander, zona comprendida en dos áreas hidrográficas de gran extensión, con la serranía del Perijá como divisoria de ambas: la subzona hidrográfica Quebrada El Carmen y Otros Directos al Magdalena Medio (2321) en la vertiente occidental de la serranía y la subzona hidrográfica Río Algodonal (Alto Catatumbo) (1605) en la vertiente oriental de la serranía (IDEAM, 2019).La extensión de la zona delimitada es de 2594,6 km^2, la topografía es altamente variable, con elevaciones máximas desde 3200 m.s.n.m, hasta elevaciones mínimas de 32 m.s.n.m, estas características condicionan un clima variable calido a templado, lo cual implica altas variaciones espaciales de evapotranspiración, con implicaciones de variabilidad en la oferta hídrica de estas regiones.

Datos

Para la estimación espacial multianual de la evapotranspiración (ET), es requerida información hidrometeorológica de relativa fácil adquisición: precipitación, temperatura y radiación solar incidente. Dado que el objetivo es obtener distribuciones espaciales de ET, lo ideal es obtener la

información mencionada como archivos espaciales (raster) a escala mensual multianual. La información mencionada puede ser obtenida de bases de datos climáticos globales de alta resolución, como lo son WorldClim 2.1 (Fick and Hijmans, 2017) y Chelsa 2.1 (Karger et al., 2017), que han mostrado un buen desempeño para reproducir diversas condiciones climatológicas a escala de cuencas (Bastidas-Osejo, Vargas and Martinez, 2019; Rodríguez-Almonacid et al., 2023). Adicionalmente, es deseable obtener la información hidrometeorológica mencionada directamente de estaciones y distribuirla espacialmente mediante técnicas de interpolación espacial, donde paquetes como *Field* de *R* son de gran utilidad (Bastidas-Osejo and Betancur, 2019). En Tabla 1 se listan las fuentes de los datos utilizados para el caso de estudio específico. Es condición deseable incorporar lo raster mencionados en un mismo sistema de coordenadas e igual resolución y extensión espacial. Para el caso de estudio la resolución es de 30 m x 30 m, en sistema de coordenadas Magna - Sirgas Origen Nacional (9377)

Tabla 1: Datos utilizados para las estimaciones espaciales de evapotranspiración

Variable	**Fuente**	**Resolución temporal**
Topografía del terreno (m.s.n.m)	Modelo de elevación digital de ALOS-PALSAR (12,5 m x 12,5 m) remuestrado	No aplica
Precipitación (mm/año)	Interpolación espacial con Kriging con Deriva Externa, con 23 estaciones del IDEAM y datos de WorldClim	Mensual multianual
Temperatura media (°C)	Interpolación espacial con Kriging con Deriva Externa, con 4 estaciones del IDEAM y datos de WorldClim	Mensual multianual
Radiación solar incidente (kJ m^{-2} da^{-1})	Datos remuestreados y proyectados de WorldClim	Mensual multianual

Metodología general

La metodología aplicada, los paquetes utilizados, las funciones implementadas y las ecuaciones incorporadas por cada método de evapotranspiración se resumen gráficamente en la Figura 1. Es de aclarar que hay métodos que estiman directamente la evapotranspiración real multianual (ETR), como el caso de Turc y Countagne, mientras que otros como Cenicafé, Hargreaves y Thornthwaite estiman evapotranspiración potencial (ETP), por tanto es necesario convertirla en ETR, considerando la disponibilidad de precipitación (P) y usando la expresión de Budyko (Ecuación 1), la cual se ha incorporado como función en el código. Se ha incluído también la posibilidad de ingresar ETP mensual calculada externamente, para convertirla en ETR mediante la expresión de Budyko. Para el caso de estudio la ETP alterna se ha tomado del proyecto Chelsa V.2.1.

$$ETR = \left[\left(ETP \cdot P \cdot \tanh\left(\frac{P}{ETP}\right)\right) \cdot \left(1 - \cosh\left(\frac{ETP}{P}\right) + \sinh\left(\frac{ETP}{P}\right)\right)\right]^{0,5} \quad (1)$$

Para los métodos que estiman ETP y ETR, es posible calcular el Índice de Aridez (IA), definido por el IDEAM (Ecuación 2), el cual se ha incorporado como función en el código.

$$IA = \frac{ETP - ETR}{ETP} \quad (2)$$

Este índice es clave para evaluar los excesos (IA menor) o déficits (IA mayor) de humedad en la en el sistema suelo-atmósfera de una región en Colombia. Finalmente, los métodos Hargreaves y

Thornthwaite parten de una implementación mensual, por lo cual para estos se ha implentado una función en el código que exporta los raster mensuales multianuales de ETR de los mencionados métodos.

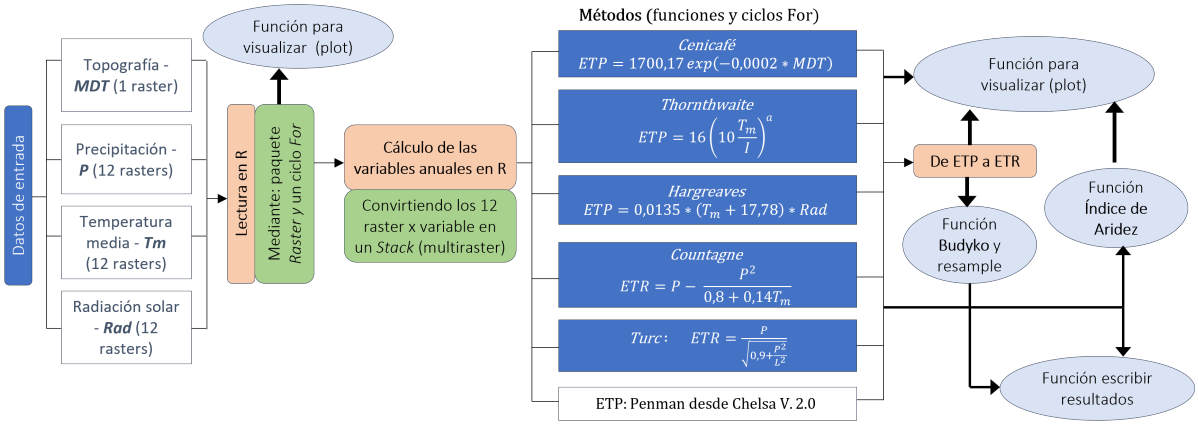


Figura 1: Metodología general que estructura el código (se ilustran las ecuaciones principales de los métodos de ETP y ETR, las ecuaciones completas están en el código)

Resultados

El código desarrollado se dispone en el siguiente repositorio de Github. Para la zona de estudio, el código permitió generar en formato Geotiff cuatro mapas de ETP multianual, seis de ETR multianual, 12 de ETR mensual multianual y tres de Índice de Aridez (IA) multianual, todos a resolución espacial de 30 m x 30 m para una extensión de 2300 filas x 2414 columnas,en un tiempo aproximado de 03 minutos (En PC: AMD Ryzen 5 4600H (3.00 GHz) - 24GB de RAM), tiempo que en un SIG tradicional podría tomar al menos varias horas. El código grafica en el panel *Plots* los mapas resultantes de cada cálculo, para facilitar el chequeo por parte del usuario. En la Figura 2 se muestra un resumen gráfico de los resultados obtenidos, donde se evidencia la importante variabilidad espacial de la ETP, ETR e IA, así como similitudes y diferencias entre los métodos implementados.

Discusión y conclusiones

La implementación de métodos espaciales empíricos para la estimaciónd de la ETP y ETR a escala multianual y mensual multianual en R Core Team (2019) muestra un notable buen desempeño, siendo fuertemente competitivo frente a los software SIG tradicionales, dada la facilidad de incorporar en *R* funciones matemáticas, funciones condicionales y bucles, requeridas en los diversos métodos de estimación, adicionalmente permiten ejecutar un proceso más simplificado y consistente, limitando errores típicos de SIG como incompatibilidad en resolución y extensión espacial y sistemas de coordenadas de referencia (src) distintos, que en muchas ocasiones implica reprocesos.

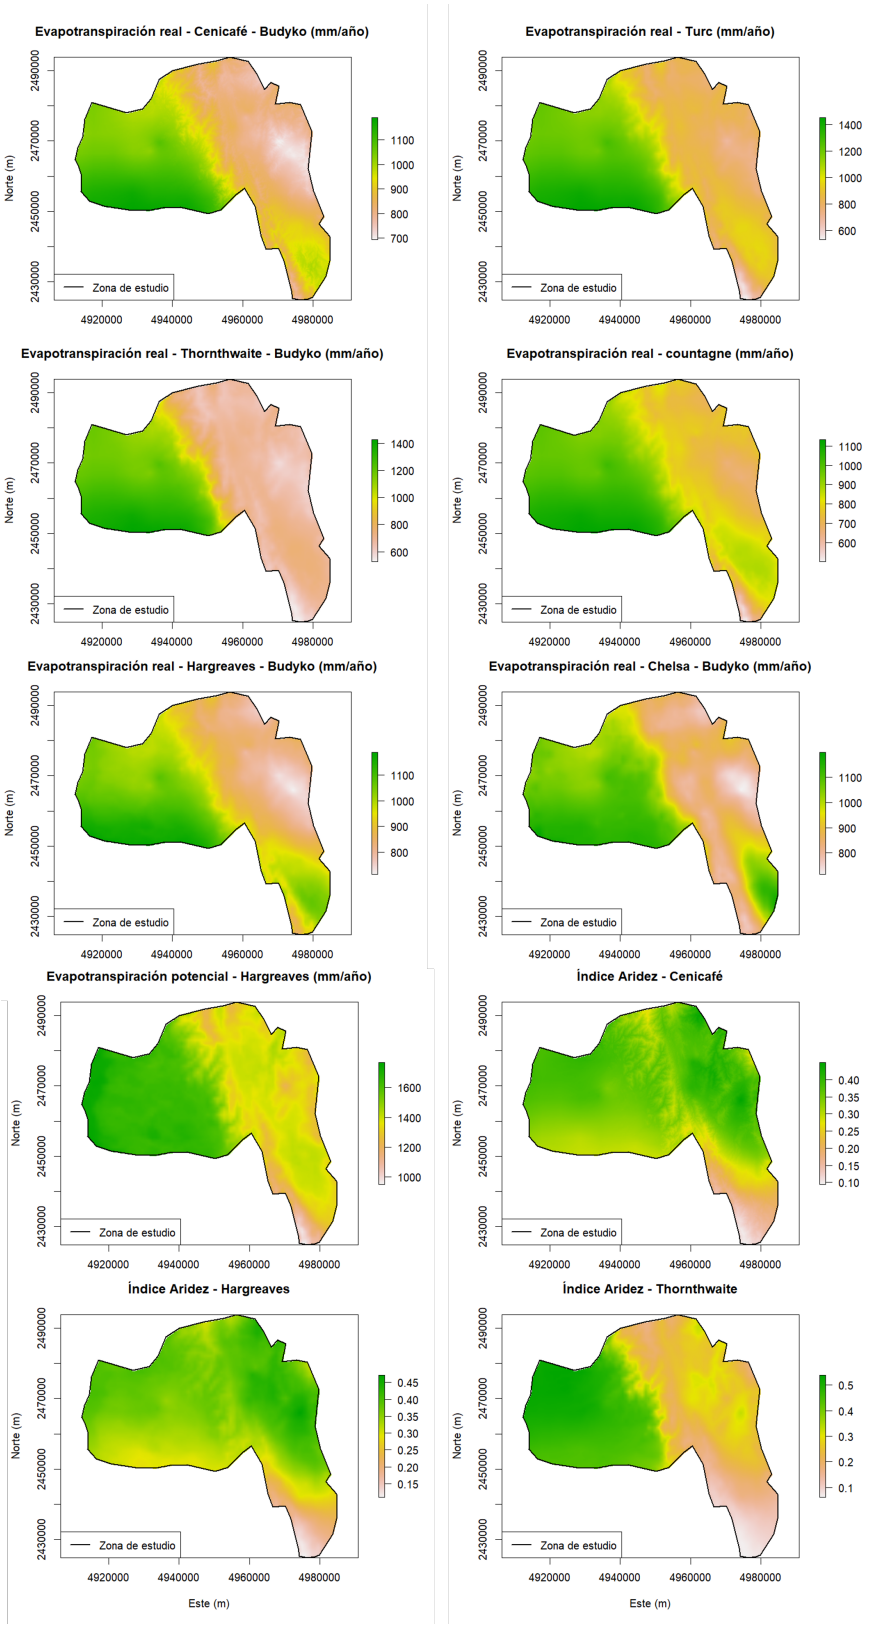


Figura 2: Distribución espacial de ETR, ETP e IA por diversos métodos en la zona de estudio

Referencias

Amani, Shima and Hossein Shafizadeh-Moghadam. 2023. "A review of machine learning models and influential factors for estimating evapotranspiration using remote sensing and ground-based data.".

Bastidas-Osejo, Breiner and Teresita Betancur. 2019. Uso de R y el paquete Fields para la interpolación espacial recurrente de variables ambientales.

Bastidas-Osejo, Breiner, Teresita Betancur Vargas and John Alejandro Martinez. 2019. "Spatial distribution of precipitation and evapotranspiration estimates from Worldclim and Chelsa datasets: Improving long-term water balance at the watershed-scale in the Urabá region of Colombia." *International Journal of Sustainable Development and Planning* 14:105–117.
URL: *http://www.witpress.com/doi/journals/SDP-V14-N2-105-117*

Chow, Ven Te, David R Maidment and Larry W. Mays. 1994. *Hidrología aplicada*. Segunda ed.

Fick, Stephen E and Robert J Hijmans. 2017. "WorldClim 2: new 1-km spatial resolution climate surfaces for global land areas." *International Journal of Climatology* 37:4302–4315. doi: 10.1002/joc.5086.
URL: *https://doi.org/10.1002/joc.5086*

IDEAM. 2019. "Estudio Nacional del Agua 2018.".

Karger, Dirk Nikolaus, Olaf Conrad, Jürgen Böhner, Tobias Kawohl, Holger Kreft, Rodrigo Wilber Soria-Auza, Niklaus E. Zimmermann, H. Peter Linder and Michael Kessler. 2017. "Climatologies at high resolution for the earth's land surface areas." *Scientific Data* 4:1–20.
URL: *http://dx.doi.org/10.1038/sdata.2017.122*

R Core Team. 2019. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing.
URL: *https://www.R-project.org/*

Raza, Ali, Yongguang Hu, Muhammad Shoaib, Manar K. Abd Elnabi, Muhammad Zubair, Muhammad Nauman and Neyha Rubab Syed. 2021. "A systematic review on estimation of reference evapotranspiration under prisma guidelines.".

Rodríguez-Almonacid, Deidy Viviana, Joaquin Guillermo Ramírez Gil, Joaquín Guillermo Ramírez-Gil, Olga Lucia Higuera, Francisco Hernández and Eliecer Díaz-Almanza. 2023. "Comprehensive Step-by-Step Guide to Using Data Science Tools in the Gestion of Epidemiological and Climatological Data in Rice A Comprehensive Step-by-Step Guide to Using Data Scie... Comprehensive Step-by-Step Guide to Using Data Science Tools in the Gestion of Epidemiological and A Comprehensive Step-by-Step Guide to Using Data Science Tools in the Gestion of Epidemiological and Climatological Data in Rice Production Systems.".
URL: *https://doi.org/10.3390/agronomy13112844*

Shuttleworth, James W. 2012. *Terrestrial hydrometeorology*.

Wanniarachchi, Susantha and Ranjan Sarukkalige. 2022. "A Review on Evapotranspiration Estimation in Agricultural Water Management: Past, Present, and Future.".

Xu, C.-Y and V P Singh. 2002. "Cross Comparison of Empirical Equations for Calculating Potential Evapotranspiration with Data from Switzerland.".

Análisis estadístico multivariado aplicado a datos hidrogeológicos usando R: Acuífero Transfronterizo del Amazonas (ATAS) en Leticia - Amazonas [*]

Laura Ximena Echeverri Gutierrez *Universidad Nacional de Colombia - sede Manizales*
Breiner Dan Bastidas Osejo *Universidad de Antioquia*

Resumen: El Acuífero Transfronterizo del Amazonas (ATAS), identificado en 2007 en el programa Internationally Shared Aquifer Resources Management (ISARM), desempeña un papel crucial para la oferta hídrica de la región transfronteriza de Leticia (Colombia), Tabatinga (Brasil) y Santa Rosa (Perú). Dada su importancia y la creciente presión sobre este recurso, en este estudio se llevan a cabo análisis estadísticos multivariados, con el objeto de comprender el estado de calidad del agua del ATAS en Leticia, empleando el software R. Se desarrolla una aproximación a la identificación de fuentes de contaminación mediante análisis de componentes principales y análisis clúster. Se determinan los índices de calidad de aguas subterráneas (ICA-AS). En la investigación se empleó la database de composición química del inventario de puntos de agua subterránea de Leticia (OTCA & SHI, 2015).

Keywords: Agua subterránea, composición química, ICA, calidad del agua

Introducción

El agua subterránea es un recurso fundamental para el abastecimiento de numerosas poblaciones en todo el mundo, ya que constituye aproximadamente el 96 % del agua dulce accesible del planeta (Betancur, 2023). Este recurso, renovable y finito, es vital para el sustento humano, el desarrollo socioeconómico y un componente valioso del ecosistema. Sin embargo, es vulnerable a impactos tanto naturales como antropogénicos. Diversas regiones transfronterizas dependen de este recurso, por lo tanto, sus condiciones de calidad y cantidad son aspectos de interés ambiental y socioeconómico (UNESCO, 2022).

La calidad del agua desempeña un papel esencial en la preservación de la salud, el medio ambiente, la seguridad alimentaria y el desarrollo sostenible. La gestión adecuada de este recurso se vuelve crucial para asegurar un futuro sostenible. Dicha calidad puede verse afectada por variaciones en el régimen hidrológico y, principalmente, por actividades antropogénicas, las cuales suelen generar el mayor impacto (OTCA, 2018).

En la actualidad, el uso de métodos estadísticos multivariados se ha generalizado en los estudios de caracterización hidroquímica y de calidad del agua subterránea ya que permiten reducir la dimensionalidad de los datos, identificar factores subyacentes que influyen en las variables de interés, desarrollar modelos para evaluar simultáneamente las relaciones entre las variables, inferir el origen de actividades que afectan los parámetros de calidad del agua, y entender las consecuencias de la interacción del sistema hídrico con el entorno geológico (Bodrud-Doza et al., 2016).

[*] **Autor de contacto**: lxecheverrig@unal.edu.co.

Esta investigación tiene como objetivo ampliar el análisis estadístico del inventario de puntos de agua subterránea, buscando identificar correlaciones entre variables y aproximarse a posibles fuentes de contaminación mediante el uso de métodos estadísticos multivariados.

Materiales y métodos

Zona de estudio

El municipio de Leticia, capital del departamento del Amazonas, se encuentra localizado en el extremo sur del país sobre la margen izquierda del río Amazonas, en la frontera entre Colombia, Perú y Brasil. Con una extensión territorial de 5.968 km^2, una altitud de 82 $m.s.n.m$ y una temperatura media de 25 a 38 C, Leticia alberga una población de 42.280 personas según el Censo del DANE 2018 (Vélez and Bastidas, 2018). El Acuífero Transfronterizo Amazónico (ATAS) desempeña un papel de vital importancia en esta ciudad ribereña, siendo una de las principales fuentes de abastecimiento de agua (SHI and OTCA, 2015). En la figura 1 se muestra la ubicación de los sitios muestreados, contrastando su posición con las potenciales fuentes de contaminación identificadas en la zona.

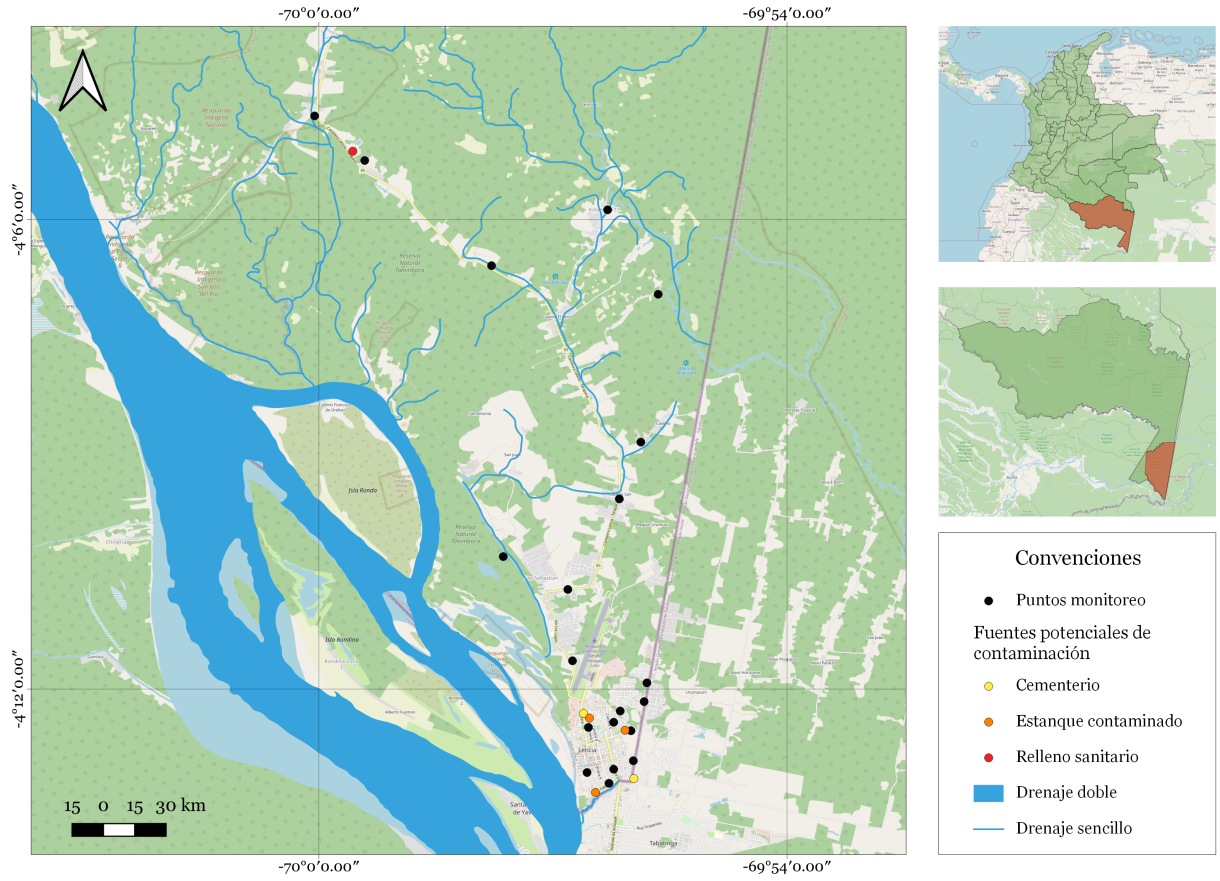


Figura 1: Mapa puntos de monitoreo.

Información de interés

Esta investigación se desarrolló a partir de la información recopilada durante el Inventario de Puntos de Agua Subterránea, realizado entre abril y junio de 2015 como parte del proyecto "Gestión Integrada y Sostenible de los Recursos Hídricos Transfronterizos en la Cuenca del Río Amazonas Considerando la Variabilidad Climática y el Cambio Climático", llevado a cabo por la Organización del Tratado de Cooperación Amazónica (OTCA). Este proyecto evaluó los sistemas acuíferos de Leticia a través de una caracterización hidrogeológica, hidroquímica e hidráulica de las aguas subterráneas en la región, con el objetivo de identificar diferentes puntos de agua, como pozos, aljibes, manantiales y piezómetros, y comprender la disponibilidad de agua subterránea junto con las características hidrogeológicas de la zona (SHI and OTCA, 2015).

La base de datos comprende 20 puntos de muestreo de agua subterránea en Leticia, con el registro de 29 especies químicas para cada observación. Esta información está disponible en el informe de la OTCA (2015) y en los registros públicos de la Corporación para el Desarrollo Sostenible del Sur de la Amazonia (CORPOAMAZONIA). Esta caracterización química se empleó como insumo principal para la aplicación de técnicas estadísticas descriptivas, métodos multivariados, indicadores de calidad de agua y análisis de componentes principales.

Resultados

Análisis de Componentes Principales

En la Tabla 1 se presentan la varianza, la varianza acumulada y los componentes principales VARIMAX rotados, obtenidos usando la función *prcomp*.

Tabla 1: Resultados PCA: rotación VARIMAX.

Parámetros rotación VARIMAX	PC1	PC2	PC3	PC4
Varianza	0.289	0.249	0.166	0.129
Varianza acumulativa	0.289	0.538	0.704	0.833
Bicarbonatos	0.788	-0.248	-0.461	
Cloruros	-0.204	-0.668	0.302	
Dureza total	0.834	-0.383	-0.326	
Color	0.958			
SST		0.143		-0.972
ST	0.193	-0.386	-0.128	-0.872
Turbiedad	0.887	0.106		-0.380
Hierro total	0.983			-0.108
Coliformes totales			-0.963	
Coliformes fecales	0.197		-0.938	
Potasio		-0.845	-0.274	
Magnesio	0.614	-0.443	-0.454	
Calcio	0.399	-0.416	-0.457	-0.216
Sodio	0.172	-0.907	-0.154	-0.173
SDT	0.370	-0.866	-0.149	-0.155
Conductividad	0.236	-0.853	0.127	0.102
OD	-0.213		-0.193	0.440

Aplicando el criterio de Kaiser (autovalores mayores a 1) se retuvieron 4 componentes principales que representan el 83.3 % de la varianza de los datos iniciales. El PC_1 explica el 28.9 % de la varianza, el PC_2 el 24.9 %, el PC_3 el 16.6 % y el PC_4 el 12.9 %. Tras el análisis de cargas con contribuciones mayores a 0.7 y menores a -0.7 (Echeverri, 2023), el PC_1 se define como factor de procesos de recarga - fondo natural, mientras que el PC_2 se caracteriza como factor de tránsito y descarga – evolución geogénica. Asimismo, el PC_3 se identifica como factor de contaminación por carga orgánica, y el PC_4 se asocia como factor de procesos de contaminación antrópica.

Análisis estadístico descriptivo

La Figura 2 presenta gráficamente la correlación entre los parámetros fisicoquímicos estudiados. Se destaca una correlación positiva significativa entre los bicarbonatos y la dureza total, así como entre el color y el hierro total. Además, se observa una correlación significativa entre la turbidez y el hierro, entre las coliformes fecales y las coliformes totales, y entre los sólidos disueltos totales (SDT) y el sodio.

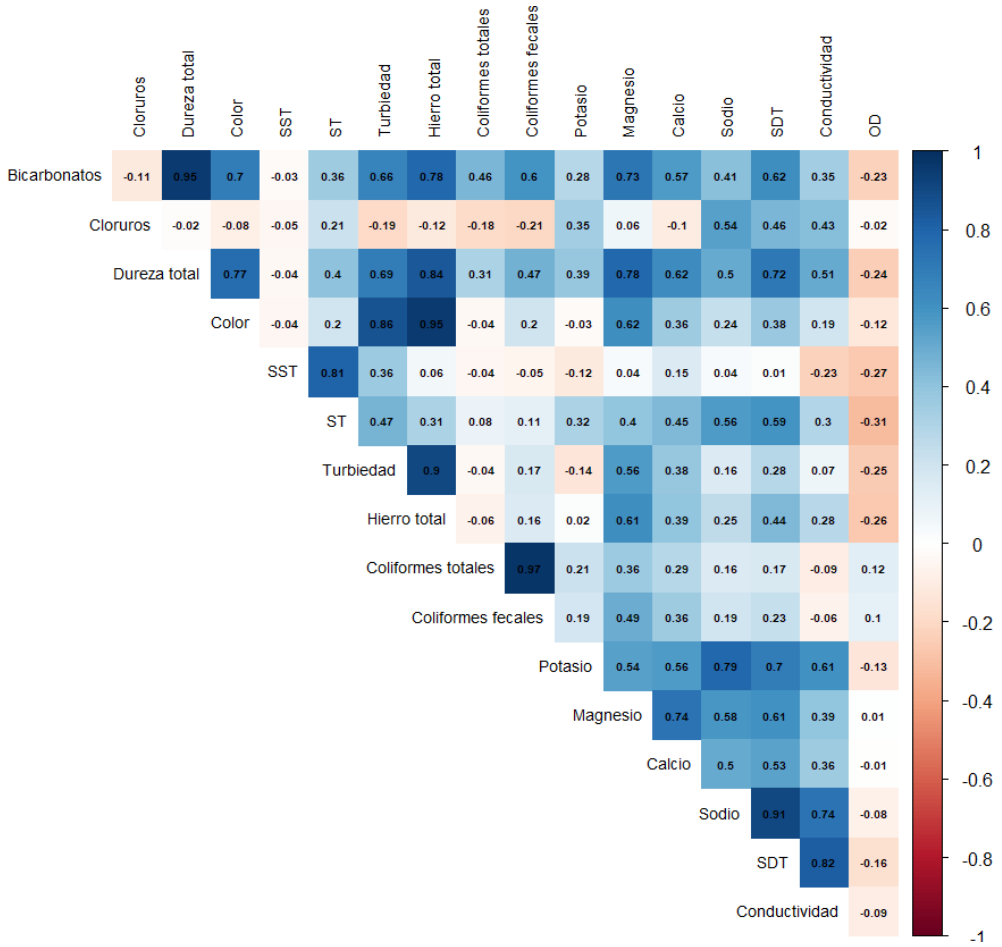


Figura 2: Análisis de correlación de variables.

De manera adicional, la Figura 3 expone los resultados obtenidos del análisis de clúster, estableciendo una relación con los hallazgos derivados del PCA, esta gráfica revela que, en relación

con los pozos, se identificaron 5 grupos mediante el análisis de clúster.

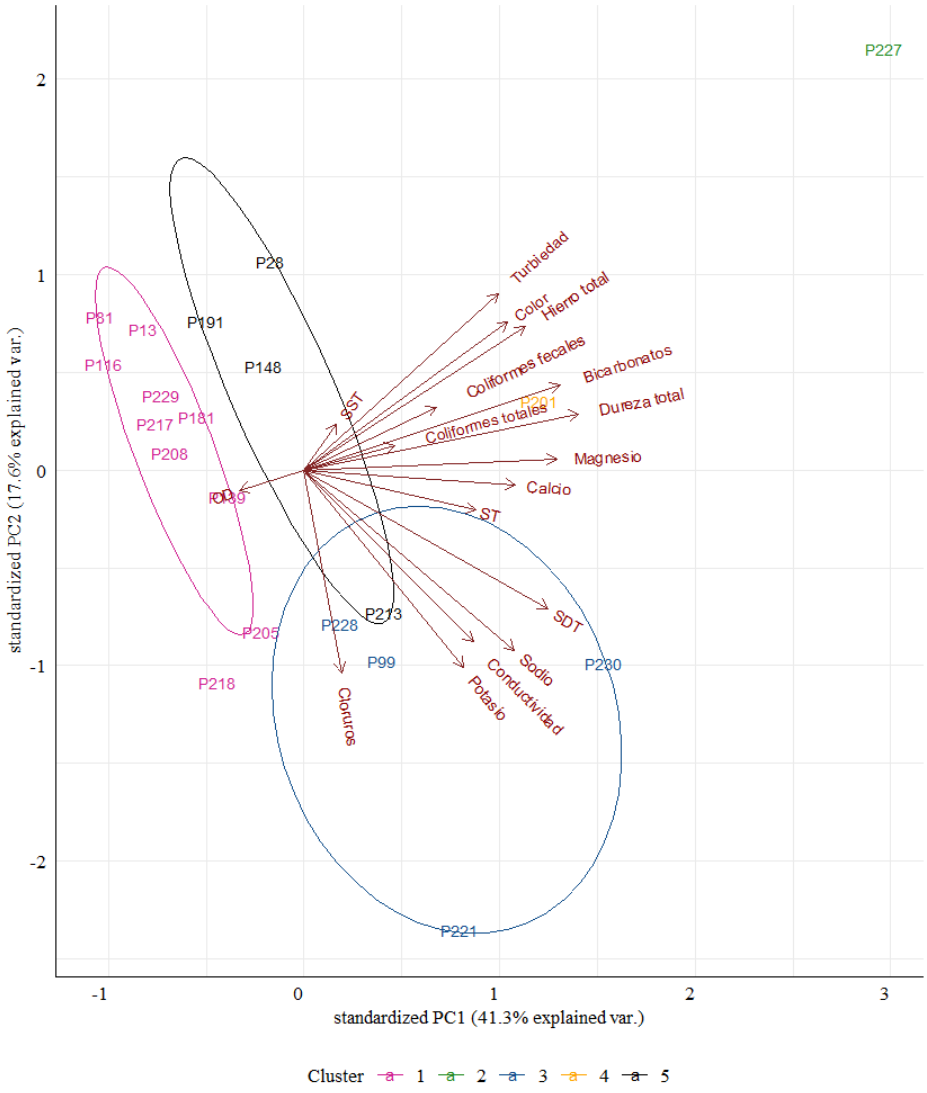


Figura 3: Análisis clúster

Índice de Calidad del Agua

Los Índice de Calidad del Agua (ICA) son medidas numéricas que evalúan las condiciones físicas, químicas y biológicas de una corriente de agua en un lugar específico y periodo determinado. Estos índices proporcionan una rápida evaluación de la contaminación y orientan sobre las posibilidades de uso del agua en distintas actividades. Es crucial destacar que los ICA varían entre agua superficial y subterránea ($ICA - AS$), considerando las características propias de cada tipo de recurso hídrico, como los parámetros evaluados, los límites establecidos y los criterios específicos de calidad. La evaluación de la calidad del agua subterránea debe incluir indicadores representativos para garantizar un análisis integral y facilitar la toma de decisiones en su gestión y control (Martínez, 2007).

En la actualidad, se cuenta con diversos $ICA - AS$. En este estudio se analizaron 3 $ICA - AS$: los $ICA - AS$ presentado en el informe de la OTCA ($ICA - AS$ e $ICA - AS - corregido$) y el $ICA - AS$ desarrollado por Martínez (2007), con el propósito de identificar posibles cambios significativos. Es importante resaltar que estas metodologías no solo abarcan conjuntos de especies distintos, sino que también asignan ponderaciones diferentes a dichas especies.

La Figura 4 presenta los resultados obtenidos para los $ICA - AS$ aplicados. El ICA OTCA 1 propuesto por (SHI and OTCA, 2015) relaciona valores típicamente menores, lo cual sugiere categorizaciones de calidad inferiores. En contraste, el $ICA - AS$ de Martínez (2007) asigna valores más altos, resultando en calificaciones superiores para los mismos puntos de muestreo. Las influencias de las diferentes variables fisicoquímicas y microbiológicas en los resultados del $ICA - AS$ podrían ser objeto de futuras investigaciones.

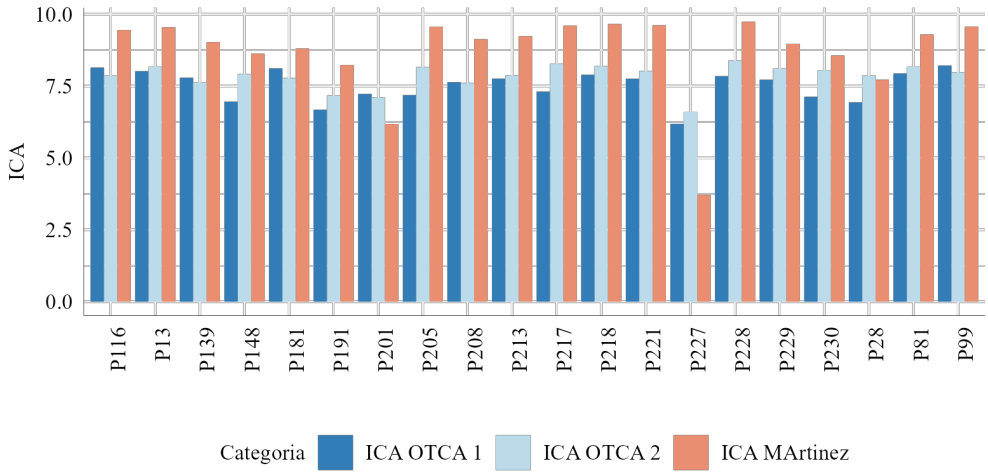


Figura 4: Resultados del ICA en los pozos por diferentes metodologías.

Discusión y conclusiones

- Se identificaron correlaciones significativas entre diferentes parámetros, destacando una relación fuerte y positiva entre los bicarbonatos y la dureza total, el color y el hierro total, turbiedad y el hierro, coliformes fecales y coliformes totales, y entre los SDT y el sodio.
- El PCA permitió identificar 4 componentes principales: PC_1 - Factor de procesos de recarga – fondo natural, PC_2 - Factor de tránsito y descarga – evolución geogénica, PC_3 - Factor de contaminación por carga orgánica y PC_4 - Factor de procesos de contaminación antrópica.
- El análisis clúster clasificó observaciones similares en grupos separados, facilitando la identificación de fuentes de contaminación y proporcionando información sobre tendencias espaciales en la caracterización hidroquímica y de calidad.

Código de R

Para conocer más detalles del código de R y los archivos utilizados para la realización de este estudio visite este enlace.

Referencias

Betancur, Teresita. 2023. "El potencial de las aguas subterráneas en Antioquia.".

Bodrud-Doza, Md, A. R.M.Towfiqul Islam, Fahad Ahmed, Samiran Das, Narottam Saha and M. Safiur Rahman. 2016. "Characterization of groundwater quality using water evaluation indices, multivariate statistics and geostatistics in central Bangladesh." *Water Science* 30:19–40.

Echeverri, Laura. 2023. "Evaluación del aporte de fuentes de emisión a la contaminación del aire por material particulado en la zona urbana de Manizales a partir de información de caracterización química y modelos de receptor.".

Martínez, Franco. 2007. "Propuesta de implementación de metodologías para la evaluación hidrogeoquímica y de calidad de las aguas subterráneas y aplicación a la zona del Bajo Cauca Antioqueño.".

OTCA. 2018. *Aguas Amazónicas, 10 Investigaciones sobre la cuenca hidrográfica más grande del mundo*.

SHI and OTCA. 2015. "Evaluación de los Sistemas Acuíferos de la Región de Leticia - Colombia.".

UNESCO. 2022. "Cooperación en materia de aguas transfronterizas en América Latina y el Caribe.".

Vélez, María Victoria and Breiner Bastidas. 2018. "Cuantificación de la recarga de aguas subterráneas en un acuífero transfronterizo de la cuenca Amazónica Acuífero Leticia-Tabatinga.".

Ciencia de datos: salarios bajo la lupa *

Daniela Alcázar *Universidad de Antioquia*
Esteffany Peña *Universidad de Antioquia*
Juliana Rueda *Universidad de Antioquia*

Resumen: La ciencia de datos es un campo de estudio que ha ganado importancia en los últimos años. Los salarios de los profesionales en esta área dependen de factores inherentes al puesto de trabajo. Este estudio presenta una aplicación Shiny desarrollada en R, que permite a los usuarios explorar la relación entre algunas variables de los profesionales, como el nivel de experiencia y la residencia, y de la empresa donde trabajan, como el tamaño y ubicación, y sus salarios. La aplicación presenta la visualización y el análisis descriptivo de los datos, así como la posibilidad de que el usuario prediga un salario a partir de la configuración de las demás variables. La herramienta puede ser utilizada para la toma de decisiones a nivel personal, permitiendo que estudiantes y profesionales interesados en ciencia de datos planifiquen su carrera o tomen decisiones sobre su desarrollo profesional, y a nivel empresarial, para que empresas puedan determinar el salario adecuado para un puesto de trabajo.

Keywords: Salarios, Ciencia de datos, Análisis descriptivo, Análisis predictivo

1. Introducción

La ciencia de datos es definida como un campo interdisciplinario que emplea técnicas, procesos, cálculos y algoritmos para extraer conocimiento de información masiva, ya sea estructurada o no estructurada, para el alcance de un objetivo en un escenario determinado (Goyal and Malviya, 2023; Lu, 2022; Mamatha et al., 2023). Este escenario puede tomar lugar en diversos sectores, tales como salud, financiero, manufacturero, agrícola, entretenimiento y comercio electrónico (Mamatha et al., 2023). Ha tomado gran relevancia en los sectores, especialmente por el aumento del volumen de información y la incorporación de las bases de datos en el arsenal tecnológico de las empresas (Kavitha, Jaisingh and Kaarthiekheyan, 2023; Xu et al., 2021). Sus bondades comprenden la identificación y descripción de patrones, tendencias y simetrías ocultas para el ojo humano en conjuntos de datos, dando valor a información aparentemente carente de importancia (Kavitha, Jaisingh and Kaarthiekheyan, 2023; Roman et al., 2023; Sundaram et al., 2023). De acuerdo con diversos autores, pilares de la ciencia de datos como la analítica son fundamentales para la toma de decisiones y el alcance de ventaja competitiva en las empresas (Carroll, 2023; Lo and Pachamanova, 2023).

En este contexto, la relevancia de orientar actividades científicas a asuntos relacionados con los salarios de los profesionales en ciencia de datos radica en la adecuada valoración del trabajo del recurso humano que ejecuta labores esenciales en una organización con interés en este tema. Partiendo de esa premisa, se ha desarrollado un sitio web que presenta información textual y gráfica y un modelo predictivo de salarios, con base en una recopilación de datos reales sobre salarios de 96 roles de ciencia de datos en distintos países del mundo. Se pretende que sea usado para la toma

* **Autor de contacto**: daniela.alcazar@udea.edu.co.

de decisiones en el futuro laboral de estudiantes y profesionales interesados en ciencia de datos.

La siguiente parte del documento está dividida así: la sección 2 expone la metodología usada para desarrollar el sitio web, en la sección 3 se explica de forma general las especificaciones de la página y se tratan con mayor profundidad en la sección 4; finalmente, en la sección 5 se disponen las conclusiones.

2. Metodología

La página web se crea a partir de elementos textuales y gráficos basados en un conjunto de datos abiertos obtenido de Kaggle y originado de aijobs.net, que está disponible en este vínculo. La base de datos contiene información de los salarios de profesionales del área de ciencia de datos en el periodo 2020-2023, cuenta con 3755 observaciones y 11 variables.

Para construir el la página web se emplearon 22 librerías. En la construcción estructural y estética de la página web se usaron las librerías **shiny** (Chang et al., 2023), **shinythemes** (Chang, 2021) y **wordcloud2** (Lang and tin Chien, 2018). Para la manipulación de datos se usaron las librerías **dplyr** (Wickham et al., 2023), **readr** (Wickham, Hester and Bryan, 2023) y **tidyverse** (Wickham et al., 2019). La visualización de los datos por medio de los distintos tipos de gráficos en la página web es posible usando las librerías **ggplot2** (Wickham, 2016), **ggridges** (Wilke, 2022), **ggtext** (Wilke and Wiernik, 2022), **rlang** (Henry and Wickham, 2023), **scales** (Wickham and Seidel, 2022), **sf** (Pebesma and Bivand, 2023), **leaflet** (Cheng et al., 2023) y **plotly** (Sievert, 2020); también se visualizan datos por medio de una tabla y un resumen, ambos en la sección descriptiva de la página web, para lo cual se usaron las librerías **DT** (Xie, Cheng and Tan, 2023), **gt** (Iannone et al., 2023) y **gtsummary** (Sjoberg et al., 2021). Por último, para el ajuste y validación del modelo de regresión lineal se emplearon las librerías **goftest** (Faraway et al., 2021), **lmtest** (Zeileis and Hothorn, 2002), **Metrics** (Hamner and Frasco, 2018), **MASS** (Venables and Ripley, 2002) y **nortest** (Gross and Ligges, 2015).

3. Interfaz

La aplicación web está disponible en este vínculo, y facilita el análisis de la base de datos mediante dos secciones principales: sección descriptiva y sección predictiva.

En la sección descriptiva el usuario puede interactuar con distintos elementos gráficos que le permitan entender las características de variables individuales de la base de datos. Asimismo, puede apreciar la relación entre el salario y otras (hasta dos) variables que él escoja; para algunas combinaciones de variables se tienen elementos visuales geográficos.

La sección predictiva se presenta como una herramienta para que el usuario realice predicciones de salarios con base en variables explicativas de su preferencia, también puede escoger las medidas de desempeño a las que se somete el modelo de regresión lineal. El valor predicho del salario, las características del modelo, los parámetros de predicción, las variables incluidas y los resultados de las medidas de desempeño son mostradas en esta sección.

En la Figura 1 se ilustra la ventana que se despliega al dar click al vínculo.



Figura 1: Pestaña 'Acerca del proyecto'

4. Resultados

4.1. Sección descriptiva

En la sección descriptiva se presentan tres subsecciones dispuestas en un menú de pestañas: "Análisis univariado", "Análisis multivariado" y "Datos". Esto se puede entender con mayor facilidad observando la Figura 2.

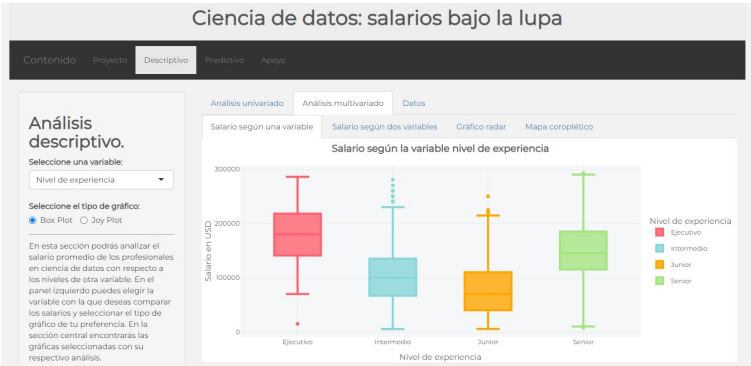


Figura 2: Sección descriptiva

La primera pestaña muestra, por medio de gráficos de barras y gráficos circulares, la información sobre las observaciones en la base de datos de las variables tipo factor: 'Año', 'Nivel de experiencia', 'Tipo de contrato', 'Rol', 'Moneda de pago', 'Residencia del empleado', 'Modalidad de trabajo, 'Ubicación de la empresa' y 'Tamaño de la compañía'.

En la pestaña "Análisis multivariado" se presentan cuatro opciones: "Salarios respecto a una variable", "Salario respecto a dos variables", "Gráfico radar" y "Mapa coroplético". La primera permite apreciar por medio de un diagrama de caja o un gráfico ridgeline la relación entre los niveles de una variable categórica elegida con el salario; la segunda opción, similar a la primera, permite al usuario observar el comportamiento del salario, esta vez el a partir de los niveles de dos variables mediante diagramas de barras en forma de múltiples paneles; finalmente, las últimas dos opciones presentan al usuario un gráfico de radar en el que puede observar los salarios medios con respecto a las variables 'Rol' y 'Nivel de experiencia', y un mapa coroplético.

La última pestaña muestra dos opciones que son “Base de datos” y “Resumen”. En “Base de datos” se muestra la base de datos usada en este estudio. El usuario puede elegir el número de datos que se muestran a la vez, filtrar la base de acuerdo con una variable que elija o por salario máximo y mínimo, e incluso descargar los datos. En la pestaña “Resumen” se presenta un resumen de las variables de la base de datos.

4.1. Sección predictiva

La sección predictiva se presenta como una herramienta para que el usuario, a partir de un modelo de regresión lineal múltiple, realice predicciones del salario en dólares con base en una configuración de las variables explicativas. De igual manera, en esta sección puede conocer las características y medidas de desempeño a las que es sometido el modelo.

5. Conclusiones

La aplicación web Shiny, desarrollada con R, proporciona apoyo a personas interesadas en desarrollarse profesionalmente en el campo de ciencia de datos. Esto se logra mediante la organización gráfica de la información de salarios recientemente devengados por profesionales del área, así como a través de un modelo de regresión lineal que estima el salario en función de especificaciones proporcionadas por el usuario.

En futuros estudios se debería considerar la inclusión de observaciones de otros países en la base de datos, a fin de tener una muestra representativa. De este modo, se tendría una visión más adecuada de las múltiples tendencias salariales en ciencia de datos y se mejoraría la aproximación de salarios para profesionales no estadounidenses.

Referencias

Carroll, Paula. 2023. "Analytics Modules for Business Students." *Operations Research Forum* 4:41.
URL: *https://doi.org/10.1007/s43069-023-00216-5*

Chang, Winston. 2021. *shinythemes: Themes for Shiny*. R package version 1.2.0.
URL: *https://CRAN.R-project.org/package=shinythemes*

Chang, Winston, Joe Cheng, JJ Allaire, Carson Sievert, Barret Schloerke, Yihui Xie, Jeff Allen, Jonathan McPherson, Alan Dipert and Barbara Borges. 2023. *shiny: Web Application Framework for R*. R package version 1.7.5.
URL: *https://CRAN.R-project.org/package=shiny*

Cheng, Joe, Barret Schloerke, Bhaskar Karambelkar and Yihui Xie. 2023. *leaflet: Create Interactive Web Maps with the JavaScript 'Leaflet' Library*. R package version 2.2.0.
URL: *https://CRAN.R-project.org/package=leaflet*

Faraway, Julian, George Marsaglia, John Marsaglia and Adrian Baddeley. 2021. *goftest: Classical Goodness-of-Fit Tests for Univariate Distributions*. R package version 1.2-3.
URL: *https://CRAN.R-project.org/package=goftest*

Goyal, Priyanshi and Rishabha Malviya. 2023. "Challenges and opportunities of big data analytics in healthcare." *Health Care Science* .

Gross, Juergen and Uwe Ligges. 2015. *nortest: Tests for Normality*. R package version 1.0-4.
URL: *https://CRAN.R-project.org/package=nortest*

Hamner, Ben and Michael Frasco. 2018. *Metrics: Evaluation Metrics for Machine Learning*. R package version 0.1.4.
URL: *https://CRAN.R-project.org/package=Metrics*

Henry, Lionel and Hadley Wickham. 2023. *rlang: Functions for Base Types and Core R and 'Tidyverse' Features*. R package version 1.1.2.
URL: *https://CRAN.R-project.org/package=rlang*

Iannone, Richard, Joe Cheng, Barret Schloerke, Ellis Hughes, Alexandra Lauer and JooYoung Seo. 2023. *gt: Easily Create Presentation-Ready Display Tables*. R package version 0.10.0.
URL: *https://CRAN.R-project.org/package=gt*

Kavitha, RK, W Jaisingh and V Kaarthiekheyan. 2023. Application of Artificial Intelligence and Data Science Across Domains: A Perspective Study. In *Handbook of Research on Data Science and Cybersecurity Innovations in Industry 4.0 Technologies*. IGI Global pp. 1–29.

Lang, Dawei and Guan tin Chien. 2018. *wordcloud2: Create Word Cloud by 'htmlwidget'*. R package version 0.2.1.
URL: *https://CRAN.R-project.org/package=wordcloud2*

Lo, Victor S Y and Dessislava A Pachamanova. 2023. "From Meaningful Data Science to Impactful Decisions: The Importance of Being Causally Prescriptive." *Data Science Journal* .

Lu, Jing. 2022. "Data science in the business environment: Insight management for an Executive MBA." *The International Journal of Management Education* 20:100588.
URL: *https://www.sciencedirect.com/science/article/pii/S1472811721001373*

Mamatha, T, A Balaram, B Rama Subba Reddy, C Shoba Bindu and M Niranjanamurthy. 2023. "Applications and Advancements in Data Science and Analytics." *Data Engineering and Data Science: Concepts and Applications* pp. 409–439.

Pebesma, Edzer and Roger Bivand. 2023. *Spatial Data Science: With applications in R*. Chapman and Hall/CRC.
URL: *https://r-spatial.org/book/*

Roman, Alexander, Roy T Forestano, Konstantin T Matchev, Katia Matcheva and Eyup B Unlu. 2023. "Oracle-Preserving Latent Flows." *Symmetry* 15.
URL: *https://www.mdpi.com/2073-8994/15/7/1352*

Sievert, Carson. 2020. *Interactive Web-Based Data Visualization with R, plotly, and shiny*. Chapman and Hall/CRC.
URL: *https://plotly-r.com*

Sjoberg, Daniel D., Karissa Whiting, Michael Curry, Jessica A. Lavery and Joseph Larmarange. 2021. "Reproducible Summary Tables with the gtsummary Package." *The R Journal* 13:570–580.
URL: *https://doi.org/10.32614/RJ-2021-053*

Sundaram, Jawahar, K Gowri, S Devaraju, S Gokuldev, Sujith Jayaprakash, Harishchander Anandaram, C Manivasagan and M Thenmozhi. 2023. An Exploration of Python Libraries in Machine Learning Models for Data Science. In *Advanced Interdisciplinary Applications of Machine Learning Python Libraries for Data Science*. IGI Global pp. 1–31.

Venables, W. N. and B. D. Ripley. 2002. *Modern Applied Statistics with S*. Fourth ed. New York: Springer. ISBN 0-387-95457-0.
URL: *https://www.stats.ox.ac.uk/pub/MASS4/*

Wickham, Hadley. 2016. *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York.
URL: *https://ggplot2.tidyverse.org*

Wickham, Hadley and Dana Seidel. 2022. *scales: Scale Functions for Visualization*. R package version 1.2.1.
URL: *https://CRAN.R-project.org/package=scales*

Wickham, Hadley, Jim Hester and Jennifer Bryan. 2023. *readr: Read Rectangular Text Data*. R package version 2.1.4.
URL: *https://CRAN.R-project.org/package=readr*

Wickham, Hadley, Mara Averick, Jennifer Bryan, Winston Chang, Lucy D'Agostino McGowan, Romain François, Garrett Grolemund, Alex Hayes, Lionel Henry, Jim Hester, Max Kuhn, Thomas Lin Pedersen, Evan Miller, Stephan Milton Bache, Kirill Müller, Jeroen Ooms, David Robinson, Dana Paige Seidel, Vitalie Spinu, Kohske Takahashi, Davis Vaughan, Claus Wilke, Kara Woo and Hiroaki Yutani. 2019. "Welcome to the tidyverse." *Journal of Open Source Software* 4(43):1686.

Wickham, Hadley, Romain François, Lionel Henry, Kirill Müller and Davis Vaughan. 2023. *dplyr: A Grammar of Data Manipulation*. R package version 1.1.3.
URL: *https://CRAN.R-project.org/package=dplyr*

Wilke, Claus O. 2022. *ggridges: Ridgeline Plots in 'ggplot2'*. R package version 0.5.4.
URL: *https://CRAN.R-project.org/package=ggridges*

Wilke, Claus O. and Brenton M. Wiernik. 2022. *ggtext: Improved Text Rendering Support for 'ggplot2'*. R package version 0.1.2.
URL: *https://CRAN.R-project.org/package=ggtext*

Xie, Yihui, Joe Cheng and Xianying Tan. 2023. *DT: A Wrapper of the JavaScript Library 'DataTables'*. R package version 0.30.
URL: *https://CRAN.R-project.org/package=DT*

Xu, Zongben, Niansheng Tang, Chen Xu and Xueqi Cheng. 2021. "Data science: connotation, methods, technologies, and development." *Data Science and Management* 1(1):32–37.

Zeileis, Achim and Torsten Hothorn. 2002. "Diagnostic Checking in Regression Relationships." *R News* 2(3):7–10.
URL: *https://CRAN.R-project.org/doc/Rnews/*

R Ladies Medellín - Aplicativo Web *

Sara Garces Cespedes, *Universidad Nacional de Colombia - Sede Medellín*
Maria Valentina Clavijo Mesa, *Universidad de Antioquia*
Stephany Michell Lobo Laguado *Universidad Nacional de Colombia - Sede Medellín*
Carmen Elena Patiño Rodríguez *Universidad de Antioquia*
Ana Maria Sánchez Henao *Universidad Nacional de Colombia - Sede Medellín*
Olga Cecilia Usuga Manco *Universidad de Antioquia*

Resumen: El propósito de este proyecto es recopilar información sobre los talleres llevados a cabo por la comunidad RLadies Medellín a lo largo de varios años. El objetivo principal es proporcionar a la comunidad una colección de tutoriales, talleres, trabajos realizados y enlaces de interés que estén disponibles públicamente. A través de esta plataforma, cualquier persona podrá acceder a recursos relacionados con los temas tratados en los talleres.

Keywords: Dashboard, Shiny, RLadies Medellín

Introducción

En los últimos años, se ha observado un creciente interés por parte de los gobiernos y diferentes instituciones, en fomentar la adquisición de habilidades de programación en la sociedad moderna, incluyendo a grupos minoritarios que históricamente han estado subrepresentados en el ámbito de la tecnología. En este contexto, la comunidad de usuarios del lenguaje de programación R ha desempeñado un papel destacado desde 2012 con la creación de R-Ladies, una comunidad que promueve la creación de espacios donde cualquier persona puede participar en conferencias, talleres y charlas enfocadas al aprendizaje de R, fomentando así la inclusión dentro de la comunidad.

Este trabajo presenta un aplicativo web construido con Shiny (Chang et al., 2022) en R (R Core Team, 2019), creado con el objetivo de exponer el trabajo desarrollado por el capítulo de R-Ladies Medellín. Este aplicativo compila todos los encuentros realizados por el capítulo desde sus inicios, ofreciendo un registro completo y accesible de su contribución a la comunidad de Medellín. El aplicativo está dividido en pestañas en las que se puede navegar de forma no secuencial. Las temáticas están agrupadas en: Introducción a R, Visualización, Machine Learning, Preprocesamiento de datos y R en otros ambientes. Además, se incluye una breve descripción de las cofundadoras que dieron origen a este capítulo y una presentación del actual equipo de trabajo. Este enfoque integral busca resaltar tanto el impacto como la diversidad de talento que caracteriza a la comunidad de R-Ladies Medellín

Metodología

El aplicativo web de R-Ladies Medellín fue creado usando el lenguaje de programación R. Este lenguaje cuenta con una librería llamada Shiny que permite construir aplicativos web interactivos en R sin necesidad de tener conocimiento avanzado en desarrollo web, HTML o CSS. Todos los

* **Autor de contacto**: olga.usuga@udea.edu.co

aplicativos web de Shiny están compuestos por dos bloques principales de código de R, los cuales pueden ser creados por separado, es decir, en dos scripts de R diferentes o pueden ser creados en un mismo script:

- **UI:** objeto de interfaz de usuario que controla el diseño y la apariencia de su aplicación
- **SERVER:** función que permite acceder a la información entregada por el usuario desde la interfaz para realizar cálculos y especificar cómo se deben actualizar las salidas que el usuario puede observar en el aplicativo.

Para este aplicativo se creó un solo script de R que contiene el UI y el SERVER. A través del UI se detalló el aspecto del aplicativo, es decir, lo que el usuario ve cuando ingresa a la aplicación. En este caso, se crea una interfaz con 9 pestañas. Algunas de estas pestañas contienen paneles de múltiples pestañas que representan los diferentes eventos que la comunidad ha llevado a cabo. El diseño de cada una de las pestañas se define por separado en la UI. Es importante mencionar que a través de Shiny es posible personalizar completamente la app, es decir, se pueden seleccionar diferentes tamaños y colores de letra, colores para el fondo, agregar imágenes, links, bloques de texto, bloques de código, iconos, entre otros.

En el server se crearon múltiples objetos de salida que se definen en R con la función *downloadHandler()*. Esta función permite que el contenido de la aplicación esté disponible para el usuario como descarga de archivos. En este caso, el usuario puede descargar archivos PDF con información de interés referente a la temática de los encuentros.

Otras de las librerías que se utilizaron para crear este aplicativo son:

- **shinythemes:** proporciona algunos temas Bootstrap para usar con Shiny (Chang, 2021).
- **ggplot2:** paquete de R más popular para la visualización de datos (Wickham, 2016).
- **dplyr:** conjunto de funciones diseñadas para permitir la manipulación de bases de datos (**?**).
- **DT:** proporciona una interfaz de R para el uso de la librería DataTables de JavaScript (Xie, Cheng and Tan, 2023).
- **plotly:** paquete de R para crear gráficos web interactivos a través de la librería plotly.js de JavaScript (Sievert, 2020).
- **readxl:** paquete para importar datos de Excel a R (Wickham and Bryan, 2023).
- **formattable:** paquete diseñado para aplicar formato a vectores y tablas de datos con el objetivo de facilitar y mejorar la visualización de los datos (Ren and Russell, 2021).

Aplicación

La aplicación Shiny del capítulo Medellín de RLadies ofrece una visualización interactiva de la variedad de contenidos y recursos que la comunidad ha desarrollado desde su inicio en noviembre de 2019 hasta septiembre de 2023. Con un diseño intuitivo de **nueve pestañas**, la aplicación invita a los usuarios a explorar distintos aspectos de la iniciativa.

La primera pestaña sirve como una entrada acogedora a la comunidad RLadies, destacando el propósito y la estructura de la aplicación. Posteriormente, los visitantes encuentran en una segunda pestaña la presentación del equipo de trabajo actual y conocen algunas caracteristicas de las cofundadoras que dieron origen a esta inspiradora iniciativa en la ciudad de Medellín.

A lo largo de las siguientes seis pestañas, la aplicación organiza el contenido desarrollado para la comunidad, guiando a los usuarios a través de los diversos Meetups. Desde una **introducción sólida a R**, diseñada para aquellos que dan sus primeros pasos en el lenguaje de programación, hasta análisis profundos de **machine learning** y **preprocesamiento de datos**, cada pestaña ofrece una experiencia de aprendizaje única. Cada evento incluye un video capturando el contenido, una breve descripción del mismo con las librerías necesarias, y un enlace a GitHub que proporciona todo el material necesario para replicar el contenido del encuentro. Además, se exploran los variados usos de **R en diferentes entornos e industrias**, brindando un interesante vistazo al papel del lenguaje de programación en sectores de alto riesgo.

Finalmente, la última pestaña se reserva para **eventos especiales**, como conferencias y grabaciones de lives en Instagram, proporcionando un acceso fácil a contenidos adicionales y eventos destacados. En resumen, la aplicación Shiny de RLadies Medellín es una herramienta valiosa que no solo presenta la riqueza de conocimiento acumulado, sino que también invita a los usuarios a sumergirse en la diversidad y la inclusión que caracterizan a la comunidad RLadies a nivel global.

¡Explora la App de RLadies Medellín!

Resultados

En esta primera versión la aplicación se actualizará cada seis meses. Como resultado del desarrollo de metodología se obtuvieron nueve pestañas: dos de información general, siete donde se encuentran las actividades realizadas por R-Laides Capítulo Medellín, agrupados por temas de interés, para facilitar la consulta y finalmente aparecen otros eventos realizados por R-ladies Capítulo Medellín. La distribución de las pestañas se observa en la 1.

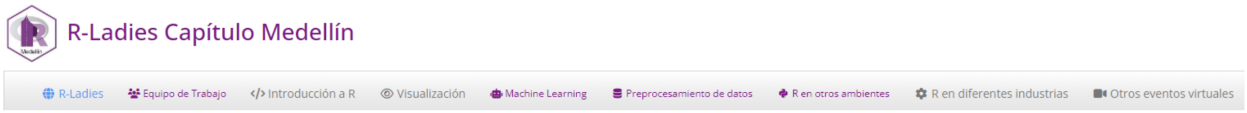


Figura 1: Pestañas de aplicación web de RLadies Medellín

La primera pestaña denominada R-Ladies se encuentra información general de la comunidad global, así como la descripción del espacio. En la segunda pestaña se encuentra la descripción del equipo actual de capítulo Medellín y del equipo cofundador. Como se mencionó anteriormente las temáticas fueron agrupados en siete secciones. En la primera temática, denominada Introducción a R, fueron ubicadas videos cortos donde se encuentran recursos básicos para aquellas personas que están iniciando el conocimiento en el lenguaje de programación.

Las temáticas de Visualización, Machine Learning, Preprocesamiento de datos, R en otros ambientes y R en diferentes industrias, se encuentran organizadas una estructura de dos bloques. En el primer bloque están los encuentros (Meetup) que han sido referentes a la temática en particular En el segundo bloque está la información referente al Meetup, donde está la descripción del encuentro, las librerías utilizadas, la fecha del encuentro, el enlace al repositorio Github donde se encuentra la información, la modalidad (Virtual y Presencial) que contiene el link al video para los encuentros virtuales y finalmente el link a la hoja de ayuda (Cheat Sheet) de la principal librería. En la Figura 2 está un ejemplo de la sección denominada Machine Learning.

Finalmente, la última sección se refiere a otros eventos que se han realizado tales como Confe-

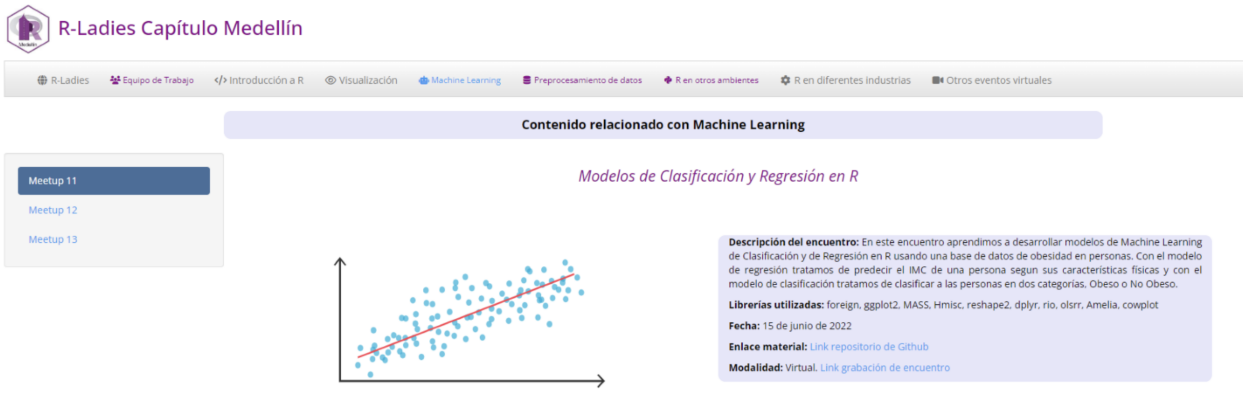


Figura 2: Ejemplo de Sección Machine Learning

meet 2020 y Lives de interés que ha buscado dar a conocer el uso del lenguaje de programación R.

Conclusiones

La disponibilidad material de aprendizaje del lenguaje de programación R es esencial para fomentar la adopción y el dominio de esta herramienta en la comunidad. Al contar con recursos accesibles, como tutoriales, ejemplos prácticos y proyectos colaborativos, se facilita el proceso de aprendizaje para los usuarios, permitiéndoles explorar y comprender de manera más efectiva las complejidades del lenguaje. Esto no solo acelera el desarrollo de habilidades en R, sino que también promueve la colaboración entre aprendices, creando un entorno en el que se comparten conocimientos y se resuelven desafíos de manera conjunta, enriqueciendo así la experiencia de aprendizaje.

La generación de material de uso libre en R no solo elimina barreras económicas, permitiendo a estudiantes y profesionales acceder a recursos de calidad de forma gratuita, sino que también contribuye a la construcción de una base de conocimientos colectiva. Esta base, alimentada por la colaboración abierta, no solo fortalece la comunidad de usuarios de R, sino que también acelera el progreso en la resolución de problemas complejos y la implementación de nuevas técnicas y metodologías.

Referencias

Chang, Winston. 2021. *shinythemes: Themes for Shiny*. R package version 1.2.0.
URL: *https://CRAN.R-project.org/package=shinythemes*

Chang, Winston, Joe Cheng, JJ Allaire, Carson Sievert, Barret Schloerke, Yihui Xie, Jeff Allen, Jonathan McPherson, Alan Dipert and Barbara Borges. 2022. *shiny: Web Application Framework for R*. R package version 1.7.4.
URL: *https://CRAN.R-project.org/package=shiny*

R Core Team. 2019. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing.
URL: *https://www.R-project.org/*

Ren, Kun and Kenton Russell. 2021. *formattable: Create 'Formattable' Data Structures*. R package version 0.2.1.
URL: *https://CRAN.R-project.org/package=formattable*

Sievert, Carson. 2020. *Interactive Web-Based Data Visualization with R, plotly, and shiny*. Chapman and Hall/CRC.
URL: *https://plotly-r.com*

Wickham, Hadley. 2016. *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York.
URL: *https://ggplot2.tidyverse.org*

Wickham, Hadley and Jennifer Bryan. 2023. *readxl: Read Excel Files*. R package version 1.4.2.
URL: *https://CRAN.R-project.org/package=readxl*

Xie, Yihui, Joe Cheng and Xianying Tan. 2023. *DT: A Wrapper of the JavaScript Library 'DataTables'*. R package version 0.30.
URL: *https://CRAN.R-project.org/package=DT*

Dashboard para la visualización de las variables que afectan la confiabilidad y la eficiencia en la operación de patinetas eléctricas *

Jose Luis Osorio Ariza *Universidad de Antioquia, Departamento de Ingeniería Industrial, Grupo Analítica para la Toma de Decisiones (ALIADO), Medellín Colombia*
Carmen Elena Patino-Rodriguez *Universidad de Antioquia, Departamento de Ingeniería Industrial, Grupo Analítica para la Toma de Decisiones (ALIADO), Medellín Colombia*
Fernando Guevara-Carazas *Universidad Nacional de Colombia, Departamento de Ingeniería Mecánica, Grupo Gestión, operación y mantenimiento de activos (GOMAC), Medellín Colombia*
Freddy Hernandez-Barajas *Universidad Nacional de Colombia, Departamento de Estadística, Grupo Estadística, Medellín Colombia*
Olga Cecilia Usuga-Manco *Universidad de Antioquia, Departamento de Ingeniería Industrial, Grupo Analítica para la Toma de Decisiones (ALIADO), Medellín Colombia*

Resumen: La medición de la eficiencia y confiabilidad de componentes críticos de vehículos eléctricos es esencial para diferentes actores de este entorno: proveedores, comercializadores y usuarios de movilidad sostenibles. Durante los últimos años se han encontrado pocos estudios de medición de eficiencia y confiabilidad en vehículos eléctricos de dos ruedas. En este trabajo se presenta una aplicación 'shiny' en R con el objetivo de analizar y visualizar datos críticos de una patineta eléctrica y las relaciones entre el voltaje, la temperatura, la corriente, la potencia y la aceleración. La interfaz de usuario contiene pestañas para cada una de las cinco variables y permite seleccionar un lugar y un rango de fechas, presenta gráficos de barras y series temporales relacionados con la variable seleccionada. La comprensión de las relaciones de estas variables con la eficiencia y confiabilidad de las patinetas eléctricas es esencial para optimizar la operación y mantenimiento de estos vehículos.

Keywords: Aplicación Shiny, Patineta eléctrica, Eficiencia, Confiabilidad, Movilidad sostenible.

Introducción

En un mundo que cambia rápidamente, es vital moverse de forma sostenible. Pasar a formas de transporte más ecológicas es una prioridad para todos. En este escenario, queremos presentarte una aplicación hecha con Shiny que ayudará a entender mejor las patinetas eléctricas y cómo funcionan.

Nuestra aplicación Shiny se ha desarrollado como parte de un proyecto de investigación llevado a cabo gracias a una participacion conjunta entre la Universidad de Antioquia y la Universidad Nacional. Este proyecto tiene como objetivo analizar y visualizar datos críticos relacionados con las patinetas eléctricas y cómo ciertas variables, como el voltaje, la temperatura, la corriente, la potencia y la aceleración, impactan en su rendimiento. La aplicacion Shiny puede ser encontrada en el siguiente enlace: https://5p4tad-jose-osorio.shinyapps.io/Patineta_App/

*Autor de contacto: jose.osorioa@udea.edu.co

La importancia de esta investigación radica en la capacidad de proporcionar información valiosa para la toma de decisiones informadas en el ámbito de la movilidad sostenible. Comprender cómo estas variables influyen en la eficiencia y confiabilidad de las patinetas eléctricas es esencial para optimizar el diseño, operación y mantenimiento de estos vehículos.

Este documento no solo sirve como un marco para presentar informes y análisis generados por nuestra aplicación Shiny, sino que también proporciona instrucciones detalladas sobre cómo utilizar eficazmente la herramienta.

El presente trabajo representa un paso adelante en la investigación de movilidad sostenible, brindando una plataforma interactiva para explorar y comprender los datos clave relacionados con las patinetas eléctricas y su eficiencia en el mundo real. Los lectores encontrarán información esencial para aprovechar al máximo esta valiosa herramienta.

El lenguaje R Core Team (2019) fue clave en la creación de este tablero grafico interactico y a su vez el documento fue hecho gracias a Xie (2015). Cabe aclarar que el manejo de datos se hizo gracias a la libreria dplyr que fue creada por Wickham et al. (2023)

Secciones

Widgets para actualizar los graficos

Selección del rango de fecha

El **sliderInput**, también conocido como `data_slider` en la aplicación de Shiny, es un componente que permite a los usuarios seleccionar un rango de valores o fechas en la interfaz gráfica. En el contexto de la aplicación, el data_slider se utiliza para permitir a los usuarios elegir un período de tiempo específico para el respectivo análisis. A continuacion se explica como funciona

Selección de fechas: El `data_slider` muestra un rango de fechas como una barra deslizante en la interfaz. Los usuarios pueden hacer clic y arrastrar los controladores en el rango de fechas para seleccionar un período de tiempo.

Valores mínimo y máximo: Se especifican los valores mínimo y máximo que definen el rango de fechas disponible para la selección. En el código, `min_date` y `max_date` determinan el intervalo de fechas que los usuarios pueden seleccionar.

Valor predeterminado: Se puede establecer un valor predeterminado para el `data_slider`, lo que significa que al cargar la página, se mostrará un rango de fechas específico como predeterminado. En la aplicación, el rango de fechas predeterminado es el rango completo de fechas disponibles.

Interacción del usuario: Los usuarios pueden ajustar el rango de fechas simplemente haciendo clic y arrastrando los controladores a lo largo de la barra deslizante. Cuando sueltan el controlador, el valor seleccionado se actualiza automáticamente.



Figure 1: Selector de Fechas.

Casilla para seleccionar lugares

El **place_selector** es un componente interactivo en la aplicación Shiny que brinda a los usuarios la capacidad de elegir ubicaciones específicas para el análisis. En el contexto de la aplicación, este selector de lugares permite a los usuarios seleccionar entre la ubicacion Rio y la ubicación Volador.

Aquí está cómo funciona el `place_selector`:

Selección de lugares: El `place_selector` muestra una lista de ubicaciones disponibles, en este caso las areas, en forma de casillas de verificación. Los usuarios pueden seleccionar una o varias ubicaciones haciendo clic en las casillas de verificación correspondientes.

Selección múltiple: Una característica clave del `place_selector` es que permite la selección de múltiples ubicaciones al mismo tiempo. Los usuarios pueden elegir las ubicaciones que deseen para comparar y analizar los datos correspondientes a esas áreas.

Personalización de análisis: El `place_selector` otorga a los usuarios la flexibilidad de personalizar su análisis en función de las ubicaciones que les interesen. Esto es especialmente útil cuando desean comparar datos entre diferentes áreas geográficas o cuando desean enfocarse en un lugar específico de su interés.

Actualización en tiempo real: A medida que los usuarios marcan o desmarcan las casillas de verificación, la aplicación se actualiza en tiempo real para reflejar las ubicaciones seleccionadas.

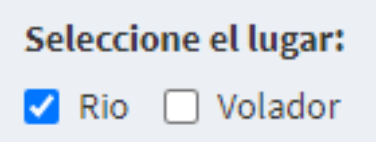


Figure 2: Casillas de Lugares.

Gráficos

Para hacer los graficos se utilizaron dos librerias muy importantes las cuales son plotly y ggplot2 creadas por Sievert (2020) y Wickham (2016) respectivamente.

Gráfico de Barras Apiladas

create_stacked_bar_plot es una funcionalidad clave en la aplicación Shiny que permite a los usuarios visualizar datos en forma de gráfico de barras apiladas. Este gráfico es particularmente útil cuando se desean comparar múltiples categorías de datos a lo largo del tiempo y observar cómo contribuye cada categoría al conjunto total.

A continuación, se explicará cómo funciona `create_stacked_bar_plot`:

Selección de categorías: Los usuarios pueden elegir entre varias categorías o variables de datos disponibles en tu aplicación. Estas categorías son representadas en el gráfico como segmentos de barras apiladas.

Visualización de la contribución: Una vez que el usuario seleccionó la variable de interes, `create_stacked_bar_plot` genera un gráfico de barras apiladas en el que cada barra representa un punto en el tiempo, en nuestro caso un determinado mes. Cada barra se divide en segmentos correspondientes a las variables seleccionadas.

Composición de datos: Los segmentos de barras apiladas muestran la contribución de cada categoría al valor total en ese punto en el tiempo. El usuario puede observar fácilmente cómo

se comporta cada categoría en relación con las demás y cómo cambian sus contribuciones con el tiempo.

Interacción dinámica: El gráfico de barras apiladas se actualiza en tiempo real a medida que el usuario selecciona o deselecciona categorías o ajusta los parámetros de tiempo.

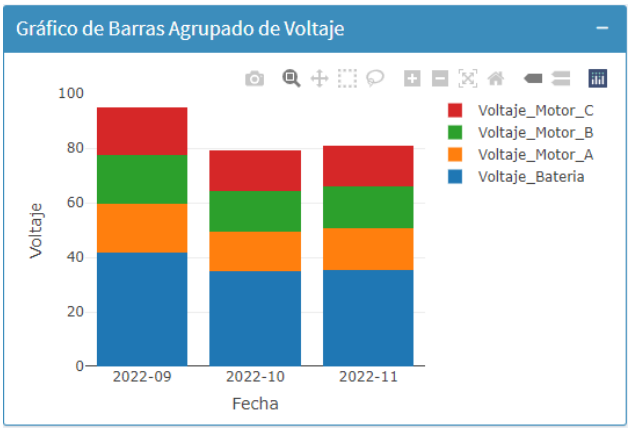


Figure 3: Gráfico de Barras Agrupadas.

Serie de Tiempo

timeline_of_parameter es una función esencial en la aplicación Shiny que permite a los usuarios explorar y analizar las series temporales de diferentes parámetros relacionados con patinetas eléctricas, como voltaje, temperatura, corriente, potencia y aceleración. Esta funcionalidad proporciona una visión detallada de cómo estos parámetros cambian con el tiempo y permite a los usuarios identificar tendencias y patrones significativos. A continuación se explicará cómo funciona `timeline_of_parameter`:

Generación de gráficos de series temporales: Una vez que el usuario ha especificado el parámetro, el rango de fechas y los lugares, `timeline_of_parameter` genera un gráfico de series temporales interactivo. Cada serie temporal representa cómo el parámetro seleccionado varía a lo largo del tiempo para los lugares elegidos.

Exploración interactiva: El usuario puede interactuar con el gráfico de series temporales, explorando diferentes aspectos de los datos. Puede hacer zoom en áreas específicas, desplazarse por el tiempo, activar o desactivar líneas de series temporales y acceder a información detallada al pasar el cursor sobre los puntos de datos.

Análisis y toma de decisiones: `timeline_of_parameter` permite a el usuario identificar patrones, tendencias y anomalías en las series temporales de datos. Esto es esencial para tomar decisiones informadas y comprender cómo los parámetros afectan la eficiencia y confiabilidad de las patinetas eléctricas en diferentes lugares y momentos.

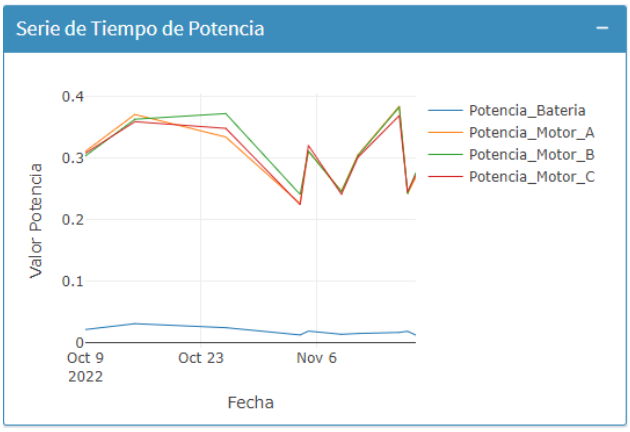


Figure 4: Serie de Tiempo.

References

R Core Team. 2019. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing.
URL: *https://www.R-project.org/*

Sievert, Carson. 2020. "Interactive Web-Based Data Visualization with R, plotly, and shiny.".
URL: *https://plotly-r.com*

Wickham, Hadley. 2016. *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York.
URL: *https://ggplot2.tidyverse.org*

Wickham, Hadley, Romain François, Lionel Henry, Kirill Müller and Davis Vaughan. 2023. *dplyr: A Grammar of Data Manipulation*. https://dplyr.tidyverse.org, https://github.com/tidyverse/dplyr.

Xie, Yihui. 2015. *Dynamic Documents with R and knitr*. 2nd ed. Boca Raton, Florida: Chapman and Hall/CRC. ISBN 978-1498716963.
URL: *https://yihui.name/knitr/*

Análisis descriptivo de las variables que afectan el tiempo de vida remanente en la operación de elementos críticos de bicicletas electricas *

Laura Herrera Giraldo *Universidad de Antioquia*
Alexander Amaya León *Universidad de Antioquia*
Carmen Elena Patiño Rodríguez *Universidad de Antioquia*
Olga Cecilia Úsuga Manco *Universidad de Antioquia*
Fernando Jesús Guevara Carazas *Universidad Nacional de Colombia - Sede Medellín*
Freddy Hernández Barajas *Universidad Nacional de Colombia - Sede Medellín*

Resumen: La importancia de los vehículos eléctricos hoy en día es innegable, es decir, que para comprender su funcionamiento resulta esencial experimentar en rutas que permitan analizar las diversas variables que inciden en su rendimiento. Aunque los estudios de laboratorio son comunes, las condiciones andinas presentan retos significativos por la topografía de la región. En este estudio, se utilizaron técnicas de análisis descriptivo de datos para analizar las variables que afectan la vida útil de los motores de las bicicletas eléctricas, a través del lenguaje de programación R. Se experimentó con 2 motores eléctricos instrumentados en 1 bicicleta eléctrica, midiendo 32 variables; los experimentos se realizaron durante 2 meses en una ruta de la ciudad de Medellín. Además, se encontró que efectivamente existen no solo relaciones lineales y correlaciones entre variables; sino también comportamientos atípicos que proporcionan información valiosa para la toma de decisiones.

Keywords: Análisis descriptivo, motor eléctrico, RUL, ggplot, dplyr, knitr, rmarkdown.

Metodología y Datos

El proyecto se inició incorporando dos modalidades de vehículos eléctricos: dos bicicletas StärkerUrban ST y una patineta Stärker Lite. Este estudio se centra en analizar las variables relacionadas con el motor eléctrico de las bicicletas que cumplen con especificaciones precisas: una potencia de 350 vatios y una velocidad máxima de 25 km/h.

Se llevaron a cabo experimentos utilizando dos motores en dos rutas urbanas de la ciudad de Medellín (Vía Las Palmas y Carril del Metro Plus), así como en un entorno de laboratorio, recorriendo distancias de 15 kilómetros. Estas pruebas se realizaron dos veces al día durante 28 días, con el mismo conductor para todas las pruebas.

Posteriormente, se instrumentalizaron los vehículos mediante sensores para obtener los datos necesarios y definir diversas variables. Se recopilaron un total de 40 variables y 78.886 registros para comprender el rendimiento del sistema, incluyendo corriente, potencia, voltaje y temperatura interna en las tres fases del motor, así como la aceleración en los ejes X, Y, y Z. Además, se consideraron factores ambientales como la humedad y temperatura, medidas a través de sensores

* **Autor de contacto**: elena.patino@udea.edu.co.

especializados. También se recopilaron datos sin sensor, como el ciclo, la fecha, el número de experimento y el Remaining Useful Life (RUL).

Una vez obtenida la información generada por los sensores, se procedió a la exploración mediante un análisis descriptivo con el objetivo de describir los datos identificando cantidad y tipo de variables, medidas descriptivas, gráficas de las variables y posibles distribuciones e identificación de patrones.

Finalmente, se analizaron los resultados generados en el lenguaje de programación R (R Core Team, 2019) con el fin de comprender el comportamiento de las variables asociadas al motor de las bicicletas y concluir a partir de esos resultados para validar el RUL, a través de librerías como readxl (Wickham and Bryan, 2023) para importar los datos desde hojas de cálculo, dplyr (Wickham et al., 2023) y tidyr (Wickham, Vaughan and Girlich, 2023) para realizar operaciones de manipulación de datos de manera más eficiente, ggplot2 (Wickham, 2016) para crear visualizaciones personalizadas, y otras librerías para dar formato a figuras como reshape2 (Wickham, 2007) y gridExtra (Auguie, 2017).

Resultados

En el marco del presente estudio, a continuación se presenta el análisis detallado del conjunto de datos recopilados durante las pruebas en ruta y en laboratorio de los motores de bicicletas eléctricas en diversas condiciones y ubicaciones. Con un total de 78.886 registros y 40 variables, nuestro objetivo fue describir las múltiples facetas que afectan el tiempo de vida remanente de estos motores críticos. Para este análisis descriptivo se usó la metodología del análisis del RUL seguida por Merkt (2019) y Kewalramani and Ram (2019).

Aceleraciones

La variable de aceleración en el eje X revela que dicho eje se alinea con la dirección del movimiento. Notablemente, esta variable exhibe una fuerte correlación con el peso del conductor. Así mismo, en la Figura 1 se observa que las aceleraciones en los ejes Y y Z, a pesar de no corresponder directamente a la dirección del movimiento, presentan un comportamiento similar, actuando de manera complementaria al eje X.

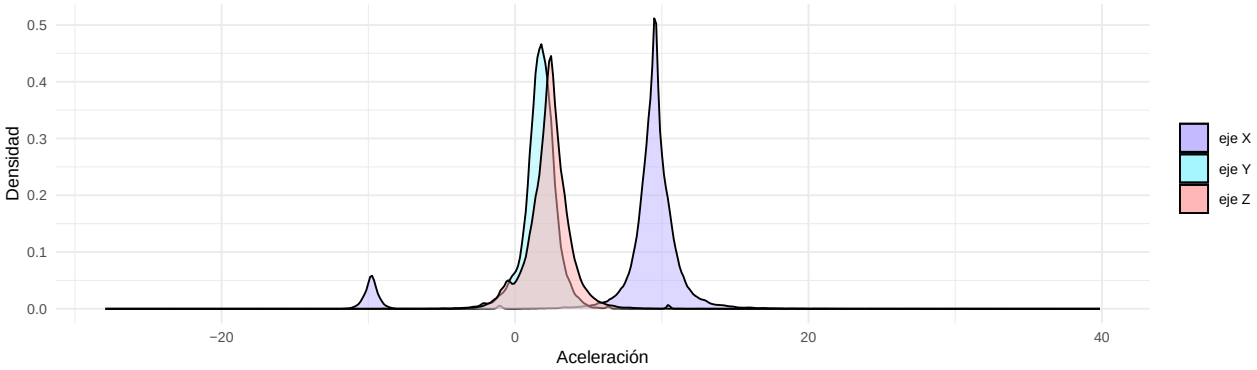


Figura 1: Diagrama de densidad de aceleraciones en los ejes de movimiento.

Corriente, potencia y voltaje

Las gráficas de la Figura 2 proporcionan una representación visual del desempeño de las variables de corriente, potencia y voltaje en tres ubicaciones diferentes (Laboratorio, Metroplus y vía Las Palmas) para ambos motores (Motor 1 y Motor 2).

En la ruta Las Palmas, se observa un aumento esperado en la corriente y la potencia en pendientes pronunciadas, indicando la necesidad de mayor potencia para vencer la resistencia del terreno. Este patrón se refleja en los datos de voltaje, que también aumentan para suministrar la potencia adicional requerida.

En la ruta Metroplus, en terrenos planos, tanto la corriente como la potencia del Motor 2 tienden a ser más constantes, ya que la resistencia al movimiento es menor. El voltaje también se mantiene relativamente estable en terreno plano.

En el entorno de laboratorio, donde se esperaba un comportamiento más estable y predecible, se observaron fluctuaciones mínimas, pero en general, las variables muestran un comportamiento consistente.

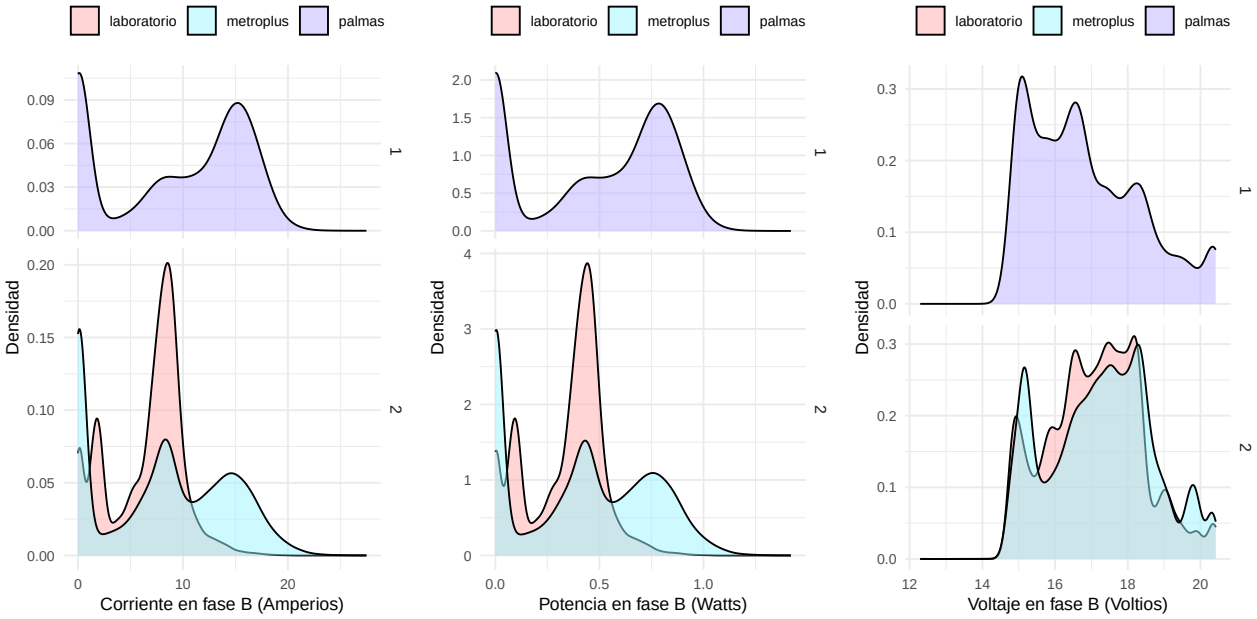


Figura 2: Digramas de densidad de las variables corriente, potencia y voltaje.

Temperatura y humedad ambiental

El análisis de la temperatura interna del Motor 1 en la vía Las Palmas de la Figura 3 revela una concentración de datos entre 0 y 60 °C, con valores cercanos a 0 que no deben interpretarse como ceros absolutos. Sin embargo, el Motor 1 no supera los 60 °C en la ruta Las Palmas debido a las exigencias del terreno, y el motor se quemó durante la prueba, limitando la disponibilidad de información relevante.

En contraste, los datos de temperatura interna en la ruta Metroplus y el Laboratorio se centran principalmente entre 30 y 60 °C. Se observan datos que superan los 90 °C, sugiriendo que el Motor 2 podría desempeñarse eficazmente en condiciones menos exigentes y alcanzar temperaturas más elevadas sin comprometer la integridad del bobinado del motor.

Es crucial destacar que la temperatura ambiental puede influir en la capacidad de disipación de calor del motor, y la humedad ambiental podría afectar la densidad del aire, influyendo en la capacidad de enfriamiento del motor. Ambientes más húmedos pueden proporcionar un efecto de enfriamiento adicional. En un entorno de laboratorio, donde se pueden controlar la temperatura y la humedad ambiental, se pueden mantener condiciones ideales para el funcionamiento del motor.

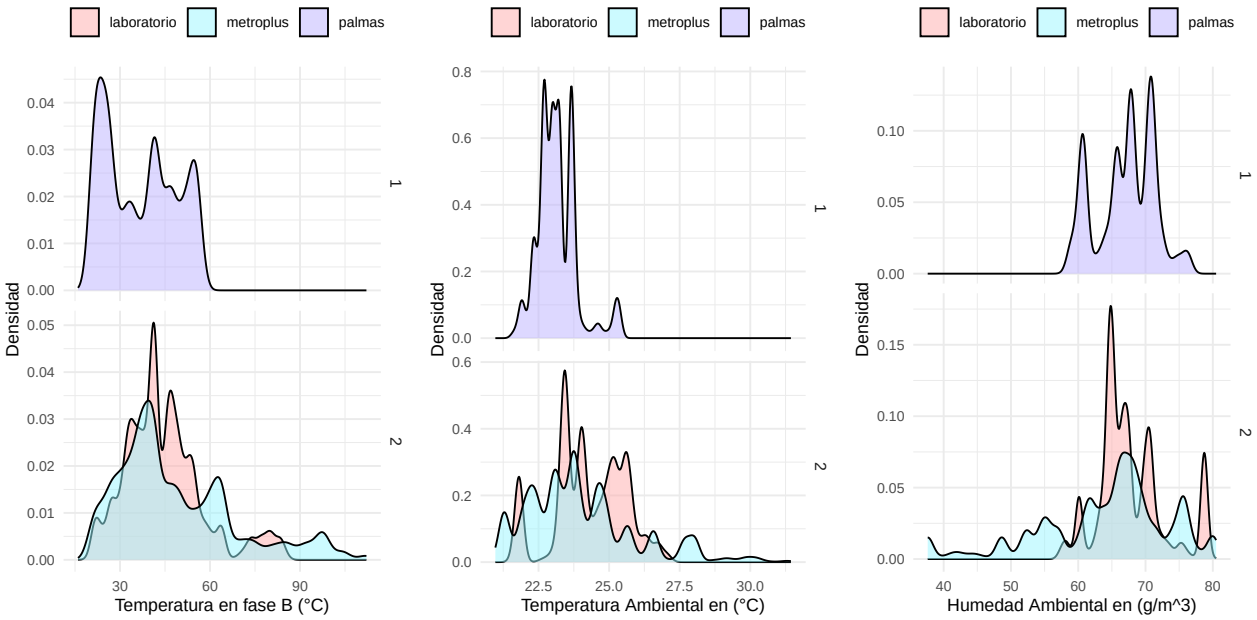


Figura 3: Diagramas de densidad de las variables temperatura interna, temperatura ambiental y humedad.

Relación entre temperatura y fecha

La relación entre la temperatura y la corriente de la Figura 4 se manifiesta como una consecuencia directa de la demanda de potencia. En situaciones donde se requiere una mayor potencia para desplazar una carga, la corriente aumenta, resultando en un calentamiento más pronunciado del embobinado del motor y, por ende, en un incremento de la temperatura.

La observación de la gráfica indica que durante las pruebas de ruta, la temperatura experimentó un aumento significativo, sugiriendo una demanda más elevada de potencia y corriente en estas condiciones. Este hallazgo se respalda adicionalmente al analizar los tiempos de ruta, revelando que el vehículo se descargaba más rápidamente durante las pruebas en ruta en comparación con los ensayos realizados en laboratorio. Este fenómeno subraya la influencia directa del entorno de prueba en el rendimiento del motor, resaltando la importancia de considerar condiciones de operación realistas para una evaluación precisa.

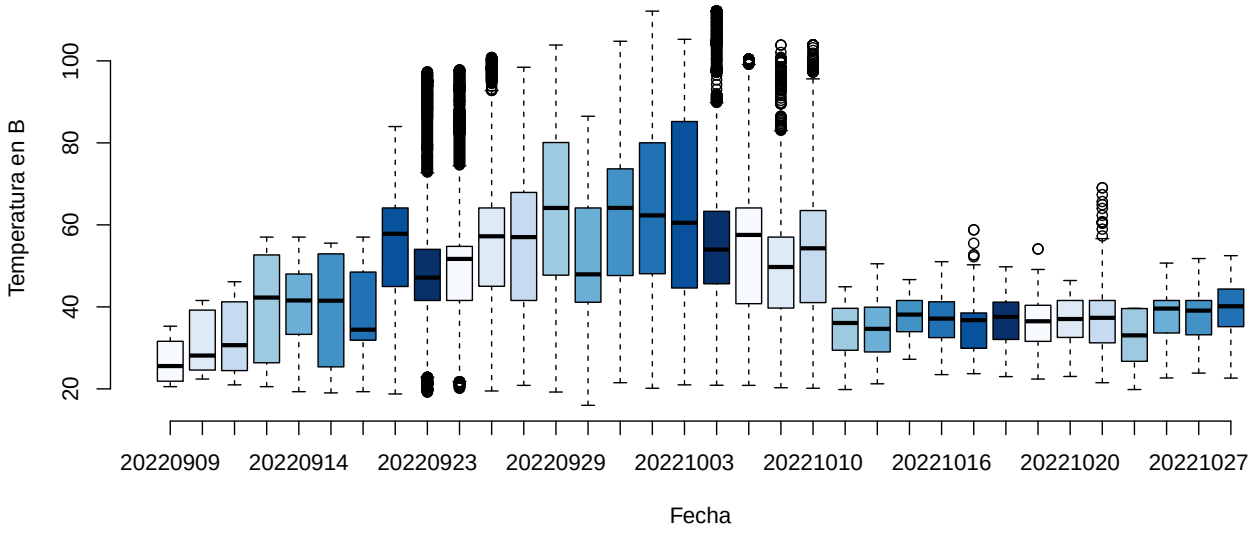


Figura 4: Boxplot comparativo entre las variables temperatura interna y fecha.

Conclusiones

La concentración de datos de temperatura interna del Motor 1 en la vía Las Palmas entre 0 y 60 °C indica que este motor no supera los 60 °C debido a las demandas del terreno y, de hecho, se quemó durante el experimento. Este hallazgo sugiere que las condiciones andinas presentan retos significativos para el rendimiento de los motores eléctricos en bicicletas, destacando la importancia de comprender el impacto específico del terreno en el tiempo de vida remanente.

Los datos de temperatura interna en la ruta Metroplus y el Laboratorio, con una concentración entre 30 y 60 °C y valores que superan los 90 °C, indican un comportamiento más eficaz del Motor 2 en condiciones menos exigentes. Esto resalta la influencia directa del entorno en el rendimiento de los motores eléctricos y la necesidad de considerar las condiciones específicas de operación para una evaluación precisa del tiempo de vida remanente.

La relación entre la temperatura y la corriente, evidenciada por un aumento significativo de la temperatura durante las pruebas de ruta, subraya la conexión directa entre la demanda de potencia y el calentamiento del motor. La observación de que el vehículo se descargaba más rápidamente en ruta que en laboratorio refuerza la importancia de realizar evaluaciones realistas del tiempo de vida remanente, considerando las condiciones específicas de operación.

Referencias

Auguie, Baptiste. 2017. *gridExtra: Miscellaneous Functions for "Grid"Graphics*. R package version 2.3.
URL: *https://CRAN.R-project.org/package=gridExtra*

Kewalramani, Rohit and A Ram. 2019. Estimation of Remaining Useful Life of Electric Motor using supervised deep learning methods. In *2019 IEEE Transportation Electrification Conference (ITEC-India)*. IEEE pp. 1–4.

Merkt, Oana. 2019. On the use of predictive models for improving the quality of industrial maintenance: An analytical literature review of maintenance strategies. In *2019 Federated Conference on Computer Science and Information Systems (FedCSIS)*. IEEE pp. 693–704.

R Core Team. 2019. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing.
URL: *https://www.R-project.org/*

Wickham, Hadley. 2007. "Reshaping Data with the reshape Package." *Journal of Statistical Software* 21(12):1–20.
URL: *http://www.jstatsoft.org/v21/i12/*

Wickham, Hadley. 2016. *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York.
URL: *https://ggplot2.tidyverse.org*

Wickham, Hadley, Davis Vaughan and Maximilian Girlich. 2023. *tidyr: Tidy Messy Data*. R package version 1.3.0.
URL: *https://CRAN.R-project.org/package=tidyr*

Wickham, Hadley and Jennifer Bryan. 2023. *readxl: Read Excel Files*. R package version 1.4.3.
URL: *https://CRAN.R-project.org/package=readxl*

Wickham, Hadley, Romain François, Lionel Henry, Kirill Müller and Davis Vaughan. 2023. *dplyr: A Grammar of Data Manipulation*. R package version 1.1.4.
URL: *https://CRAN.R-project.org/package=dplyr*